

面向工业缺陷检测的 任务蒸馏超表面光学视觉前端

开题/项目构想报告

建议方向：Task-distilled metasurface optical encoder for high-speed industrial defect inspection

核心问题	能否把复杂电子模型对工业缺陷的判别知识，压缩到一个受物理约束的线性/弱非线性超表面光学编码器中。
推荐应用	芯片/PCB/晶圆/金属表面等高分辨率、小缺陷、固定视场的在线检测。
推荐输出	先做 OK/NG 二分类和 defect heatmap，再扩展到 ROI proposal + tiny detector。
技术路线	超表面多通道卷积/频域滤波 + teacher-student 蒸馏 + 轻量电子后端。

版本：2026-05-09 调研版

0. 执行摘要：本项目到底要证明什么

本报告建议把课题定义为“面向工业缺陷检测的任务蒸馏超表面光学视觉前端”。核心不是宣称一片超表面实现完整 YOLO，也不是重复固定 Sobel/Laplacian 边缘检测，而是把工业检测中最靠近传感器的低级特征提取移动到光学成像链路中完成。超表面输出多通道缺陷敏感 feature maps，后端只保留很小的电子网络完成 OK/NG、缺陷热力图、ROI proposal 或轻量检测。


项目的关键科学/工程假设是：对于固定视场、固定照明、少类别的工业检测任务，复杂电子 teacher 模型学到的判别知识可以通过知识蒸馏压缩到一个受物理约束的线性光学编码器中；由于光学卷积在传播中并行完成，这种前端有望减少电子 MACs、传感器读出和后端推理负担。

推荐主线：先用开源工业异常/缺陷数据集完成算法闭环，优先选择 VisA 的 PCB 子集、DeepPCB、MVTec AD 2 或 KolektorSDD2；teacher 可以是 U-Net、YOLO、EfficientAD、PatchCore 或自建强模型；student 建议不是完整 YOLO，而是“OpticalConvBank + tiny heatmap/MLP head”。如果结果显示 8-16 个受物理约束的光学通道就能接近 teacher 的定位/分类能力，再进入 4f/SLM 光学验证和真实超表面设计。

预期创新点可以集中在三处：一是把 metasurface machine vision 从 MNIST/Fashion-MNIST 推进到真实工业缺陷检测；二是用 teacher-student 蒸馏把复杂检测知识压缩到可实现的光学编码器，而不是追求不现实的全光 YOLO；三是给出完整系统指标，包括小缺陷召回率、误报率、电子 MACs、读出数据量、延迟、光效率和鲁棒性。

- 最低可行版本：OK/NG 二分类，超表面输出 8 通道 feature maps，后端使用 global pooling + linear/MLP。
- 主论文版本：缺陷 heatmap 定位，超表面输出 16 通道 feature maps，后端使用 1x1 conv + sigmoid + 连通域分析。
- 系统增强版本：超表面作为 ROI generator，只把可疑区域交给 tiny YOLO 或小型检测器精检。

图 3 本项目与相关工作的错位：从“光学分类玩具任务”走向“工业检测相机前端”



项目定位图：已有工作分别覆盖光学卷积、光电蒸馏和工业检测，但工业检测相机级超表面前端仍有明显空白。

1. 文献地图与空白判断

1.1 超表面光学卷积已经成立，但应用仍偏“玩具任务”

代表性工作已经证明超表面可以通过 PSF/OTF 工程实现任意或多通道光学卷积。Fu 等的 meta-imager 展示了通过调控成像系统的点扩散函数实现任意光学卷积，用于边缘增强、微分、去噪和生物样品处理 [1]。Zheng 等的 multichannel meta-imager 使用角度/偏振复用实现多通道正负权重卷积，并与数字后端联合做机器视觉分类 [2]。Liang 等进一步提出空间频域训练方法，用超表面生成大尺寸任意 analog convolution kernels，并支持空间复用正负权重 [3]。

这些工作给出了本项目的光学可行性基础，但大多仍以 MNIST、Fashion-MNIST 或 CIFAR-10 为主要验证。工业在线缺陷检测的核心挑战是高分辨率、小缺陷、规则背景、反光/照明漂移和误报控制，这与通用分类数据集存在明显差异。

1.2 蒸馏是把复杂电子模型压到光学 student 的关键工具

光学系统的优势是高速线性变换，难点是非线性、深层表达和硬件误差。Xiang 等提出用知识蒸馏把非线性 CNN teacher 的知识迁移给更接近光学实现的线性/频域 student，以规避中间非线性不足 [4]。Wirth-Singh 等把 modified AlexNet 压缩成一个光学卷积层加两个电子全连接层，并用 meta-optic PSF 实现光学卷积，报告电子 MACs 从 17M 降到 86K、MNIST 准确率超过 93% [5]。

PHOENIX 进一步把蒸馏用于光电混合目标检测，但它不是 metasurface 成像前端，也不是 YOLO。该工作用 FCOS/RegNet-Y 或 ViT-Base 检测框架，将 backbone 中后段部分 stage 替换为 ONN student，并通过 feature-level/object-level 蒸馏恢复性能；COCO 上 1 个 ONN stage 的相对性能可通过蒸馏提升到约 88%-93% [6]。它说明蒸馏路线有价值，也说明“光学化越多层性能掉得越厉害”，因此本项目应避开通用 ONN detector，专注传感器前的工业专用光学编码器。

1.3 工业缺陷检测需要光学前处理，但尚未与任务学习超表面闭环结合

工业缺陷检测已有成熟数字模型和丰富数据集。MVTec AD、VisA、DeepPCB、KolektorSDD2 等都提供缺陷分类、定位或分割标注 [7-10]。同时，传统光学空间滤波已经被用于晶圆高速表面缺陷检测，例如 2025 年 wafer STEI 工作用高通空间滤波增强缺陷边缘，降低环境干扰和算法复杂度 [11]。

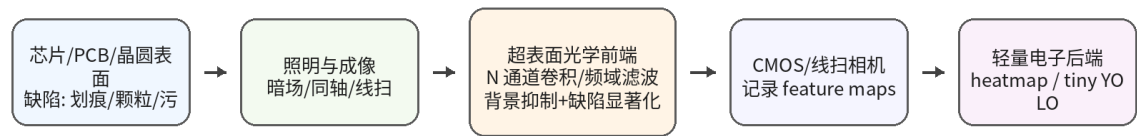
本项目的空白是：把“任务学习/蒸馏得到的 metasurface optical encoder”与“工业缺陷检测的真实任务指标”完整闭环。也就是不再只展示漂亮的边缘增强图，而是直接优化缺陷召回、误报、定位、吞吐、读出数据和后端网络复杂度。

方向	已有结论	本项目避开/推进点
超表面卷积	已证明 PSF/OTF 可实现卷积、多通道、正负权重。	从通用分类推进到工业缺陷检测，强调 task loss 而非手工滤波。
光电蒸馏	可把电子 teacher 知识迁移到线性/光学 student。	不做通用 COCO detector；做固定工业场景的可实现光学编码器。
工业检测	数字模型强，但面临高分辨率、小缺陷、实时性和照明漂移。	把特征提取前移到成像链路，比较电子 MACs/读出/延迟。

2. 总体系统设计：超表面做什么，电子后端做什么

建议系统定义为 hybrid optical-electronic defect inspection，而不是 all-optical YOLO。被动超表面主要实现一个或多个线性光学算子：空间卷积、频域滤波、PSF 编码、偏振/波长/空间复用等；电子后端负责非线性判别、通道混合、阈值、连通域、bbox 或类别输出。

图 1 系统总体思路：超表面不是完整 YOLO，而是传感器前的任务特征编码器



核心价值

- 把高分辨率图像的低级特征提取前移到光学域，减少电子 MACs 与读出压力。
- 让相机直接获得缺陷敏感特征图，而不是先获得完整原图再数字处理。
- 对固定工业场景，不追求通用 COCO 检测能力，而追求高召回、低误报、低延迟。

推荐架构：超表面处在成像链路中，输出缺陷敏感特征，而不是替代整个 AI 模型。

2.1 三个任务层级

层级	输出	电子后端	适用阶段	优缺点
A. OK/NG 二分类	整图是否有缺陷	global pooling + linear/MLP	最小可行验证	最稳，但缺少定位能力，顶刊说服力较弱。
B. 缺陷 heatmap	像素/patch 级缺陷概率图	1x1 conv + sigmoid + 连通域	推荐主线	与超表面卷积匹配好，可展示缺陷位置和误报控制。
C. ROI + 精检	可疑区域 proposal	tiny YOLO/小 CNN 精检	系统增强版	最贴近在线高分辨率检测，可减少整图推理。

2.2 为什么不建议“完整 YOLO 塞进超表面”

YOLO/FCOS/DETR 类目标检测器包含多层卷积、非线性激活、归一化、多尺度特征金字塔、检测头、bbox 回归和后处理。超表面虽然有大量 meta-atoms，但这些自由度不是任意数字神经网络参数；它们共同形成受 Maxwell 方程、NA、效率、串扰和制程约束的线性或弱非线性光学映射。因此更合理的说法是“超表面实现一个 optical stem / optical encoder”，而不是完整 detector。

以 YOLO11 为例，YOLO11n 在 640 输入下也有约 2.6M 参数和 6.5B FLOPs；YOLO11s 约 9.4M 参数和 21.5B FLOPs [12]。本项目应把要光学实现的规模压缩到 8-32 个大核/任务核，例如 16 个 31x31 kernel 约 1.5 万等效权重，后端只保留几千到几万参数的 tiny head。

3. 推荐数据集与应用场景选择

第一阶段建议不要一开始自建大数据集。更稳的方式是用公开工业缺陷数据集训练和验证算法闭环，再用自采芯片/晶圆/PCB/金属样品完成最终光学验证。公开数据集负责证明方法不是玩具任务；自采数据负责证明成像链路和超表面器件真实有效。

数据集	规模/标注	场景特点	本项目用途
VisA	10,821 张高分辨率图；12 类；9,621 正常、1,200 异常；图像级与像素级标注。	包含 4 个 PCB 子集，结构复杂，比较贴近电子制造。	优先推荐；可做 PCB/芯片视觉前端仿真、异常分割和蒸馏。
DeepPCB	1,500 对 template/test PCB 图像，640x640，6 类缺陷。	天然是板级模板对比检测，open/short/pinhole/spur 等。	适合目标检测或差分检测；可作为 ROI/box 任务验证。
MVTec AD	超过 5,000 张高分辨率图；15 类物体/纹理；像素级 anomaly mask。	经典工业 anomaly benchmark，方法已较饱和。	作为基础 benchmark 和异常检测对照。
MVTec AD 2	8,004 张高分辨率图；8 类高级场景；包含透明/反光/暗场/背光/极小缺陷。	更接近真实工业难度，支持照明分布漂移测试。	作为挑战组；可验证光学前端对照照明/微缺陷的鲁棒性。
KolektorSDD2	3,000+ 图；356 张有缺陷、2,979 张无缺陷；约 230x630。	真实工业表面缺陷，划痕、斑点、表面瑕疵。	适合 OK/NG 二分类和 heatmap 主线。
NEU/GC10-DET	NEU: 1,800 张钢带缺陷；GC10-DET: 10 类金属表面 bbox。	钢材/金属表面，多类缺陷，分辨率和场景复杂度有限。	作为多类别缺陷检测补充。

3.1 推荐选择

推荐主数据集组合：VisA PCB 子集 + DeepPCB + KolektorSDD2。VisA 用于复杂电子元件/PCB 异常分割；DeepPCB 用于标准 PCB defect detection；KolektorSDD2 用于真实工业表面 OK/NG 和 heatmap。MVTec AD 2 作为挑战数据集，放到第二阶段用于证明方法在反光、暗场、背光和极小缺陷下的鲁棒性。

最终实验仍建议自采一批芯片/PCB/晶圆或金属片样品。原因是公开数据集通常已经是数字相机图像，无法完整体现超表面成像链路的光照、反射、散射、NA、像差、sensor noise 和通道串扰。

4. AI 模型选择：YOLO 可以做 teacher，但不必成为 student

本项目不应被 YOLO 框住。YOLO 适合 bounding box 检测，但工业缺陷往往更自然地表现为像素级异常、热力图或缺陷区域。对超表面而言，线性光学前端输出 defect saliency map 比输出完整 YOLO 多尺度检测结果更匹配。


模型	适合任务	作为 teacher 的价值	作为最终后端的建议
U-Net / U-Net++	缺陷 mask、heatmap、分割	可生成 soft mask/feature，适合蒸馏到 heatmap student。	优先推荐 teacher；student 不必复制 U-Net。
YOLOv8/YOLO11	bbox 检测、小目标/多类别缺陷	可提供 objectness、bbox 和早期 feature maps。	可作为 ROI 精检后端；不建议声称光学实现完整 YOLO。
EfficientAD	工业异常检测与定位，低延迟	student-teacher 思路天然适合蒸馏，强调实时性。	可作为 anomaly teacher 或数字 baseline。
PatchCore/PaDiM	只用正常样本的异常检测	可产生异常分数图，适合少缺陷样本场景。	适合作为无监督 baseline，不适合完全搬到光学端。
自建小模型	固定产线、少类别、二分类/heatmap	可针对数据集简化并便于映射到光学 student。	推荐作为最终 student 结构。

4.1 推荐 student 结构

主线 student 建议如下：输入图像经过受物理约束的 OpticalConvBank，产生 N=8/16/32 个 feature maps；电子端只做 1x1 通道混合、可选 depthwise 3x3、sigmoid heatmap 或 global pooling + linear 分类。若任务需要 bbox，可由 heatmap 连通域产生候选区域，再交给 tiny detector 精检。

蒸馏损失可写为： $L = L_{task} + \alpha L_{distill} + \beta L_{physics}$ 。L_task 可以是 BCE、Dice、Focal、box loss；L_distill 可以匹配 teacher 的 soft mask、objectness map、中间浅层 feature 或 logits；L_physics 约束 PSF/OTF 可实现性、正负权重差分、通道串扰、相位量化、光效率、探测器噪声和对准误差。

图 2 训练范式：用电子 teacher 蒸馏一个物理受限的 optical student



训练不要求 student 与 teacher 同构；teacher 负责提供强监督，student 只保留可物理实现的光学编码器与极小电子头。

5. 超表面光学前端设计边界

5.1 可选光学架构

方案 A：4f Fourier-plane metasurface。样品经 L1 到 Fourier 面，超表面实现空间频率传递函数 $H_i(k_x, k_y)$ ，再经 L2 成像到传感器。这种结构利于实现频域滤波、尺度选择、方向选择和背景/周期纹理抑制，适合实验原型和 SLM 先验验证。

方案 B：PSF-engineered meta-imager。通过超表面直接塑造成像系统的 PSF h_i ，使传感器输出 $x * h_i$ 。优点是紧凑，更接近最终相机前端；难点是多通道、视场、像差和正负权重读出。

方案 C：复用型多通道输出。通道可以通过空间复用、偏振复用、波长复用或角度复用实现。第一代样机建议空间复用或偏振复用，因为设计和读出相对直接；后续可扩展到更高通道数或更紧凑封装。

5.2 正负权重与多通道

光强非负约束会限制 signed convolution。常见处理是差分通道：每个 kernel 分解为正权重和负权重两路，传感器读出后做 $y = y_+ - y_-$ ；也可以用偏振/空间区域承载正负响应。工业检测中不必追求精确还原任意卷积核，关键是任务性能和鲁棒性，因此可在训练时直接加入非负、差分和串扰模型，让网络适应真实光学读出。

5.3 参数量和器件尺寸的正确理解

1 mm x 1 mm 的可见/近红外超表面在 300-700 nm 周期下可以包含百万级 meta-atoms，但这不等价于百万个独立神经网络权重。meta-atoms 共同形成一个受物理约束的波前变换；真正可控的是可实现的 PSF/OTF、复振幅/偏振响应和多通道输出。

因此，本项目不要试图装下 YOLO 的百万参数，而应设计一个 $1e4$ - $1e5$ 等效自由度的光学前端。例如 16 个 31x31 kernel 约 15,376 个等效权重；16 个 63x63 kernel 约 63,504 个等效权重。对固定工业场景，这个规模已经可能覆盖低级缺陷显著性、方向/尺度选择、背景抑制和粗定位。

模块	建议规模	物理实现关注点
通道数 N	先做 8 或 16；仿真可扩至 32。	通道独立性、串扰、读出布局、SNR。
核大小	15x15/31x31 起步；复杂背景可试 63x63。	NA、视场、PSF 尺寸、边界效应。
输出方式	feature maps 或 defect saliency map。	与 CMOS 像素匹配；是否需要差分读出。
后端	1x1 conv/MLP/heatmap head/tiny detector。	保留少量非线性，避免全线性表达不足。

6. 实验设计与对照组

实验需要证明三件事：第一，蒸馏后的 optical student 在工业检测任务上确实有效；第二，这个 student 的前端可以用光学/超表面近似实现；第三，相比纯数字轻量模型，超表面前端带来速度、读出、算力或鲁棒性收益。

6.1 分阶段实验

阶段	实验内容	成功判据
数字仿真	在 VisA/DeepPCB/KolektorSDD2 上训练 teacher，再蒸馏到物理约束 OpticalConvBank + tiny head。	8-16 通道 student 接近 teacher；明显优于手工滤波和同等小模型。
物理约束增强	加入 PSF/OTF 限制、正负差分、通道串扰、相位/振幅量化、探测器噪声和对准扰动。	性能下降可控；能估计所需通道数、SNR 和光效率。
SLM/4f 验证	用 SLM 或可编程光学滤波器实现 learned kernels，采集真实/投影样品图像。	光学 feature maps 与数字仿真相近，检测指标接近 C 组对照。
超表面器件	制备 4/8/16 通道 metasurface 前端，完成芯片/PCB/晶圆样品检测演示。	证明样机闭环：光学前端 + tiny head 输出 heatmap/OK-NG。
系统指标	测量或估算吞吐、延迟、电子 MACs、传感器读出量、能耗和误报率。	在相近检测性能下，电子后端显著变小或读取区域显著减少。

6.2 必要对照组

- A. 原始图像 + 强 teacher：U-Net/YOLO/EfficientAD/PatchCore，给出上限。
- B. 原始图像 + tiny head：证明小模型单独不够。
- C. 数字实现同样 OpticalConvBank + tiny head：证明蒸馏后的光学编码器有效。
- D. 光学/超表面实现 OpticalConvBank + tiny head：证明物理实现接近数字设计。
- E. 手工 Sobel/Gabor/LoG/高通 + tiny head：证明不是传统滤波器简单替代。

6.3 评价指标

任务	核心指标	补充指标
OK/NG 二分类	AUROC、AUPR、FPR@95%TPR、召回率、误报率。	参数量、MACs、吞吐、低照/照明漂移鲁棒性。
缺陷定位/分割	pixel AUROC、PRO、Dice、IoU、miss rate。	小缺陷召回率、缺陷面积分组性能、连通域定位误差。
bbox 检测/ROI	mAP50/mAP50-95、Recall、false alarms per image。	ROI 减少比例、后端裁剪数、整图推理时间。
系统	电子 MACs、读出像素数、端到端 latency。	光效率、SNR、通道串扰、温漂/对准容忍度。

7. 与 PHOENIX、YOLO 和传统工业检测的差异

PHOENIX 的贡献是通用光电混合目标检测部署框架：它在图像已采集之后，把 detector backbone 的中后段部分 stage 替换成 ONN，并用特征/目标级蒸馏恢复检测性能 [6]。本项目不应复刻这一路线，也不应把题目写成 optical YOLO。

本项目应强调 “sensor-side metasurface feature extraction”：光在到达普通数字图像之前已经经过任务学习的超表面编码，传感器直接记录缺陷敏感 feature maps。这是成像过程的改变，而不仅仅是神经网络中间层计算加速。

维度	PHOENIX/通用 ONN 检测	本项目建议定位
任务	COCO 等通用目标检测，自然场景，多类别。	芯片/PCB/晶圆/金属表面，固定视场，小缺陷，少类别。
光学位置	图像采集后，替换网络 backbone stage。	成像链路中，传感器前生成缺陷特征图。
硬件形态	DONN/ONN module，多层光学计算。	metasurface image processor / optical convolutional encoder。
输出	bbox/logits，检测头仍然电子。	OK-NG、heatmap、ROI proposal、可选 tiny detector。
创新叙事	通用 object detection 的光电部署。	工业检测相机的任务驱动物理前端。

7.1 可主张的创新点

- 提出工业缺陷专用的 task-distilled metasurface optical encoder，而非手工光学边缘检测。
- 将 teacher 模型的 soft mask/objectness/feature 蒸馏到可实现的线性光学卷积/频域滤波前端。
- 在 VisA/DeepPCB/KolektorSDD2/MVTec AD 2 等真实工业数据上验证二分类、heatmap 和 ROI 三层任务。
- 给出物理误差感知训练：正负差分、通道串扰、相位量化、光效率、探测噪声、对准误差。
- 展示系统级价值：减少电子 MACs、读出数据量、ROI 数量或提升小缺陷召回/低误报。

7.2 文章题目建议

- Task-distilled metasurface optical encoder for high-speed industrial defect inspection
- Task-driven metasurface image formation for defect-sensitive machine vision
- Metasurface convolutional sensing for lightweight chip defect detection
- YOLO-guided metasurface optical front-end for chip/PCB defect inspection（如果保留 YOLO，只作为 teacher/guide）

8. 风险、规避策略与里程碑

风险	具体表现	规避策略
线性 student 能力不足	8/16 个光学通道无法接近 teacher，缺陷定位不稳定。	先做固定场景；增加通道数/核大小；保留少量电子非线性；用 heatmap 而非复杂 bbox。
物理可实现性差	训练出的 kernel 不能被 PSF/OTF 或超表面高效实现。	从训练开始加入物理参数化；限制非负/差分/带宽/NA；fabrication-aware training。
公开数据集 domain gap	开源数据是普通数字图像，不能代表真实光路。	公开数据做算法验证，自采样品做最终演示；加入照明、噪声、模糊、反射增强模拟。
正负权重和通道串扰	差分通道读出误差导致特征漂移。	用 paired channel 训练；标定矩阵反演；后端 fine-tuning 补偿。
顶刊叙事不够物理	被认为只是 AI 应用或数字卷积换皮。	突出 image formation 改变、光学读出/吞吐优势、真实器件和系统指标。

图 4 18 个月推进路线：先证明算法闭环，再做光学验证，最后做器件样机



建议先用仿真证明“值得做器件”，再进入可编程光学验证和超表面样机。

8.1 18 个月目标版本

第 1 个里程碑是纯数字 closed-loop: teacher > optical student > tiny head，在至少两个开源工业数据集上跑通并完成对照。
第 2 个里程碑是物理约束闭环：把可实现性、噪声、串扰、效率纳入训练，确定通道数和 kernel 尺寸。第 3 个里程碑是 4f/SLM 验证：证明 learned optical filters 在真实光路里确实能提升缺陷 saliency。第 4 个里程碑是超表面器件：做 4/8/16 通道样机并完成自采样品检测。

9. 参考文献与调研来源

- [1] Fu et al., “Ultracompact meta-imagers for arbitrary all-optical convolution,” *Light: Science & Applications*, 2022. <https://www.nature.com/articles/s41377-022-00752-5>
- [2] Zheng et al., “Multichannel meta-imagers for accelerating machine vision,” *Nature Nanotechnology*, 2024. <https://www.nature.com/articles/s41565-023-01557-2>
- [3] Liang et al., “Metasurface-Generated Large and Arbitrary Analog Convolution Kernels for Accelerated Machine Vision,” *ACS Photonics*, 2024. <https://pubs.acs.org/doi/10.1021/acsphotonics.4c01874>
- [4] Xiang et al., “Knowledge Distillation Circumvents Nonlinearity for Optical Convolutional Neural Networks,” *Applied Optics / arXiv*, 2021/2022. <https://arxiv.org/abs/2102.13323>
- [5] Wirth-Singh et al., “Compressed Meta-Optical Encoder for Image Classification,” *CLEO/arXiv*, 2024. <https://arxiv.org/abs/2406.06534>
- [6] PHOENIX, “Photonic Distillation Transfers Electronic Knowledge to Hybrid Optical Neural Networks,” *OpenReview ICLR 2026 submission*, 2025/2026. <https://openreview.net/forum?id=J36Tagukno>
- [7] MVTec AD Dataset. <https://www.mvtec.com/research-teaching/datasets/mvtec-ad>
- [8] MVTec AD 2 Dataset, *IJCV 2026 / arXiv 2025*. <https://link.springer.com/article/10.1007/s11263-026-02743-0>
- [9] VisA Dataset / SPot-the-Difference, *Amazon Science / AWS Open Data*, 2022. <https://registry.opendata.aws/visa/> ; <https://github.com/amazon-science/spot-diff>
- [10] KolektorSDD2, “Mixed supervision for surface-defect detection,” 2021. <https://arxiv.org/abs/2104.06064>
- [11] Cai et al., “High-speed wafer surface defect detection with edge enhancement via optical spatial filtering in serial time-encoded imaging,” *Optics & Laser Technology*, 2025. <https://doi.org/10.1016/j.optlastec.2024.111442>
- [12] Ultralytics YOLO11 model table, 2024/2025. <https://huggingface.co/Ultralytics/YOLO11>
- [13] EfficientAD, “Accurate Visual Anomaly Detection at Millisecond-Level Latencies,” 2023. <https://arxiv.org/abs/2303.14535>
- [14] PatchCore, “Towards Total Recall in Industrial Anomaly Detection,” 2021. <https://arxiv.org/abs/2106.08265>
- [15] DeepPCB dataset summary and paper sources. <https://www.emergentmind.com/topics/deeppcb-dataset>
- [16] GC10-DET dataset summary. <https://datasetninja.com/gc10-det>

10. 建议下一步

建议下一步先不讨论器件版图，而是做一个最小数字仿真包：选择 VisA PCB + KolektorSDD2，训练 U-Net/EfficientAD teacher，搭建 8/16 通道 OpticalConvBank + heatmap head，跑出 A-E 对照组。只要这一步显示 optical student 在性能/复杂度上有明显优势，再细化超表面 PSF/OTF 设计、通道复用和样机光路。