

基于神经切线的知识蒸馏技术在光学卷积网络中的应用

金林翔^{*} 陈敏浩^{*†} 张宇波[‡] 周志浩[‡] 阿尔卡·马朱姆达尔^{§||}

埃利·施利泽曼^{†||}

摘要

混合光学神经网络（ONNs，通常由光学前端和数字后端组成）为实时运行且受功耗限制的系统提供了比全数字深度神经网络更节能的替代方案。然而，其应用受到**两大主要挑战**的制约：训练过程中与大规模网络相比的精度差距，以及模拟系统与实际制造系统之间的差异会进一步降低精度。尽管先前研究针对特定数据集（如 MNIST）和光学系统提出了端到端优化方案，但这些方法通常缺乏跨任务和硬件设计的泛化能力。为解决这些局限性，我们提出了一种与任务和硬件无关的流程，可在多种光学系统上支持图像分类和分割任务。为辅助训练前的光学系统设计，我们根据制造限制设计了超表面布局。在训练阶段，我们引入了神经切线知识蒸馏（NTKD）技术，该技术通过将光学模型与电子教师网络对齐，有效缩小了精度差距。器件制造完成后，NTKD 还能指导数字后端的微调，以补偿实现过程中的误差。在多个数据集（如 MNIST、CIFAR、Carvana 图像掩膜数据集）和不同硬件配置上的实验表明，我们的流程能持续提升 ONN 性能，并可在预制仿真和实际物理实现中实现高效部署。

1 引言

与卷积神经网络（CNN）和视觉变换器（ViT）等数字实现方式相比，光学神经网络（ONNs）在实现高效计算和节能方面展现出显著优势，因此特别适用于资源受限的实时物理系统[1]。例如，已有研究提出将ONNs应用于功耗受限的应用场景（如图1所示）。a），包括卫星[2]、无人机[3]、智能家居设备[4]、自动驾驶系统[5]、可穿戴电子设备[6]以及医疗设备[7]。

在不同的 ONN 实现方案中，混合光电子架构在当前硬件限制条件下是切实可行的选择[8]。此类系统中，光学前端以光速加速计算，而数字后端则对预测结果进行优化以提升鲁棒性[9]。

^{*}这些作者对本研究的贡献相同。

[†]华盛顿大学应用数学系，美国华盛顿州西雅图市，邮编 98195。

[‡]华盛顿大学电气与计算机工程系，美国华盛顿州西雅图市，邮编 98195。

[§]华盛顿大学物理系，美国华盛顿州西雅图市，邮编 98195。

^{||}电气工程系，蔚山国立科学技术研究院，韩国蔚山 44919

^{||}通讯作者：arka@uw.edu, shlizem@uw.edu




图1：ONNs的潜在应用概述及我们提出的部署流程。(a)ONNs在电力受限场景下的实时决策应用。(b)我们提出的流程包括用户驱动的设计、知识迁移训练、器件制造及误差补偿。

光学前端通常由单一线性层构成（如图1.a所示），原因如下：(1) 由于材料和器件的限制，在物理光学中实现非线性激活函数仍极具挑战性；(2) 若不引入非线性特性，多个线性变换在数学上可被压缩为单一线性变换。此外，从理论角度来看，浅层网络仍能满足通用近似特性，这表明经过适当优化的混合ONNs在广泛任务中仍具备足够的表达能力[10–12]。

尽管ONNs具有这些优势，但由于**架构限制**和**制造相关挑战**，它们仍然难以设计和训练。首先，现有的 ONN 架构通常比现代深度卷积神经网络（CNN）或视觉Transformer（ViT）简单得多。这些简化效果无法通过剪枝或量化技术直接实现[13–15]。其次，物理制造和实验部署过程中不可避免地会产生多种噪声源，例如光学对准偏差、材料差异性和测量噪声，这些都会进一步降低性能[16]。尽管已有若干端到端优化策略被提出以应对这些挑战，但它们通常针对特定数据集（如 MNIST）和特定光学系统设计，而非提供通用解决方案（相关工作综述亦有提及）。相比之下，我们的目标是开发一种任务无关且硬件无关的流程，能够跨不同数据集和光学硬件配置实现泛化应用。

为应对这些挑战，知识迁移——尤其是知识蒸馏（KD）——提供了一种有前景的解决方案：它能够将预训练数字网络中的知识迁移至光学模型[17, 18]。此外，近期研究表明，成功的KD方法会隐式地提升师生神经切线核（NTK）相似度——其中 NTK 能够捕捉网络预测值随参数微小变化所产生的变化规律[19]。本文证明，利用 NTK 进行匹配对光学神经网络（ONNs）尤为有效，因为 NTK 能对网络行为进行线性近似，这与光学系统执行的线性运算机制高度契合。

因此，我们提出了一种神经切线知识蒸馏（NTKD）流程，该流程能够适应不同的光网络设计和数据集，支持分类、分割等多种任务（详见图1.b）。该流程首先需明确任务目标、数据集及光网络结构；随后，NTKD 优化机制通过匹配数字教师模型与混合ONN的NTKs，将知识从数字模型传递至混合ONN，从而有效实现类别间关系结构的迁移，而不仅仅是预测结果的一致性匹配。此外，该流程通过利用一小部分（例如10%）真实实验数据对学生的NTKs和教师的NTKs进行对齐，从而补偿在制造和实验部署过程中引入的误差。

总之，我们的贡献如下：

- 我们提出了一种神经切线知识蒸馏（NTKD）流程，该流程能够支持多种任务和光学结构，有效解决了浅层架构及物理缺陷带来的挑战。
- 我们通过在分类和分割任务中采用不同的 ONN 实现方案，对流程进行了实验验证，并通过仿真和实际构建案例证明了其有效性。

表1：按任务类型（分类、分割）和实现层级分类的先前 ONN 研究成果汇总——分为仅包含模拟的部分（标记为**Sim**）以及包含物理制造与实验验证的部分（标记为**Fab**）。

ONN 能力	工厂	分类 (同时)	分类 (极好的)	分割 (同时)	分割 (极好的)
单色的	2018–2025: [9, 16, 20–27, 30–38]	✓	✓	✗	✗
多色的	2023–2025: [16, 28, 29, 39, 40]	✓	✓	✗	✗
	ExtremeMETA (2025) [5]	✗	✗	✓	✗
	我们的 (NTKD)	✓	✓	✓	✓

- 我们运用 NTK 分析来评估特定混合 ONNs 可达到的精度，从而为其设计与优化提供理论指导。

2 相关作品

ONN 任务与实现：表1将 ONN 应用分为两类任务（分类与分割）及两种光学实现方式（单色与多色系统）。以往大多数研究都专注于用于 MNIST 图像分类的单色光学神经网络（ONN），包括执行线性变换的全光学系统[20, 21]、利用原子蒸气或增强器的物理非线性 ONN[22–24]，以及结合光学前端与数字后端的混合架构[25–27]。此前用于分类的多色 ONN 仅适用于 CIFAR-10 等小型数据集，因为 ONN 架构在扩展至复杂基准测试时面临挑战[28, 29]。分割任务仍处于早期阶段，已有研究仅基于模拟实验[5]。我们的工作同时涵盖分类与分割任务。在我们的流程中，通过促使光学前端输出与模拟结果对齐，隐式地实现了图像重建——因为物理输出会偏离模拟结果而需要修正。

ONNs 的迁移学习：迁移学习，尤其是知识蒸馏（KD），为将预训练数字网络的知识迁移至光学模型提供了有前景的解决方案[17, 41]。KD 能最小化紧凑型学生模型与预训练教师模型预测结果之间的差异，从而促使学生主动模仿教师的行为[17, 42]。除传统 KD 外，近期研究还提出了基于 NTK 的方法来理解知识迁移[43]。例如，通过 NTK 分析已建立了关于宽网络中 KD 迁移风险与数据效率的理论见解[44]；后续研究表明，成功的知识蒸馏会隐式实现学生-教师 NTK 对齐[19]，而 NTK 相似性进一步被应用于量化多任务学习中的任务亲和性[45–47]。相比之下，我们的研究聚焦于物理约束下的光学神经网络（ONNs），并提出了一种显式的 NTK 匹配策略，可直接引导从数字教师到光学学生的知识蒸馏过程。

实际光学神经网络的补偿策略：物理光学神经网络中的制造缺陷和系统噪声通常会导致其性能较仿真结果显著下降。部分方法采用深度学习以数据驱动的方式直接建模系统[48]，包括 ONN 自学习[49, 50]——通过训练光学神经网络来拟合实验输入-输出映射关系；其他方法则通过硬件环路训练引入物理信息，例如基于物理约束的框架将考虑制造特性的模型和损失函数纳入其中，以更好地使学习过程与光学行为一致[16]。此外，某些方法完全避免仿真，通过随机制造光学核并训练数字后端来适应固定的前端结构[51–55]。这种简化了制造流程，但将全部学习负担转嫁给了后端。目前尚不清楚这类随机表面是否比普通透镜表现更优。相比之下，我们的研究明确了物理误差的来源，并提出了一种 NTK 对准策略以实现有效补偿。

3 方法

3.1 光学前端设计

在管道初始化阶段，需要用户输入参数来定义光学系统（如图2.1所示）。具体而言，用户需指定：(1) 光学前端的物理尺寸（例如，




图2：流程概览。该流程包含三个步骤：(1)基于用户指定输入的光学前端设计；(2)采用神经切线核（NTK）匹配技术进行知识迁移训练；(3)对制造完成的光学前端进行误差补偿。

(1)元光学核的数量），(2)任务的目标数据集，以及(3)所需的网络结构（例如层数和通道数）。先前的研究表明，光学卷积可以通过4f系统或基于PSF的自由空间传播系统实现[18, 30, 38, 56]。在本工作中，我们实际实现了基于PSF的元表面设计，因其具有紧凑性、对准鲁棒性及易于制造等优势[29, 30]。

光学前端布局：我们考虑一个尺寸为 (h, w) 的超表面，在其上放置 n_{kerels} 个方形光学核，每个核的尺寸为 k （单位：毫米），且各核之间的最小边缘间距为 d ，以满足制造工艺要求。为计算在保持对称性条件下可放置的最大内核数量，我们定义如下：

$$n_{\text{cols}} = \left\lfloor \frac{w - d}{k + d} \right\rfloor, \quad n_{\text{rows}} = \left\lfloor \frac{h - d}{k + d} \right\rfloor, \quad n_{\text{kerels}} = n_{\text{cols}} \times n_{\text{rows}}. \quad (1)$$

性能评估：在确定 ONN 的物理布局后，我们的目标是在无需经验性训练的情况下估算其预期性能。我们采用神经切线核（NTK）框架，该框架能够捕捉梯度下降下**无限宽度神经网络**的训练动态。具体而言，我们引入了一个参考网络，其架构与设计的 ONN 相同（例如层数和连接方式），但每一层的宽度均为无限大。在此假设下，参考网络的预测结果对应于 NTK 回归[57, 58]。设参考网络 $f(x; \theta)$ 是由 θ 参数化的神经网络，它将输入 x 映射为输出 $f(x; \theta)$ 。NTK 定义为：

$$\Theta(x, x') = \nabla_{\theta} f(x; \theta)^{\top} \nabla_{\theta} f(x'; \theta), \quad (2)$$

其中 $\nabla_{\theta} f(x; \theta)$ 表示网络输出相对于其参数的雅可比矩阵。令 $\{x_{\text{train}}^i, y_{\text{train}}^i\}_{i=1}^{n_{\text{train}}}$ 作为训练数据，以及 $\{x_{\text{test}}^i\}_{i=1}^{n_{\text{test}}}$ 为测试数据。我们计算如下：

$$\mathbf{b}_{\text{训练集}} = \mathbf{b}_{\text{train}} = \mathbf{b}_{\text{train}}^{\text{train}}, \quad \mathbf{R}_{\text{训练集}} = \mathbf{R}_{\text{train}}^{\text{train}} \times n_{\text{train}}, \quad \mathbf{b}_{\text{测试集}} = \mathbf{b}_{\text{test}} = \mathbf{b}_{\text{test}}^{\text{test}}, \quad \mathbf{R}_{\text{测试集}} = \mathbf{R}_{\text{test}}^{\text{test}} \times n_{\text{train}}. \quad (3)$$

并使用核回归方法对测试集上的输出进行预测

$$f(x_{\text{测试}}; \theta) = \mathbf{b}_{\text{测试集}}^{\text{test}} (\mathbf{b}_{\text{训练集}}^{\text{train}} + \mathbf{A} \mathbf{I})^{-1} \mathbf{y}_{\text{训练集}}^{\text{train}}, \quad (4)$$

其中 $\mathbf{A}$ 为正则化参数，通过在验证集上进行网格搜索确定。基于 NTK 的性能评估可作为诊断工具，用于判断指定的 ONN 架构是否足以满足特定任务的需求。尽管该评估不用于训练或损失计算，但它能提供早期反馈以指导架构设计决策，并允许用户在正式训练和制造前逐步优化光学设计。例如，若估算的测试准确率远低于预期性能，则可能表明 ONN 的容量（如深度）与任务复杂度之间存在不匹配。

3.2 知识转移培训

在用户指定 ONN 架构后，我们针对目标任务对系统进行训练。我们定义了一个监督学习问题，其输入为输入-输出对 (x, y) ，其中 x 表示输入样本， y 表示相应的真实标签。网络参数 θ ，包括光学前端和数字后端，均被初始化并联合优化（如图2.2所示）。

端到端损失：我们考虑的第一个损失项是标准的端到端监督损失，该损失直接最小化网络预测结果与真实标签之间的差异。具体而言，我们优化以下目标函数：

$$\mathcal{L}_{\text{E2E}} = \mathbb{E}_{(x,y) \sim \mathcal{D}} [\ell(f_{\text{ONN}}(x; \theta), y)], \quad (5)$$

其中 $\ell(\cdot, \cdot)$ 是标准损失函数（例如分类任务中的交叉熵）， $f_{\text{ONN}}(x; \theta)$ 表示参数为 θ 的网络输出， $\mathcal{D}$ 代表训练数据集。

神经切线知识蒸馏（NTKD）损失：除了标准的端到端损失外，我们还引入了一种基于神经切线核（NTK）的知识迁移损失。具体而言，我们假设可以使用预训练的教师网络，例如用于 MNIST 的 LeNet、用于 CIFAR-10 的 AlexNet，或用于图像分割任务的 U-Net。

给定一个输入样本的小批量集合 $\{x_i\}_{i=1}^{n_{\text{batch}}}$ ，我们分别计算了教师网络（ f_{teacher} ）和学生 ONN（ f_{ONN} ）相对于其参数 θ_{teacher} 、 θ_{ONN} 的雅可比矩阵。

$$J_{\text{teacher}} = \left[\frac{\partial f_{\text{teacher}}(x_i)}{\partial \theta_{\text{teacher}}} \right]_{i=1}^{n_{\text{batch}}}, \quad J_{\text{ONN}} = \left[\frac{\partial f_{\text{ONN}}(x_i)}{\partial \theta_{\text{ONN}}} \right]_{i=1}^{n_{\text{batch}}}. \quad (6)$$

雅可比矩阵 $J_{\text{teacher}} \in \mathbb{R}^{n_{\text{batch}} \times p_{\text{teacher}} \times n_{\text{class}}}$ 与 $J_{\text{ONN}} \in \mathbb{R}^{n_{\text{batch}} \times p_{\text{ONN}} \times n_{\text{class}}}$ 的宽度可能因各网络中可训练参数的数量而异。此处， p_{teacher} 和 p_{ONN} 分别表示教师模型和 ONN 模型中的参数数量；它们对应的 NTK 矩阵如下：

$$\mathbf{b}_{\text{教师}} = J_{\text{teacher}} J_{\text{teacher}}^\top, \quad \mathbf{b}_{\text{ONN}} = J_{\text{ONN}} J_{\text{ONN}}^\top, \quad (7)$$

两者的尺寸均为 $n_{\text{batch}} \times n_{\text{batch}}$ 。我们通过最小化教师网络与 ONN（例如 MSE）的 NTK 矩阵之间的差异来定义 NTKD 损失。

$$\mathcal{L}_{\text{NTKD}} = \mathbb{E}_{\{x_i\}_{i=1}^{n_{\text{batch}}} \sim \mathcal{D}} [\ell(\Theta_{\text{teacher}}, \Theta_{\text{ONN}})]. \quad (8)$$

随后，我们最小化两个损失函数的加权和，该过程由超参数 α 和 β 控制。

$$\min_{\theta} (\alpha \mathcal{L}_{\text{E2E}} + \beta \mathcal{L}_{\text{NTKD}}). \quad (9)$$

3.3 错误补偿

物理制造过程采用了通过第3.2节所述流程获得的优化仿真参数。该制造过程固定了光学前端，仅数字后端仍可调节。由于不可避免的制造误差和实验误差，设计的光学系统与实际实现的系统之间会产生差异。给定输入图像 a 和卷积核 k ，理想输出应为 $y = a \otimes k$ 。在位置 (i, j) 处带有噪声的合成光学卷积输出为：

$$\tilde{y}_{i,j} = \alpha \beta \sum_{m=1}^{k_{\text{size}}} \sum_{n=1}^{k_{\text{size}}} a_{i+m-1, j+n-1} (k_{m,n} + \delta_{m,n}) + \epsilon_{i,j}. \quad (10)$$

在此，缩放因子 α （图像亮度）和 β （图像与核函数的错位）可通过实验校准以匹配所设计的系统，而传感器噪声 ϵ 主要由成像设备特性决定。我们进一步量化了制造噪声 δ 的影响（相关证明详见补充材料）。具体而言，我们证明由核函数制造误差引起的 NTK 扰动（ δ_{ij} ）具有如下标度关系：

$$\|\Delta \Theta_{\text{ONN}}\| \sim O\left(\frac{\|\delta\|}{m}\right), \quad (11)$$

其中 $\Delta \epsilon_{\text{ONN}}$ 表示 NTK 扰动， m 为核的数量（即网络宽度）。该结果表明：具有更多核的网络在制造过程中本质上更具鲁棒性。




图3：光学系统。(a)基于 MNIST 的压缩Meta ONN [37]；(b)基于 CIFAR -10的多色Meta ONN [29]；(c)采用双光学前端进行分割的极端META[5]；(d)定制化的多色Meta ONN 用于分割（本研究）；(e)光学测量装置；(f)经PSF工程设计的制造型元光学器件；(g)元光学器件的扫描电子显微镜图像。

表2：教师与学生网络详情。

学生建筑	教师模型	教师准确性	教师大小
压缩元数据（0.05MB）	LeNet	99.1%	~0.18M
多色元数据（1.62MB）	亚历克斯·奈特	85.4%	233.29M
多色元数据（1.06M）	U-Net	95.4%	196.97M

噪声。事实上，如果 $m \rightarrow \infty$ ，制造噪声对预测的影响可忽略不计。若将 γ 解释为梯度下降步骤，则等式11与 NTK 理论一致：当 $m \rightarrow \infty$ 时，NTK (Θ) 在训练过程中保持恒定，这意味着 $\Delta \Theta \rightarrow 0$ [57]。

为纠正这些错误，我们再次在等式中应用最小化方法。9，但将优化限制在未冻结的后端参数上（如图2.3所示）。教师网络接收原始输入图像，并根据等式7的定义，对一批样本计算其 NTK 矩阵。学生网络接收来自固定光学前端的特征图，该前端处理相同的输入图像批次，并生成大小为 $n_{\text{batch}} \times n_{\text{batch}}$ 的 NTK 矩阵。

4 结果

4.1 实施细节、预训练模型、数据集及评估指标

实现细节：图3展示了实验中使用的四种不同光学系统。对于单色图像分类，我们在Compressed Meta ONN 架构[37]上使用 MNIST 数据集[59]进行了实验。该系统包含一个具有8个内核（ 7×7 ）的单一光学前端，以及由两个全连接层组成的紧凑型数字后端。对于多色图像分类，我们在 CIFAR -10数据集[60]上评估了Polychromatic Meta ONN [29]。该模型由一个包含16个内核（ 7×7 ）的单一光学前端，以及一个由三个全连接层组成的数字后端构成。

在图像分割实验中，我们分别使用Extreme Meta ONN [5]和改进版的Polychromatic Meta ONN [29]，基于Kaggle的Carvana图像掩码数据集进行了测试。Extreme META系统包含两个并行的多色光学前端模块，后接由CoarseNet（用于全局特征提取）和FineNet（用于细节增强）组成的双路径数字后端，两者的输出结果融合后生成最终分割结果。我们定制的多色分割系统在Polychromatic Meta ONN 基础上进行了扩展：采用配备56个光学核（分别为8、16和32个核，用于捕捉层次化深度表征，每个核尺寸为 3×3 ）的单一光学前端模块，以及由上卷积层构成的后端模块以支持密集预测任务。为确保两系统间的公平比较，我们匹配了光学核的数量。光学实现细节详见补充材料。

在实验中，我们采用梯度下降算法对超光学系统的多色红、绿、蓝点扩散函数（PSF）进行调控。PSF的物理形状与尺寸特征如下：




图4：仿真结果：MNIST (a-d)和 CIFAR -10(e-h)中的t-SNE及混淆矩阵。

图3展示了经过工程设计的元光学系统。由于该系统采用的点扩散函数（PSF）可充当卷积核，因此在图像采集过程中光学卷积操作能够自然实现。我们的实验装置设计简洁：用经过PSF优化的元光学系统替换了传统成像镜头。这些元光学元件被精确安装并与彩色相机对准，分别通过激光指针和 OLED 显示器实现PSF的采集与卷积图像的生成。图3展示了该装置的示意图及实物照片。

通过雅可比矩阵乘积显式计算 NTK 会占用大量内存，在大规模应用中不可行。为此，我们采用了 NTK -SAP[61–63]的近似策略，该方法通过估计 NTK 的迹而非构建完整矩阵来实现计算。具体参数设置如下：MNIST 和 CIFAR -10/100任务使用批量大小128，ImageNet-100任务使用批量大小64，分割任务使用批量大小8。

预训练教师模型与数据集： MNIST 和 CIFAR -10 数据集分别包含 50,000 张训练图像和 10,000 张测试图像。Carvana 数据集最初发布于 Kaggle 的 Carvana 图像掩码挑战赛，包含 5,088 张高分辨率（ $\times 1920, 1280$ ）汽车图像。我们分别采用 LeNet（在 MNIST 上达到 99.1%的准确率）、AlexNet（在 CIFAR -10 上达到 84.5%）以及完整的 U-Net（在分割任务上达到 95.4% 的平均交并比）作为对应任务的教师模型。表2总结了这些教师模型与学生模型的架构。

评估指标： 对于分类任务，我们使用不同的随机种子对每个实验进行了五次重复实验，并报告了分类准确率的平均值和标准差（std）。对于分割任务，我们同样进行了五次独立实验，并报告了平均交并比（mIoU）及其标准差。

4.2 主要结果

仿真结果： 表3总结了不同 ONN 训练策略在分类和分割任务中的准确率。在单色分类任务中，NTKD 达到了97.3%的准确率，优于基于KD的迁移学习方法（95%）。9%）以及非迁移基准模型（91.4%）。在更具挑战性的多色分类任务中也观察到类似趋势：NTKD 模型达到75.6%，超过了KD模型（72.5%）和基准模型（56.4%）。对于分割任务，我们在Extreme Meta数据集和我们提出的Polychromatic Meta数据集上对模型进行了评估。NTKD

表3：不同任务及训练策略下 ONN 方法的性能对比。

方法	单色分类 (%)	多色分类 (%)	多色分割 (mIoU)	
	压缩元数据 (2025) [37]	《多色元》(2025) [29]	Extreme Meta (2025) [5]	多色元数据 (我们的版本)
模拟，无传输	91.4 $\pm$ 0.8%	56.4 $\pm$ 1.9%	68.3 $\pm$ 0.5%	74.3 $\pm$ 0.4%
模拟，KD	95.9 $\pm$ 0.6%	72.5 $\pm$ 2.1%	75.3 $\pm$ 0.2%	86.7 $\pm$ 0.4%
模拟，NTKD	97.3 $\pm$ 0.6%	75.6 $\pm$ 0.9%	80.1 $\pm$ 0.2%	91.5 $\pm$ 0.4%




图5：实验结果：MNIST（a-d）和 CIFAR -10（e-h）数据集上的t-SNE可视化及混淆矩阵。

两种光学系统均持续获得更高的mIoU评分，分别超越基于KD的迁移学习方法及无迁移的端到端训练方法（分别为75.3%和86.7%）。

这些结果表明，未经知识迁移的端到端训练通常会导性能欠佳。通过知识迁移（KD）或知识迁移学习（NTKD）引入知识迁移机制，可显著提升学习效率和整体分割质量。特别是在多项任务中，NTKD 方法的表现均优于KD方法，充分证明了其在引导光学神经网络表征学习方面的优势。

图4展示了基于 MNIST 和 CIFAR -10表示的知识迁移策略及其分类性能。与无迁移基线相比，这些策略提升了t分布随机邻域嵌入（t-SNE）可视化中的类别可分性，并降低了混淆矩阵中的噪声。实验表明，NTKD 迁移显著改善了聚类效果和分类准确率。**制造与补偿效果分析：**表4总结了误差补偿策略对分类和分割任务中 ONN 性能的影响。由于不可避免的制造误差和实验误差，光学前端的准确率显著下降，尤其在多色场景下更为明显。未进行补偿时，单色系统的准确率下降8.1%；而对制造误差更为敏感的多色系统在 CIFAR -10任务中准确率下降28.3%，在Carvana分割任务中mIoU指标降低41.8%。这一性能差距凸显了在多色 ONN中制造对RGB敏感的核函数相较于单色ONN更具挑战性。我们的结果表明，知识迁移方法能够有效缓解这一差距：NTKD 补偿在两种场景下均提升了准确率（单色任务达95.1%，多色任务达74.9%，图像分割任务达81.2%），其表现优于端到端深度学习补偿方法，验证了该方法在制造误差校正方面的有效性。

图5对比了不同补偿策略下 MNIST 与 CIFAR -10表征的t-SNE可视化结果及混淆矩阵。未进行补偿时（图5 a、c、e、g），两种光学系统在特征空间均出现类别重叠且分类准确率下降，主要源于制造误差和光学对准偏差。NTKD 校正后（图5 b、d、f、h）有效补偿了这些误差，显著改善了聚类结构与分类准确率，展现出跨数据集及光学系统的鲁棒性与泛化能力。

表4：在分类和分割任务中，对制造光学系统上 ONN 误差补偿方法的评估。

方法	单色分类（%） 压缩元数据（2025）[37]	多色分类（%） 《多色元》（2025）[29]	多色分割（mIoU） 多色元数据（我们的版本）
无补偿（基线）	89.2%	47.3%	49.7%
错误补偿（端到端）	93.2 ± 0.1%	70.4 ± 2.1%	62.7 ± 0.9%
错误补偿（NTKD）	95.1 ± 0.1%	74.9 ± 1.3%	81.2 ± 0.6%

表5：不同任务中随机PSF核的设计方案。

	单色分类 (%)	多色分类 (%)	多色分割 (mIoU)
8个内核	96.12%	36.73%	49.3%
500粒种子	96.81%	49.32%	64.1%
1000粒种子	97.24%	56.23%	69.9%
∞ 谷粒	97.72%	67.33%	72.1%

4.3 讨论与消融研究

光神经网络的后端复杂度：后端的复杂度对光学系统的性能至关重要，尤其在混合光数字架构中。当采用强大的数字后端时，即使光学前端引入显著噪声，也能有效消除噪声并恢复精确输出。然而，强大的后端不仅会削弱光学前端的作用，还会大幅增加功耗——这恰恰违背了在资源受限环境中采用光计算的核心初衷。在此类场景下，数字网络（如ViT或U-Net）通常比后端过于强大的混合光神经网络更为实用且高效。对于实际部署而言，我们需要仔细平衡光学系统与计算后端之间的计算负载，并在可接受的能量消耗/延迟与可接受的精度之间找到平衡点——这种平衡的具体要求取决于具体应用场景。

随机参数与设计参数：设计和训练ONNs的另一种可能方向是：在仅训练数字后端的同时，采用随机初始化的光学参数。这种方法旨在避免对光学前端进行大量仿真和硬件闭环优化的需求。我们使用单个光学卷积层和轻量级后端进行了实验——该后端由用于分类的单个全连接层或用于分割的单个上采样层组成。如表5所示，增加随机核的数量在所有任务中均能持续提升性能。例如，在多色分类任务中，准确率从36.73%（8个核）提升至56.23%（1000个核），在 NTK 区域进一步提升至67.33%，这接近于无限数量随机核的效果；同样，在多色分割任务中，mIoU值从49.3%上升至69%。根据 NTK 估计，该数值达到9%，最高可达72.1%。这些结果表明：虽然增加随机点扩散函数（PSF）的数量能提升性能，但其表现仍逊于我们的方法（该方法通过知识迁移设计了核函数）。

ONN的可扩展性：当前ONN的扩展仍面临挑战，因为大多数设计采用浅层结构，线性计算能力有限。由于物理限制（如像素尺寸受限），在ONN中实现非线性运算尤为困难。这些硬件限制使得ONN难以支持数字网络中使用的深度且功能强大的架构。我们发现，与将深度CNN简单压缩为单层 ONN 相比，使用不同核函数模拟数字网络的多层结构能获得更优性能。

表6：教师复杂度对分类与分割任务中 NTK 蒸馏性能的影响。

数据集	任务	教师	学生	教师准确性	学生准确率（使用/不使用 NTKD）
ImageNet-100	分类	ResNet-18	多色元	78.43%	46.32% / 33.45%
ImageNet-100	分类	ResNet-50	多色元	88.32%	47.86% / 33.45%
COCO-Stuff 10公里	分割	U-Net	多色元	61.89%	41.43% / 35.03%
COCO-Stuff 10公里	分割	ResU-Net	多色元	69.23%	42.73% / 35.03%

表6分析了在光学物理限制条件下，更强性能教师模型对学生网络 ONN 的影响，并通过使用ResNet变体以及ImageNet-100和COCO-Stuff 10k等更复杂数据集进行了补充实验。在分类任务中，我们同时采用ResNet-18和ResNet-50训练多色元模型学生网络。尽管两种教师模型均通过 NTK 蒸馏提升了性能，但从ResNet-18到ResNet-50的性能提升幅度有限，仅增加1.54%。类似地，在分割任务中，我们使用U-Net和ResU-Net作为教师网络，在COCO-Stuff 10k数据集上训练多色元光学模型学生网络进行二值前景-背景分割。在此任务中，前景包含所有语义对象类别，背景则由非物体区域构成。同样地，虽然更强的教师模型均带来了性能提升，但采用更复杂教师模型所带来的性能增益较为有限。

这些结果表明，性能瓶颈主要源于当前 ONN 硬件的物理建模限制，而非教师模型本身的复杂性。正如预期的那样，随着 ONN 技术的未来改进，更强的教师网络可通过 NTKD 方法实现性能提升——该方法能将优质教师的知识传递给能力更出色的学生。总之，可扩展且功能强大的光学神经网络（ONNs）的实现，最终将依赖于推动深度非线性光学计算的物理技术进步。

制造分析：多个因素可能有助于解释设计值与实测值之间的差异。首先，局部周期性近似方法通过假设散射体呈周期性排列来简化超表面光学设计，但忽略了相邻不同类型散射体之间的耦合效应，从而可能导致相位误差。其次，不可避免的制造误差也进一步加剧了观测到的差异。第三，预设计的核函数必须与传感器的像素阵列精确匹配；超表面光学元件与相机之间的任何对准偏差都可能导致测量所得核函数发生变形。关于多色核函数与单波长核函数的区别，超表面本身存在显著的色差现象——这是衍射光学技术的普遍特性。尽管我们在设计过程中对多个波长的核函数进行了联合优化以确保其性能稳定，但其实际表现仍受限于材料本身的固有特性。

MAC运算与功耗：我们以多色 ONN 为例（详见补充材料），估算了混合 ONN 的乘积累加运算（MAC）及功耗。模拟数字网络中的 MAC 运算总数约为 2.39 亿次（而完整 U-Net 需 65.9 亿次 GMAC 运算，高效 U-Net 则达到 1.37 亿次 GMAC），在集成光前端后该数值降至 6500 万次[64]。总能耗涵盖图像采集与数字计算两部分：完整 U-Net（预训练教师模型）的能耗为 2.03 J 用于计算，2.36 mJ 用于图像采集，每张图像总能耗为 **2.04 J**。紧凑型数字网络的计算能耗为 7.37 mJ，图像采集能耗为 2.36 mJ，每张图像总能耗为 **9.73 mJ**。相比之下，我们的混合 ONN 图像采集能耗为 3.82 mJ，后端处理能耗为 2.01 mJ，总能耗为 **5.83 mJ**——与模拟数字网络相比，系统级能耗降低超过 40%；与预训练的教师 U-Net 相比，能效提升超过 300 倍。

5 结论

我们提出了一套全面的 NTKD 流程，能够同时处理 ONN 设计、训练及补偿过程中的多项任务与多种光学系统。通过引入知识迁移技术（特别是基于 NTK 的知识蒸馏），我们的框架在分类与分割任务中持续提升各类光学系统的识别精度。大量实验表明，当前 ONN 的性能主要受限于现有光学架构的浅层化与线性化特性。未来在更深层、非线性光学神经网络（ONNs）方面的进展，有望缩小光学神经网络与电子神经网络之间的性能差距，从而提升其可扩展性与准确性。

致谢

本研究由美国国家科学基金会（EFRI -braid-2223495）资助，并获得 HDR 研究所“数据驱动发现的加速人工智能算法”项目（A3D3）的部分支持；同时获得美国国家科学基金会 PHY-2117997 项目资助（项目负责人：JX、ES）。部分研究工作在华盛顿大学的华盛顿纳米制造与分子分析设施完成，该设施是美国国家纳米技术协调基础设施（NNCI）站点，其运营部分由美国国家科学基金会通过 NNCI -1542101 和 NNCI -2025489 两项资助支持。作者还感谢华盛顿大学电气计算机工程系、应用数学系及物理系提供的部分支持，并对华盛顿大学 eScience 中心给予的支持表示感谢。

参考文献

- [1] 赵贵斌、李鹏飞、张志波、郭福森、黄雪婷、徐伟、王佳欣和陈建龙。迈向全自动目标识别：多类别 SAR 图像分类

- 基于轻量级视觉变换器。发表于2024年第21届 *Annual International 隐私、安全与信任会议 (PST)*，第1–6页。IEEE，2024。
- [2] 付廷昭、张建发、孙润、黄玉瑶、徐伟、杨思刚、朱志宏和陈洪伟。光学神经网络：进展与挑战。 *Light: Science & Applications*，13(1):263,2024。
 - [3] 吴英章、李文波、张杰、唐邦北、向金林、李申和郭刚。疲劳状态下的驾驶员手足协调性与全局-区域脑功能连接：基于图论与可解释人工智能的研究。 *IEEE 智能车辆汇刊*，9(2):3493–3508,2023。
 - [4] Adith Bloor, Weikai Lin, Tianrui Ma, Yu Feng, Yuhao Zhu, 与 Xuan Zhang：通过光学特征分离实现传感器内部隐私保护。收录于《2025年IEEE /CVF Winter Conference Computer Vision (WACV) </应用会议论文集》，第2357–2367页。IEEE，2025年。
 - [5] 刘全、布兰登·T·斯沃茨、伊万·克拉夫琴科、杰森·G·瓦伦丁和霍远凯。Extrememeta：基于多通道超材料成像器重构的高速轻量级图像分割模型。《*Imaging Science 与技术杂志*》，第1–10页，2025年。
 - [6] 赵柏恒、程俊伟、吴波、高鼎山、周海龙和董建基。可穿戴设备用集成光子卷积加速核心。 *光电科学*，2(12):230017–1,2023。
 - [7] Jinlin Xiang, Hillol Sarker, Bozhao Qi, Ruisu Zhang, Roger Trullo, Salvatore Badalamenti, Maria Wiekowski, Annie Kruger, Etienne Pochet, Qi Tang, 等.无约束临床试验视频中的内窥镜评分与定位.收录于2025年IEEE/ CVF 计算机视觉应用冬季会议(WACV),第4006–4015页.IEEE,2025年.
 - [8] 徐润琴、吕平、徐凡江和史一石。光学神经网络实现方法综述。 *Optics & Laser Technology*，136:106787,2021。
 - [9] Shane Colburn、Yi Chu、Eli Shilzerman 和 Arka Majumdar。卷积神经网络的光学前端。 *应用光学*，58(12):3179–3186,2019。
 - [10] 陆志远、朴焕、王飞成、胡志强和王立伟。神经网络的表现力：基于宽度的视角。载于 *NeurIPS*，2017。
 - [11] 周丁轩。深度卷积神经网络的普适性。 *应用与计算调和分析*，48(2):787–794,2020。
 - [12] 常朔保、李千晓与杨海兆。从特征提取视角对卷积神经网络的近似分析。 *应用与计算调和分析*，54:47–84,2021。
 - [13] Song Han、Jeff Pool、John Tran 和 William Dally。高效神经网络的权重与连接权重学习。《*神经信息处理系统进展*》，第28卷，2015年。
 - [14] 帕夫洛·莫尔恰诺夫、斯蒂芬·泰里、特罗·卡拉斯、蒂莫·艾拉和扬·考茨。针对资源高效推理的卷积神经网络剪枝。 *arXiv 预印本 arXiv:1611.06440*，2016年。
 - [15] 玛丽亚·谢列兹诺娃、达娜·魏茨纳、拉贾·吉雷什、吉塔·库蒂尼奥克和周洪旭。神经（切线核）坍塌。《*神经信息处理系统进展*》，36:16240–16270,2023。
 - [16] 刘艳兵、秦建伟、刘艳、xi岳、刘迅、王国清、李天宇、叶晔和李伟。物理约束型综合光学神经网络。 *神经信息处理系统进展*，37:92036–92054,2024。
 - [17] 胡新婷、唐开华、苗春燕、华先胜与张寒旺。类增量学习中数据因果效应的提炼。载于 *IEEE/ CVF 计算机视觉与模式识别会议论文集*，第3957–3966页，2021年。
 - [18] 金林·香、肖恩·科尔本、阿尔卡·马朱姆达尔和埃利·施利泽曼。知识蒸馏技术能够规避光学卷积神经网络的非线性问题。《*应用光学*》，61(9):2173–2183,2022年。
 - [19] Hrayr Harutyunyan、Ankit Singh Rawat、Aditya Krishna Menon、Seungyeon Kim 和 Sanjiv Kumar。监督复杂性及其在知识蒸馏中的作用。 *arXiv 预印本 arXiv:2301.12245*，2023。

- [20] 邢林、亚伊尔·里文森、内齐赫·T·亚迪姆齐、穆罕默德·韦利、罗毅、莫娜·贾拉希和艾多甘·奥兹坎。基于衍射深度神经网络的全光机器学习。《科学》，361(6406):1004–1008,2018。
- [21] Deniz Mengü, Yi Luo, Yair Rivenson 和 Aydogan Ozcan。衍射光学神经网络及其与电子神经网络的集成分析。《IEEE量子电子学精选专题期刊》，26(1)，2020。
- [22] 杨明伟、伊丽莎白·罗伯逊、路易莎·埃斯格拉、库尔特·布施和雅尼克·沃尔特斯。基于原子非线性的光学卷积神经网络。《Optics Express》，31(10):16451–16459,2023。
- [23] Albert Ryou, James Whitehead, Maksym Zhelyeznyakov, Paul Anderson, Cem Keskin, Michal Bajcsy 和 Arka Majumdar。基于热原子非线性的自由空间光学神经网络。《Photonics Research》，9(4):B128–B134,2021。
- [24] 王天宇、曼达尔·M·索霍尼、洛根·G·赖特、马丁·M·斯坦、马世元、小野田达弘、麦克斯韦·G·安德森和彼得·L·麦克马洪。基于多层非线性光学神经网络的图像传感。《Nature Photonics》，17(5):408–415,2023。
- [25] 郑汉字、刘全、周友、Ivan I Kravchenko、霍元凯和Jason Valentine。面向对象分类器的元光学加速器。《Science Advances》，8(30):eabo6410,2022。
- [26] 田光周、邢林、吴佳敏、陈一通、谢浩、李一鹏、范景涛、吴华强、方璐和戴琼海。采用可重构衍射处理单元的大规模神经形态光电子计算。《Nature Photonics》，15(5):367–373,2021。
- [27] 罗成黄、Quentin AA Tanguy、Johannes E Froch、Saswata Mukherjee、Karl F Bohringer 和 Arka Majumdar。光学编码器的光子学优势。《纳米光子学》，13(7):1191–1196,2024。
- [28] 薛志伟、周天康、徐志浩、余少亮、戴琼海和方璐。光学神经网络的全前向模式训练。《Nature》，632(8024):280–286,2024。
- [29] Minh Choi, Jinlin Xiang, Anna Wirth-Singh, Seung-Hwan Baek, Eli Shlizerman 和 Arka Majumdar。适用于神经网络的可转移多色光学编码器。《Nature Communications》，16(1):5623,2025。
- [30] 朱莉·张、文森特·西茨曼、熊敦、沃尔夫冈·海德里希和戈登·韦茨斯坦。采用优化衍射光学技术的混合光电子卷积神经网络用于图像分类。《科学报告》，8(1):1–10,2018。
- [31] Carlos Mauricio Villegas Burgos, Tianqi Yang, Yuhao Zhu 和 A. Nickolas Vamivakas。基于超表面光学的卷积神经网络设计框架。《Applied Optics》，60(15):4356–4365,2021。
- [32] 朱博·胡、李舒瑞、Russell LT Schwartz, Maria Solyanik-Gorgone, Mario Miscuglio, Puneet Gupta 和 Volker J Sorger。高通量多通道并行衍射卷积神经网络加速器。《Laser & Photonics Reviews》，16(12):2200213,2022。
- [33] 丛赫、赵丹、范飞、周洪强、李欣与姚莉、李俊杰、董飞、苗银晓、王永天及黄玲玲。基于级联超表面的可插拔多任务衍射神经网络。《Opto-Electronic Advances》，7(23005)，2024。
- [34] 魏凯旋、李晓、约翰内斯·弗罗伊奇、普拉尼思·查克拉瓦尔图拉、詹姆斯·怀特黑德、伊桑·曾、阿尔卡·马朱姆达尔和费利克斯·海德。空间可变纳米光子神经网络。《Science Advances》，10(45):eadp0391,2024。
- [35] 郑汉字、刘全、Ivan I Kravchenko、张晓萌、霍元凯和Jason G Valentine。用于加速机器视觉的多通道元成像技术。《Nature Nanotechnology》，19(4):471–478,2024。
- [36] Cong He, Dan Zhao, Fei Fan, Hongqiang Zhou, Xin Li, Yao Li, Junjie Li, Fei Dong, Yin-Xiao Miao, Yongtian Wang, 等。基于级联超表面的可插拔多任务衍射神经网络。《Opto-Electron. Adv.》，7(2):230005,2024。
- [37] 安娜·沃思-辛格、向金林、崔敏浩、约翰内斯·E·弗罗赫、黄洛成、肖恩·科尔本、埃利·施利泽曼和阿尔卡·马朱姆达尔。用于图像分类的压缩元光学编码器。《Advanced Photonics Nexus》，4(2):026009–026009,2025。

- [38] 安娜·维尔特-辛格、向金林、崔民浩、约翰内斯·弗罗赫、黄洛成、埃利·施利泽曼和阿尔卡·马朱姆达尔。用于图像分类的压缩元光学编码器。载于*CLEO: 基础科学*, 第FF1 J-1页。Optica Publishing Group, 2024年。
- [39] 霍宇奇、鲍虎军、彭一凡、高晨、华伟、杨清、李海峰、王睿和尹成娥。基于松散神经元阵列与功能学习的光学神经网络。*Nature Communications*, 14(1):2535,2023。
- [40] Sadman Sakib Rahman与Aydogan Ozcan。基于衍射神经网络的延时图像分类。*Advanced Intelligent Systems*, 5(5):2200387,2023。
- [41] 陈宇友、向金林、苏坤、张晓然、董思远、John Onofrey、Lawrence Staib 和 James S. Duncan。增量学习与迁移学习的结合：在多站点前列腺MRI分割中的应用。收录于*分布式、协作式与联邦学习国际研讨会*, 第3-16页。Springer出版社, 2022年。
- [42] 金林翔、博兆奇、Marc Cerou、赵伟和唐琦。Dn-ode: 基于数据驱动的神经 ode 模型用于乳腺癌肿瘤动态演变及无进展生存期分析。*生物学与医学中的计算机*, 180:108876,2024。
- [43] 李在勋、肖乐超、Samuel S. Schoenholz、Yasaman Bahri、Roman Novak、Jascha Sohl-Dickstein 和 Jeffrey Pennington。有限与无限神经网络：一项实证研究。载于《*神经信息处理系统进展*》第33卷, 第15156-15172页, 2020年。
- [44] 广达基与朱展兴。广义神经网络中的知识蒸馏：风险边界、数据效率与不完美教师。《*神经信息处理系统进展*》, 33:20823-20833,2020。
- [45] 约安·莫雷洛、埃米莉·格雷瓜尔和萨姆·维尔博文。通过NTK对齐与多任务学习中的早期训练动态探索任务亲和性。发表于2024年*NeurIPS现代机器学习数学研讨会*。
- [46] Jinlin Xiang 和 Eli Shlizerman。Tkil: 用于类别平衡增量学习的切线核方法。*arXiv 预印本 arXiv:2206.08492*, 2022。
- [47] 金林翔与埃利·施利泽曼。TKIL: 用于类别平衡增量学习的切线核优化算法。收录于《*IEEE/CVF 国际计算机视觉会议论文集*》研讨会, 第3529-3539页, 2023年。
- [48] 齐阳郑、郑阳段、陈航、杨瑞、高胜、张海欧、熊洪凯和林星。光子神经网络的双自适应训练。《*自然·机器学习*》, 5(10):1119-1129,2023。
- [49] James Spall、Xianxin Guo 和 Alexander I Lvovsky。光学神经网络的混合训练。*Optica*, 9(7):803-811,2022。
- [50] Hans-Christian Ruiz Euler、Marcus N Boon、Jochem T Wildeboer、Bram van de Ven、Tao Chen、Hajo Broersma、Peter A Bobbert 和 Wilfred G van der Wiel。一种基于深度学习的方法实现纳米电子器件的功能。*Nature Nanotechnology*, 15(12):992-998,2020。
- [51] Yubo Zhang 、 Rui Chen 、 Minh Choi 、 Johannes E Froch与 Arka Majumdar 。基于随机点扩散函数超表面及计算后端的通用图像压缩技术。收录于2024年*激光与电光会议 (CLEO)* 第1-3页。IEEE, 2024年。
- [52] 赵梦然、朱世涛、李迪、托马斯·弗罗门特兹、莫森·哈利利、陈晓明、文森特·富斯科和奥坎·尤尔杜塞文。用于微波计算成像的频率多样化簇状超表面天线。*IEEE 天线与传播汇刊*, 2024年。
- [53] 安德斯·波尔斯、费丁、陈一婷、伊利亚·P·拉德科和谢尔盖·I·博热沃尔尼。光学波长下的随机相位超表面。*科学报告*, 6(1):28448,2016。
- [54] Matthieu Dupre、Liyi Hsu 和 Boubacar Kante。基于随机超表面器件的设计。*Scientific Reports*, 8(1):7162,2018。
- [55] Parker R. Wray 与 Harry A. Atwater。随机分布的单向散射介电纳米颗粒薄膜中的光-物质相互作用。*ACS Photonics*, 7(8):2105-2114,2020。
- [56] Laj Cutrona、E Leith、C Palermo 和 L Porcello。光学数据处理与滤波系统。*IRE 信息论汇刊*, 6(3):386-400,2003。

- [57] Arthur Jacot、Franck Gabriel 和 Clement Hongler。神经切线核：神经网络中的收敛性与泛化。《神经信息处理系统进展》，第31卷，2018年。
- [58] Sanjeev Arora、Simon S Du、Wei Hu、Zhiyuan Li、Russ R Salakhutdinov 和 Ruosong Wang。《基于无限宽神经网络的精确计算》。收录于 H. Wallach、H. Larochelle、A. Beygelzimer、F. d 'Alche-Buc、E. Fox 和 R. Garnett 主编的《神经信息处理系统进展》第32卷。Curran Associates, Inc., 2019。
- [59] Yann LeCun、Leon Bottou、Yoshua Bengio 和 Patrick Haffner。基于梯度的学习在文档识别中的应用。《IEEE 会议录》，86(11):2278–2324,1998。
- [60] Alex Krizhevsky。从微小图像中提取多层特征。技术报告，多伦多大学，2009年。
- [61] 王一特、李大伟和孙若宇。Ntk-sap：通过对齐训练动态改进神经网络剪枝。arXiv 预印本 arXiv:2304.02840, 2023。
- [62] Ryan Vogt、Yang Zheng 和 Eli Shlizerman。基于李雅普诺夫方法的循环神经网络性能表征。《神经计算与应用》，36(34):21211–21226,2024。
- [63] Caleb Zheng 和 Eli Shlizerman。Hyperpruning：基于李雅普诺夫谱对循环神经网络剪枝变体进行高效搜索。arXiv 预印本 arXiv:2506.07975, 2025。
- [64] 谭明兴与Quoc V. Le。EfficientNet：重新思考卷积神经网络的模型缩放。ArXiv, abs/1905.11946,2019。

1. 索赔

问题：摘要和引言中提出的主要论点是否准确反映了该论文的贡献与研究范围？

答案：是

论证依据：摘要与引言清晰阐述了论文的研究范围与贡献，明确了拟提出的 NTKD 流程，并通过理论与实验双重依据支撑相关论点。

指南：

- 答案“NA”表示摘要和引言部分未包含论文中提出的主张。
- 摘要和/或引言部分应清晰阐述所提出的论点，包括论文中的贡献、重要假设及局限性。若对此问题回答“否”或“不适用”，审稿人将不予认可。
- 所提出的论断应与理论及实验结果相符，并反映这些结果在何种程度上可推广至其他情境。
- 将理想目标作为动机纳入研究是可行的，前提是必须明确这些目标并未在论文中实现。

2. 局限性

问题：该论文是否讨论了作者所开展工作的局限性？

答案：是

理由说明：本文在讨论部分承认了当前在线神经网络（ONNs）存在的局限性，例如其结构浅层且呈线性特征、实现非线性功能及规模化扩展的难度，以及制造过程中引发的问题。

指南：

- 答案“NA”表示该论文不存在任何局限性；而答案“No”则表明该论文存在局限性，但这些局限性未在文中进行讨论。
- 建议作者在论文中单独设置“局限性”章节。
- 论文应指出所有重要的假设条件，并说明研究结果在违反这些假设时（例如独立性假设、无噪声环境、模型设定准确、渐近近似仅在局部成立）的稳健性。作者还应探讨这些假设在实际应用中可能被违反的情形及其潜在影响。
- 作者应反思所提出主张的范围，例如该方法是否仅在少数数据集或少量运行中进行过测试。总体而言，实证结果往往依赖于隐含假设，这些假设应当予以明确阐述。
- 作者应反思影响该方法实施效果的各种因素。例如，当图像分辨率较低或拍摄环境光线不足时，面部识别算法的表现可能较差；同样，语音转文本系统也可能无法可靠地为在线讲座提供字幕，因为它无法处理专业术语。
- 作者应讨论所提出算法的计算效率及其随数据集规模的变化规律。
- 如适用，作者应讨论其方法在解决隐私与公平性问题时可能存在的局限性。
- 尽管作者可能担心，对研究局限性的完全坦诚可能会被审稿人作为拒绝论文的理由，但更糟糕的情况是，审稿人会发现论文中未提及的局限性。作者应运用最佳判断力，并认识到：为促进透明度而采取的个人行动，在建立维护学术界诚信的规范方面发挥着重要作用。审稿人将收到明确指示，不得因作者对研究局限性的坦诚陈述而给予扣分。

3. 理论假设与证明

问题：对于每项理论结果，论文是否提供了完整的假设集合及完整（且正确的）证明？

答案：是

依据说明：补充材料提供了相关假设及完整的证明过程。

指南：

- 答案“NA”表示该论文未包含理论研究成果。
- 论文中的所有定理、公式及证明均应编号并进行交叉引用。
- 所有假设均应在任何定理的陈述中明确说明或予以引用。
- 证明可出现在主论文或补充材料中；若出现在补充材料中，建议作者提供简要的证明草图以增强读者的直观理解。
- 反之，论文核心部分提供的任何非正式证明，均应辅以附录或补充材料中提供的正式证明。
- 证明所依赖的定理与引理均应予以恰当引用。

4. 实验结果的可重复性

问题：该论文是否充分披露了重现其主要实验结果所需的所有信息，且这些信息对论文的主要论点和/或结论具有影响（无论代码和数据是否提供）？

答案：是

依据说明：补充材料包含光学实现及安装细节。

指南：

- 答案“NA”表示该论文未包含实验内容。
- 若论文包含实验内容，对此问题未作回答将难以获得审稿人的认可：无论是否提供代码和数据，确保论文可重复性均至关重要。
- 若投稿内容为数据集和/或模型，作者应详细说明为确保研究结果可重复或可验证所采取的具体步骤。
- 根据贡献的具体内容，可重复性的实现方式也有所不同。例如，如果贡献是一项全新的架构设计，完整描述该架构可能就足够；而如果贡献是一个具体的模型及其实证评估结果，则可能需要让他人能够使用相同数据集复现该模型，或提供模型的访问权限。总体而言，公开代码和数据通常是实现可重复性的有效途径之一；此外，通过提供详细的实验复现指南或托管模型的访问权限（例如），同样可以确保结果的可重复性。（对于大型语言模型而言），发布模型检查点，或采用其他适用于所开展研究的方法。
- 尽管 NeurIPS 并不要求公开代码，但会议要求所有提交的论文必须提供某种合理的可重复性验证途径，具体要求可能因论文内容的性质而异。例如：
 - (a) 若贡献主要为新算法，则论文应明确说明如何复现该算法。
 - (b) 若贡献主要为新型模型架构，则论文应清晰完整地阐述该架构。
 - (c) 如果提交的是一个新模型（例如大型语言模型），则应提供两种途径之一：要么能够访问该模型以重现实验结果，要么能够复现该模型（例如通过开源数据集或构建数据集的说明）。
 - (d) 我们认识到，在某些情况下可重复性可能较为复杂；对此，作者可详细说明其确保可重复性的具体方法。对于闭源模型而言，模型的访问权限可能受到一定限制（例如：（仅限注册用户）），但其他研究人员应能够找到某种途径来重现或验证这些结果。

5. 数据和代码的开放获取

问题：该论文是否提供了数据和代码的开放获取权限，并附有充分的操作说明，以便按照补充材料所述内容准确复现主要实验结果？

答案：是

研究依据：本实验采用开源基准数据集，具体实现细节详见补充材料。

指南：

- 答案“NA”表示该论文不包含需要编写代码的实验。
- 更多详情请参阅 NeurIPS 代码与数据提交指南 (<https://nips.cc/public/guides/CodeSubmissionPolicy>)。
- 尽管我们鼓励公开代码和数据，但我们理解这可能无法实现，因此“否”是一个可接受的答案。论文不能仅因未包含代码而被拒绝，除非该代码是研究贡献的核心部分（例如，针对新的开源基准测试）。
- 说明中应包含运行以重现结果所需的精确命令和环境。更多详情请参阅 NeurIPS 代码与数据提交指南 (<https://nips.cc/public/guides/CodeSubmissionPolicy>)。
- 作者应提供关于数据访问与处理的指导说明，包括如何访问原始数据、预处理数据、中间数据及生成数据等。
- 作者应提供脚本，以重现所提出新方法及其基线方法的所有实验结果。若仅部分实验可重复，则需明确说明哪些实验未包含在脚本中及其原因。
- 在提交时，为保护匿名性，作者应发布匿名化版本（如适用）。
- 建议在补充材料（附于论文后）中提供尽可能多的信息，但允许包含数据和代码的 URL 链接。

6. 实验设置/详情

问题：该论文是否详细列出了理解实验结果所需的所有训练与测试参数（例如数据划分方式、超参数及其选择依据、优化器类型等）？

答案：是

依据说明：具体实施细节详见补充材料。

指南：

- 答案“NA”表示该论文未包含实验内容。
- 实验设置应在论文核心部分予以详尽阐述，其细节程度应足以使读者理解并解读实验结果。
- 完整细节可随代码、附录或补充材料一并提供。

7. 实验统计学显著性

问题：该论文是否恰当且正确地定义了误差条，或提供了关于实验统计学显著性的其他相关信息？

答案：是

理由：实验采用多个随机种子重复进行，结果以均值和标准差形式报告。

指南：

- 答案“NA”表示该论文未包含实验内容。
- 若研究结果附有误差线、置信区间或统计学显著性检验（至少针对支持论文主要结论的实验），作者应回答“是”。
- 误差条所反映的变异因素应明确说明（例如：训练集/测试集划分、初始化设置、某些参数的随机选取，或在特定实验条件下进行的整体运行）。

- 应详细说明误差条的计算方法（包括闭合形式公式、调用库函数、自助法等）。
- 应明确所作的假设（例如：误差服从正态分布）。
- 必须明确误差条表示的是标准差还是均数的标准误。
- 报告 1σ 误差条是可行的，但应明确说明。若未验证误差服从正态分布的假设，作者最好报告 2σ 误差条，而非仅声明其置信区间（CI）为96%。
- 对于非对称分布，作者应谨慎避免在表格或图表中使用对称误差条，否则可能导致结果超出合理范围（例如出现负误差率）。
- 若表格或图表中包含误差条，作者应在文中说明其计算方法，并引用相应的图表或表格。

8. 实验计算资源

问题：对于每个实验，论文是否提供了足够的计算机资源信息（计算工作节点类型、内存容量、执行时间）以供重复实验？

答案：是

依据说明：我们提供了MAC值及系统级功耗的估算数据。

指南：

- 答案“NA”表示该论文未包含实验内容。
- 论文应明确说明计算节点的CPU或GPU类型、内部集群或云服务提供商，并注明相关的内存和存储配置。
- 该论文应提供每次独立实验运行所需的计算量，并估算总计算量。
- 该论文应披露整个研究项目是否需要比论文中报告的实验更多的计算资源（例如，未纳入论文的初步实验或失败实验）。

9. 职业道德准则

问题：论文中进行的研究在各个方面是否都符合NeurIPS伦理准则<https://neurips.cc/public/EthicsGuidelines>？

答案：是

研究依据：本研究符合NeurIPS伦理准则。

指南：

- 答案“NA”表示作者未审阅NeurIPS伦理准则。
- 若作者回答“否”，则应说明需要偏离《伦理准则》的具体特殊情况。
- 作者应确保保护匿名性（例如，若其所在司法辖区的法律法规有特殊要求）。

10. 更广泛的影响

问题：该论文是否同时探讨了所开展工作的潜在积极社会影响与消极社会影响？

答案：[NA]

研究依据：本研究未产生显著的社会影响，属于基础性研究。

指南：

- 答案“NA”表示所执行的工作未对社会产生任何影响。
- 若作者回答“NA”或“否”，则应说明其研究为何未产生社会影响，或论文未涉及社会影响的原因。

- 负面社会影响的例子包括潜在的恶意或非预期用途（例如：虚假信息传播、创建虚假个人资料、监控行为）、公平性考量（例如：部署可能对特定群体造成不公平影响的技术）、隐私问题以及安全问题。
- 本次会议预计，许多论文都将属于基础性研究，与特定应用并无直接关联，更遑论实际部署。然而，如果研究结果可能被用于负面用途，作者应当明确指出。例如，指出生成模型质量的提升可能被用于制造虚假信息类深度伪造内容是合理的；但另一方面，无需强调通用神经网络优化算法能够帮助研究人员更快地训练出生成深度伪造内容的模型。
- 作者应考虑以下可能产生的危害：当技术按预期用途正确运行时可能出现的危害；当技术按预期用途使用但产生错误结果时可能出现的危害；以及因（故意或无意）滥用该技术而引发的危害。
- 如果存在负面的社会影响，作者还可以讨论可能的缓解策略（例如：对模型实施门控式发布、在防御措施之外增设攻击防护机制、建立监控滥用行为的机制、建立监测系统如何随时间从反馈中学习的机制、提升机器学习的效率与可访问性）。

11. 保障措施

问题：该论文是否描述了为负责任地发布存在高滥用风险的数据或模型（例如预训练语言模型、图像生成器或抓取数据集）而制定的保障措施？

答案：[NA]

理由：该论文不存在此类风险。

指南：

- 答案“NA”表示该论文不存在此类风险。
- 具有高误用风险或双重用途的发布模型，应在发布时采取必要的保障措施，以确保该模型能够得到受控使用；例如，要求用户遵守使用指南或访问限制，或实施安全过滤机制。
- 从互联网抓取的数据集可能带来安全隐患。作者应说明如何避免发布不安全的图像。
- 我们认识到，提供有效的保障措施具有挑战性，且许多论文并不要求这样做；但我们鼓励作者充分考虑这一点，并尽最大努力予以落实。

12. 现有资产的许可证

问题：论文中使用的资产（例如代码、数据、模型）的创建者或原始所有者是否得到了应有的致谢？其许可协议及使用条款是否已明确提及并得到妥善遵守？

答案：是

理由：] 我们已正确标注了论文中使用的所有资产来源。

指南：

- 答案“NA”表示该论文未使用现有资源。
- 作者应引用生成该代码包或数据集的原始论文。
- 作者应说明所使用的资产版本，并尽可能提供相应的URL链接。
- 每项资产均应注明许可证名称（例如：CC-BY 4.0）。
- 对于来自特定来源（例如网站）的 scraped 数据，应提供该来源的版权信息和服务条款。
- 若释放资产，应提供该软件包中的许可证、版权信息及使用条款。对于常用数据集，建议参考 paperswithcode.com/datasets 已为部分数据集整理了相应的许可协议。其许可指南可帮助用户确定特定数据集的许可类型。

- 对于已重新打包的现有数据集，应同时提供原始许可证及衍生资产的许可证（若许可证内容已变更）。
- 若该信息无法在线获取，建议作者联系该资源的创建者。

13. 新资产

问题：论文中引入的新资产是否已有充分记录？相关文件是否随资产一并提供？

答案：[NA]

研究依据：本文未引入任何新的数据集。

指南：

- 答案“NA”表示该论文未发布新的研究成果。
- 研究人员应在提交材料时，通过结构化模板详细说明数据集/代码/模型的相关信息，包括训练过程、许可证类型、使用限制等内容。
- 该论文应探讨是否以及如何从其资产被使用的人群处获得知情同意。
- 提交文件时，请务必对您的资产进行匿名处理（如适用）。您可以创建一个匿名URL，或上传一个经过匿名处理的压缩文件。

14. 众包与涉及人类受试者的研究

问题：对于涉及众包实验及人类受试者的研究，论文是否包含了提供给参与者的完整指导文本（如适用）及截图，同时还包含有关报酬的详细信息（如有）？

答案：[NA]

研究依据：本研究未涉及任何众包或人体受试者研究。指南：

- 答案“NA”表示该论文未涉及众包或人体受试者研究。
- 将此信息纳入补充材料并无不妥，但若论文的主要贡献涉及人类受试者，则应在正文部分尽可能详尽地阐述相关细节。
- 根据NeurIPS伦理准则，参与数据收集、数据整理或其他相关工作的人员，其薪酬至少应达到数据收集所在国家的最低工资标准。

15. 涉及人类受试者的研究需获得机构审查委员会（IRB）批准或同等效力的许可

问题：该论文是否描述了研究参与者可能面临的风险？这些风险是否已向受试者披露？是否获得了机构审查委员会（IRB）的批准（或根据贵国或机构的要求获得的同等审批/审查）？

答案：[NA]

研究依据：本研究不涉及人类受试者或用户研究，因此无需获得机构审查委员会（IRB）的批准。

指南：

- 答案“NA”表示该论文未涉及众包或人体受试者研究。
- 根据研究开展的国家不同，任何涉及人类受试者的研究可能均需获得机构审查委员会（IRB）的批准（或同等效力的许可）。若您已获得IRB批准，应在论文中明确说明这一点。
- 我们认识到，不同机构和地区的相关操作流程可能存在显著差异，因此要求作者严格遵守NeurIPS伦理准则及其所在机构的指导方针。

- 在初次提交时，不得包含任何可能破坏匿名性的信息（如适用），例如进行评审的机构名称。

16. LLM使用声明

问题：若大型语言模型（LLM）是本研究核心方法中重要、原创或非标准的组成部分，论文是否需对其使用情况进行说明？需注意：若LLM仅用于写作、编辑或格式化目的，且不影响研究的核心方法论、科学严谨性或原创性，则无需作出声明。

答案：[NA]

理由：本研究的核心方法开发不涉及大型语言模型（LLMs）。

指南：

- 答案“NA”表示本研究的核心方法开发未将大语言模型（LLMs）作为任何重要、原创或非标准组成部分。
- 有关应描述或不应描述的内容，请参阅我们的LLM政策（<https://neurips.cc/Conferences/2025/LLM>）。