




适用于神经网络的可移植多色光学编码器

收到日期：2024年12月2日

接受日期：2025年6月19日

Published online: 01 July 2025

崔敏浩^{1,5}✉, 向金林^{1,5}, 安娜·维尔特-辛格², 白承焕³, 埃利·什莱泽曼^{1,4}
✉ & 阿尔卡·马朱姆达尔^{1,2}✉

神经网络从根本上改变了计算机视觉领域，实现了前所未有的性能提升。然而，这些用于图像处理的神经网络需要消耗大量计算资源，常常阻碍实时运算。在本研究中，我们开发了一种光学编码器，能够在图像采集过程中同时对三个颜色通道进行卷积运算，从而有效实现了网络多个初始卷积层的功能。这种光学编码技术使计算操作量减少了约24,000倍，并在自由空间光学系统中实现了最先进的分类准确率（约73.2%）。此外，我们针对 CIFAR -10数据训练的模拟光学编码器无需任何修改即可直接迁移至ImageNet的High-10子集，并仍能保持中等准确率。所提出的方法可使单个物体分类的系统级总能耗降低两个数量级以上。实验结果证明了混合式光学/数字计算机视觉系统的潜力：其光学前端可对环境场景进行预处理，从而降低整个计算机视觉系统的能耗与延迟。

视觉信息在人类反应中起着至关重要的作用，尤其是在反应时间仅限于几十至几百毫秒的情况下^{1,2}。尽管人脑的效率远超任何其他人工计算系统，但由于信息量巨大，它仍无法处理所有收集到的视觉数据。很可能，人脑会进行早期视觉处理，提取出高效快速解读所需的关键特征，而无需处理全部视觉数据³⁻⁵。

随着人工智能（AI）的飞速发展，得益于人工神经网络（ANNs），计算机能够像人脑一样处理视觉信息，从而实现了计算机/机器视觉⁶⁻¹⁰。尽管取得了显著进展，但在计算资源有限的情况下，即使采用更高效的算法，实时推理仍极具挑战性。例如，在飞行物体（即栖息地无人机¹¹）的现场数据处理过程中，会面临严重的发热、电池容量及重量控制难题。利用基于云的

这些系统存在与数据安全及额外数据传输延迟相关的挑战^{12,13}。

光学神经网络已成为规避这些权衡关系的潜在平台，因为光学系统能够以较大的时空带宽处理多维信息¹⁴。近年来，集成光子学与自由空间或光纤技术已被应用于实现人工神经网络（ANN）的某些部分，用于图像压缩/加密^{15,16}及分类¹⁷⁻²⁵。然而，大多数方法在处理相对简单的灰度数据集（如 MNIST 和 Fashion-MNIST）时存在严重局限，仅有少数系统实现了对更复杂的多通道数据集（如 CIFAR -10和ImageNet）的处理^{17,23}。对于这些复杂数据集，光学系统往往变得极其庞大（包含多层光子电路堆叠）²³；否则分类准确率仍维持较低水平（CIFAR -10分类任务的准确率约为60%）^{17,26,27}。此外，最成功的人工神经网络架构均采用了非线性激活函数。

¹华盛顿大学电气与计算机工程系，西雅图 98103 WA，美国。²华盛顿大学物理系，西雅图 98103 WA，美国。³韩国京畿道浦项市37673，浦项科技大学计算机科学与工程系。⁴美国华盛顿州西雅图市98103，华盛顿大学应用数学系。⁵本文作者贡献相同：Minho Choi、Jinlin Xiang。✉电子邮件：kernel@uw.edu；shlee@uw.edu；arka@uw.edu




图1 | 使用原始CNN、压缩全数字CNN及混合光学/数字CNN的不同图像分类方法的流程示意图

数字CNN。原始CNN（AlexNet）最初会利用现有知识进行压缩处理。

通过蒸馏技术，将所有卷积层整合为单一卷积层。随后，该压缩后的卷积层被替换为超表面结构。

这些方案在光学实现上颇具挑战性。所提出的解决方案（包括原子蒸气池^{28,29}和图像增强器³⁰）不仅显著增加了实验复杂度，还导致功耗上升。

为了充分发挥光学与数字计算系统的双重优势，一种受编码器-解码器启发的混合型光学/数字架构是一种极具前景的方法^{8,10,31,32}。具体而言，模拟线性光学前端（称为光学编码器）承担了大部分线性计算任务，而数字后端则实现非线性运算。一个引人入胜的可能性是采用静态光学前端，该前端对数据类型无要求，而后端则可进行训练和重新配置。这种设计解决了全光学系统中常见的调制速度、误差及系统尺寸等问题。光学编码器特别适用于卷积神经网络（CNN）架构——其中卷积层充当特征提取器，将高维图像编码为低维特征³³。事实上，在非相干光成像过程中，任何自由空间光学系统本质上都会执行二维卷积运算。所捕获的图像实际上是场景与光学系统非相干光场之间的卷积结果。

固有的点扩散函数（PSF）³⁴。因此，通过优化PSF，光学编码器能够执行所需的卷积运算，从而替代卷积神经网络（CNN）的初始层。

最近，研究人员采用基于PSF算法设计的光学编码器对MNIST手写数据集进行分类，并证明其分类准确率相当，且与AlexNet相比计算成本显著降低³⁵。需要指出的是，MNIST图像均为单色图像，且几乎具有线性可分性（分类准确率可达99.9%）。损失率仅为84%，且不存在任何非线性效应³⁶。图像的单色特性使得PSF工程方法具有波长无关性。另一方面，诸如CIFAR-10³⁷或ImageNet子集（High-10）^{33,38}等数据集无法通过线性层进行有效分类。此外，这些数据集包含彩色图像，其实际颜色信息被用于分类任务。

本文展示了一种采用PSF工程化元光学技术的多色光学编码器，用于对CIFAR-10数据集进行分类。我们首先通过知识蒸馏技术将该架构压缩为一个卷积层和两个全连接层；随后，采用一组元表面阵列实现了卷积层的物理结构，其中每个元表面均具备特定功能。

得益于其固有的色度特性，超表面可对每个颜色通道分别进行卷积运算。因此，采用光学编码器的混合CNN将数字后端的乘积累加（MAC）操作总数降低了约24,000倍。MAC操作数量的减少直接对应于计算成本，即功耗和延迟³⁹。需要特别指出的是，在将图像数据传输至计算后端之前，我们始终需要依赖成像系统（即镜头和相机）在环境光照条件下采集图像。因此，采用单一超光学编码器时，我们并未增加任何额外的光学元件，而只是用点扩散函数（PSF）优化设计的超光学元件替换了传统镜头。这使得我们的光学系统结构紧凑，且与传统光学成像系统完全兼容；相比之下，集成光子系统等其他方案则需要对数据进行预处理²³，而传感器内计算技术则需要定制化的传感器设计⁴⁰。

此外，我们采用了相同的元光学架构（光学卷积层），该架构已针对CIFAR-10数据集进行优化，并扩展应用于High-10数据集，以验证光学编码器的通用性。实际上，静态光学编码器应适用于任何场景。一种实现方法是采用可重构前端架构。基于非易失性相变材料⁴¹或液晶材料⁴²构建的这些可重构前端，在单像素控制精度、功耗及运行速度方面，其性能仍不满足实际应用需求。通过采用相同的被动光学编码器（针对CIFAR-10数据集进行优化），我们借助迁移学习方法，在数字后端网络中添加全连接层后，实现了较高的分类准确率（针对High-10数据集）。这种前端网络的泛化能力对任何人工神经网络（ANN）都至关重要，它能显著提升网络的通用性、效率和鲁棒性。具有良好泛化能力的网络无需大量重新训练即可应用于不同任务，从而节省时间、降低超表面制造成本，并为实际应用节省计算资源。

结果

我们的光学编码器概念如图1所示。原始CNN（即AlexNet）包含五个卷积层和三个最大池化层。

该架构前端包含一个卷积层，末端接续三个全连接层，每层均采用非线性激活函数“ReLU”。若将所有五个独立的卷积层替换为五个连续的光学元件，会面临对位精度不足、系统规模过大、缺乏非线性特性以及信噪比偏低等问题——这些问题会随着光学元件数量的增加而加剧。因此，我们采用知识蒸馏方法⁴³将AlexNet压缩为单个卷积层和两个全连接层，从而在几乎不牺牲准确性的前提下降低了架构复杂度。

虽然对原始CNN进行压缩对于实现光学编码器方案至关重要，但实际应用中需要权衡诸多因素。一方面，传感器的物理尺寸和元光学元件的结构限制了核的数量和尺寸；另一方面，过小的核尺寸或过多的核数量会降低数据分类效果。我们通过实验方法，在压缩原始CNN的过程中找到了最优的核数量和尺寸。在CIFAR-10分类任务中，我们设计了16个7×7尺寸的卷积核（详见补充信息）。经压缩处理的全数字CNN在训练集和测试集上的准确率分别为76.24±0.31%和75.90±0.30%。

由于CIFAR-10图像包含三个通道信息——分别对应红色(R)、绿色(G)和蓝色(B)——每种颜色都有16个独立的7×7卷积核，共计48个卷积核。在元光学技术中，可以设计单一元光学系统来生成针对RGB波长的三种不同点扩散函数（即卷积核）（详见方法部分）。由于难以同时为相机端的光强度设置正负权重，我们将每个卷积核拆分为正负两部分，并分别为每部分设计对应的光学元件⁴⁴，最终共获得32个元光学系统，分别对应16个正色多色卷积核和16个负色多色卷积核。

另一个重要的设计参数是确定相机上多少个像素对应PSF的一个像素。我们将这一参数称为放大因子。例如，当放大倍数为2时，真实的点扩散函数（PSF）——一个7×7矩阵——在相机上对应14×14个像素。虽然较大的放大倍数能降低对齐误差，但每个相机像素的信号强度会降低，从而导致信噪比下降。为确定最佳放大倍数，我们针对特定核函数对多种具有不同放大倍数的元光学系统进行了实验测试（详见补充信息），最终得出：由3200×3200个散射体组成的元光学系统的最佳放大倍数为2。

这些超表面由氮化硅制成，并沉积在石英基底上，以确保在可见光波长范围内具有高透明度（图2a）。图2b展示了透射系数和相位偏移。

通过严格的双波分析（RCWA）获得，在固定高度800纳米条件下，氮化硅柱在RGB波长下的形态随柱宽 w 的变化关系。基于激光二极管的可用性，我们针对RGB颜色选定了450、532和635纳米作为目标波长（ λ ）。

为有效模拟基于梯度下降优化方法中元光学元件的波长依赖性效应，需要一个快速且可微分的函数来建立柱宽与施加相位之间的映射关系。我们设计了一个代理函数，其灵感来源于介电波导的近似相位偏移，并加入了根据RCWA模拟结果拟合得到的校正因子。该函数用于计算相位偏移。（ f_R 、 f_G 和 f_B ）针对RGB波长与柱宽 w 的关系，我们定义了以下代理函数：

$$f_{\lambda}(w) = 2\pi n_{\text{eff}} L / \lambda + A \exp((w - B)^2 / C) - f_0. \quad (1)$$

第一项对应于介电波导中的通用相位偏移，其中 n_{eff} 和 L 分别为氮化硅柱的有效折射率和高度。第二项仅包含 w 方差，对应于高斯分布形式的修正项，其中 A 、 B 和 C 为拟合参数。最后， f_0 表示相位偏移量，使得 $f_{\lambda}(0)=0$ 。该代理函数并未模拟共振引起的相位变化；然而，我们并不希望利用这些由振幅减小导致的相位变化，且由于侧壁粗糙度的影响，这些共振在制造的器件中预计不会那么显著。

图2c展示了针对各RGB颜色优化了点扩散函数（PSF）的多色RGB超光学系统的设计流程。对于由任意二维柱宽图 $w(x, y)$ 参数化的超光学系统，我们通过代理函数 f_{λ} 提取三个独立的相位图。随后采用角谱法⁴⁵传播电磁场，以模拟距超光学系统2.4毫米焦平面处的PSF。在焦平面处，我们比较了基于知识蒸馏（ $\text{PSF}_{\text{GT}, \lambda}$ ）获得的卷积核定义的计算基准PSF与各RGB通道的光学模拟PSF（ $\text{PSF}_{\text{sim}, \lambda}$ ），其中通道依赖性损耗由各像素差异的平方和定义：

$$\mathcal{L}_{\lambda} = \sum_{x,y} |\text{PSF}_{\text{GT}, \lambda}(x, y) - \text{PSF}_{\text{sim}, \lambda}(x, y)|^2. \quad (2)$$

我们优化了二维柱宽图（即元光学系统），以最小化净损耗——该损耗定义为三种不同颜色下损耗的均方根值，并采用Adam优化算法进行计算。




图2 | 多色超光学设计。a 超光学散射器的示意图：位于石英基底上的氮化硅柱状结构。b 统一排列的柱状结构相对于参考基准的相对相位偏移（虚线）与透射率（实线）。

当柱高固定为800 nm时，不同RGB波长对应的柱宽 w 。阴影线为相对于 w 的相位偏移拟合代理函数。

c 多色超光学优化的设计流程。




图 3 | 元光学编码器的光学特性分析。a 制造完成的元光学编码器照片，该编码器由 16 个正卷积核、16 个负卷积核及 5 个对准金属透镜组成。b 多色点扩散函数 (PSF) 测量装置示意图。c 特定多色卷积核（正卷积核编号 7）的基准数字测量值与光学测量值点扩散函数示意图。d

配备微型显示屏的元光学卷积图像测量系统。彩色相机可单次拍摄即可获取卷积图像。e 图展示了特定 CIFAR-10 图像在数字（上图）与光学（下图）两种卷积方式下各 RGB 颜色的对应结果。f 图呈现了采用不同网络架构的 CIFAR-10 数据集分类任务的混淆矩阵。

TensorFlow 中的优化器⁴⁶：

$$mw_{\alpha} i, ny_{jj} \sum_{\lambda} L2 \lambda_{jj}^{1/2}. \quad (3)$$

所有三种不同颜色样本的计算损失值详见补充信息。

图 3a 展示了所制备芯片的光学图像。单个芯片共包含 32 个卷积元光学元件（对应 16 个正卷积核和 16 个负卷积核），以及另外 5 个金属透镜，这些金属透镜用于在焦平面上聚焦光线，以辅助元光学元件与相机之间的对准（例如倾斜、旋转和距离）。每个卷积元光学元件的尺寸约为 $940 \times 940 \mu\text{m}^2$ 。图 3b 展示了 PSF 测量装置的示意图。通过更换激光二极管，我们可以分别对 RGB 通道进行独立照明。

通过超光学系统将相干光投射到相机上，并对多色点扩散函数 (PSF) 进行实验表征。直径为 25 微米的针孔可模拟近似点光源；在更换激光二极管的同时，光学元件（即针孔、超光学系统和相机）的位置保持不变。

图 3c 展示了针对特定核函数在各 RGB 波长下的真实点扩散函数 (PSF) 与实测点扩散函数。为定量分析真实值与实验测量值之间的差异，我们定义了余弦相似度 (η)，其计算公式如下：

$$\eta = \frac{\sum_i (A_i B_i)}{\sqrt{\sum_i (A_i^2)} \sqrt{\sum_i (B_i^2)}}, \quad (4)$$

where A_i and B_i 表示 RGB 波长下 PSF 的真实强度分布曲线与实测强度分布曲线。计算得到的 RGB 波长 η 值如下：

表1 | CIFAR -10数据集上的分类结果

网络架构	训练准确率 (%)	测试准确率 (%)
亚历克斯·奈特	83.04 ± 0.87	81.03 ± 0.89
压缩数字CNN	76.94 ± 0.52	76.59 ± 0.50
混合光学/数字CNN（不含校准层）	56.78 ± 0.91	56.39 ± 0.92
混合光学/数字CNN（含校准层）	73.18 ± 0.58	72.06 ± 0.57
混合光学/数字CNN（支持后端重新训练）	75.05 ± 0.47	73.17 ± 0.49
仅适用于后端（含校准层）	54.32 ± 0.48	51.40 ± 0.49

表2 | MAC操作次数取决于CNN架构（*可进行压缩）

图层	亚历克斯·奈特	压缩CNN	混合光学/数字卷积神经网络（CNN）
		3 × 64 × 11 × 11 × 224 × 224	
		64 × 192 × 5 × 5 × 55 × 55	
卷积	192 × 384 × 5 × 5 × 27 × 27	3 × 16 × 7 × 7 × 32 × 32	0
		384 × 256 × 3 × 3 × 13 × 13	
	256 × 256 × 3 × 3 × 6 × 6		
	9216 × 4096	576 × 256	576 × 576*
全连接	4096 × 1024	256 × 10	576 × 256
	1024 × 10		256 × 10
总数	3,651,368,960	2,558,464	150,016

各波长值分别约为0.88、0.56和0.81。这种定量差异部分可归因于制造和测量过程中的缺陷。此外，并非所有多色点扩散函数（PSF）在物理上都能实现，因为不同波长下的相位并非完全独立。通过协同设计光学前端与计算后端（即所谓的端到端设计^{47,48}）来创建更符合物理特性的PSF——而非用光学元件替代卷积层——可能有助于提升 η 。然而，在端到端设计中引入元光学仿真可能会导致局部最优解，且制造/测量过程中的缺陷依然存在。如图后文所示，计算后端对点扩散函数（PSF）中的此类差异具有鲁棒性；我们只需在数字后端增加一个全连接校准层，即可轻松修正这些误差。关于光学实现不完美的详细讨论，请参阅“讨论”部分。

随后，我们使用 CIFAR -10数据集对多色光学编码器进行了测试。通过用有机发光二极管（OLED）显示屏替代针孔，输入图像与点扩散函数（PSF）之间的光学卷积运算可在单个芯片上通过空间分离的元光学系统完成，随后由彩色相机采集（图3 d）。彩色相机采集了32幅不同的卷积图像，并对其进行校准及全连接层的数字后处理。显示图像尺寸根据卷积核尺寸及相机放大倍数进行精确调整（更多细节详见补充信息）。图3 e展示了 CIFAR -10数据集中一张图像的计算卷积与元光学卷积处理后的RGB图像。元光学卷积图像会损失部分高分辨率成分，这可能是由于制造工艺不完美及对准误差所致——这些误差已可通过点扩散函数（PSF）测量结果识别，同时相机RGB颜色像素之间也存在光谱重叠现象。不过如图后文所示，我们的计算后端对这类差异具有较强的鲁棒性，因为我们对卷积后的图像进行了6×6尺寸的平均池化处理。此外，我们还添加了一个名为“校准层”的全连接层，用于调整各卷积核和颜色通道的权重，以消除光学系统与数字系统之间的差异（例如归一化、缩放、平移、旋转、倾斜及噪声）。该校准层使我们能够利用预训练的数字后端模型，同时将计算成本降至最低。

关于校准层的详细说明详见方法部分及补充信息。

图3 f展示了 CIFAR -10数据在使用原始CNN（AlexNet）、采用知识蒸馏技术的压缩CNN，以及压缩后采用卷积元光学技术的混合光学/数字CNN时的分类准确率混淆矩阵。尽管光学与数字卷积结果存在细微差异（图3 e），但在引入校准层后，我们在训练集和测试集上均实现了相近的准确率（损失低于5%）（表1）。若重新训练后端模型和校准层仍可提升准确率，但重新训练后端模型并无实际应用价值。此外，这种混合方案显著降低了计算成本，具体体现在乘积累加（MAC）操作次数的减少上：从原始CNN到压缩CNN，MAC操作次数减少了约1/400；而用元光学技术替代卷积层后，该数值进一步降低了约1/17。各CNN架构所需的MAC操作次数的详细计算结果见表2。网络设计及维度选择的详细信息详见补充材料。

为分析元光学卷积层的有效性，我们采用了主成分分析方法（图4）。对于原始CNN和压缩后的全数字CNN，各类别均呈现良好的分离效果（图4 a、b），这表明经过卷积处理后能够有效提取 CIFAR -10图像数据集的关键特征。另一方面，采用元光学技术进行光学卷积且未设置校准层时，图像中不同类别的区分变得极为困难（图4 c）；此外，某些聚类区域的规模及重叠部分较图4 a、b、e更为显著，例如海军蓝、棕色和红色聚类区域（置信椭圆）。然而，在引入校准层后，聚类区域缩小，类别间分离度显著提升。如图4 d所示，各类别均实现了清晰可辨的分离效果，与压缩后的CNN表现相当。校准层的这一关键作用与未使用及使用校准层时的分类准确率结果一致（表1）。我们注意到，校准层可通过额外训练被整合到预训练的数字后端模型中。




图4 | CIFAR -10图像数据集的主成分分析。a原始CNN（AlexNet）；b压缩后的全数字CNN；c无校准层的混合光学/数字CNN；d带校准层的混合光学/数字CNN。

表3 | High-10图像数据集上的迁移学习结果

网络架构	训练准确率 (%)	测试准确率 (%)
亚历克斯·奈特	85.31 ± 0.27	84.95 ± 0.49
压缩CNN（不使用迁移学习）	41.43 ± 0.26	40.44 ± 0.39
压缩CNN（结合迁移学习）	67.43 ± 0.22	66.01 ± 0.13
混合光学/数字卷积神经网络（采用迁移学习）	63.46 ± 0.46	59.73 ± 0.91

这不会影响推理所需的MAC操作次数（表2）。此外，与仅使用后端的结果（表1）相比，我们的混合光/数字架构实现了显著更高的分类准确率（超过20%），充分凸显了光学卷积编码器的关键作用。

我们的卷积元光学系统采用了源自 CIFAR -10数据压缩CNN的卷积核。与计算神经网络不同，光学实现一旦制造完成便极难进行修改。这要求针对不同数据集采用不同的卷积元光学方案。然而，我们发现为 CIFAR -10数据集优化的卷积层可通过迁移学习方法轻松适配于另一数据集High-10的分类任务。我们在原有全连接层与卷积层之间新增了一个全连接层（称为“迁移学习层”）。通过训练该迁移学习层，仅需对原始网络结构保持不变，仅对原网络的少量部分进行微调，即可将原本为特定数据集（如 CIFAR -10）预优化的CNN模型适配至另一数据集（即High-10）（具体方法详见“方法”部分）。High-10图像数据集为多色（RGB）格式，尺寸为224×224像素。为使针对 CIFAR -10数据优化的CNN模型适用于High-10数据，我们将High-10图像调整为与 CIFAR -10数据相同的32×32像素尺寸。

在未采用迁移学习方法的情况下，训练和测试准确率较低，约为40%。然而，应用迁移学习后，训练和测试准确率显著提高至约67.43%和约66%。在High-10数据集上，分别使用卷积层和两个全连接层（表3）实现了约0.01%的性能提升。我们进一步通过实验验证了该方法在混合光学/数字CNN中的有效性：采用与 CIFAR -10数据数字后端结构相同的卷积元光学架构，并结合迁移学习层。High-10数据的平均训练与测试准确率（损失率低于5%）与全数字压缩CNN相当，与 CIFAR -10案例基本一致。压缩CNN和混合CNN在High-10数据上的主成分分析结果详见补充材料，从中可清晰观察不同类别在特征图中的分离效果。关于校准层设计、校准层数量选择及主成分分析可视化等详细信息亦收录于补充材料中。

讨论

多通道数据集

知识蒸馏与元光学编码器的优势在于显著降低计算复杂度，这一优势体现在MAC操作次数的减少上。在 CIFAR -10数据集上，我们提出的混合光学/数字CNN将MAC操作次数减少了约24,000倍（表2）。这一降幅比 MNIST 手写数据集高出两个数量级以上——后者采用的超光学编码器仅将MAC操作次数减少了约200倍（详见³⁵补充材料中的表S2）。与 MNIST 数据集相比， CIFAR -10数据集数字运算量的大幅缩减在能耗和延迟方面均具有显著优势。这主要源于该数据集的复杂性（包括其多色特性），导致卷积层需要执行更多运算。

另一方面，与 MNIST 数据集相比， CIFAR -10数据集的分类准确率下降更为显著。在 CIFAR -10数据集上，我们的混合CNN的训练（测试）准确率较原始CNN下降约9.86%（约8.97%）；而在 MNIST 数据集上，混合CNN的训练（测试）准确率较原始CNN下降约5.0%（约5.0%）³⁵。尽管 CIFAR -10数据集上的分类准确率下降不容忽视，但我们的PSF工程化光学编码器相较于其他适用于传统相机系统的自由空间光学神经网络架构，展现出显著更高的分类准确率。在无需重新训练后端模型、仅通过校准层进行投影的情况下，该编码器在 CIFAR -10数据集上的分类测试准确率约为72.1%。若对后端模型进行重新训练，测试准确率可进一步提升至约73.2%，这一结果优于先前采用复杂端到端优化及50个核函数后端重新训练的最先进成果（约72.8%）⁴⁸。我们的混合光学/数字CNN可通过使用复杂的元原子来更精确地光学复现PSF⁴⁹，并采用先进的压缩方法降低知识蒸馏过程中的信息损失⁵⁰，从而实现更优性能。其他研究报道的准确率（约63%^{17,26,27}）远低于我们的成果。

可转让性

由于数据量巨大，这种混合方法在处理更复杂的真实世界数据集（如 ImageNet）时的可扩展性仍面临挑战。

表4 | 计算机视觉各步骤中单次图像分类任务的系统级能耗（单位：焦耳）取决于网络架构

网络架构	光学前端（GT 1930C）	数字后端（2080 Ti/最先进的技术）	系统（2080 Ti） / 现状——
原始CNN，配备最佳摄像头像素	2.91×10^{-5}	$1.12 \times 10^{-1} / 3.65 \times 10^{-3}$	$1.12 \times 10^{-1} / 3.68 \times 10^{-3}$
我们采用最优相机像素的混合光学/数字CNN	3.28×10^{-5}	$4.62 \times 10^{-6} / 1.50 \times 10^{-7}$	$3.74 \times 10^{-5} / 3.30 \times 10^{-5}$

“State-of-the-art” 指的是最先进的GPU。

在准确性方面，准确性下降的主要原因是网络结构的简化，例如减少了网络层数。例如，AlexNet在其最终卷积层中使用了256个卷积核，而我们仅使用了16个卷积核。

在此，我们将模型从 CIFAR -10 迁移至 ImageNet 子集（High-10）。High-10 与 CIFAR -10 具有相同的类别数量，但样本数量较少。从头开始使用简化网络训练High-10已极具挑战性。表2中的消融实验表明，与端到端训练相比，该迁移学习方法将性能提升40%至66%，再次证实了迁移学习的有效性。

针对High-10数据集的MAC运算与 CIFAR -10数据集完全相同，因为两者采用了相同的CNN架构。与原始CNN相比，我们的混合CNN在训练（测试）准确率上显著下降了约21.85%（约25.22%）。这些性能损失主要发生在网络压缩阶段，因为卷积层和全连接层是针对 CIFAR -10数据集进行优化的。尽管如此，通过迁移学习和光学编码器，我们的模型仍实现了约60%的分类准确率，优于其他自由空间光学神经网络¹⁷。需要强调的是，光学前端保持不变，仅对数字后端（包含两个全连接层和一个额外的迁移学习层）进行了微调，这充分展现了我们混合CNN系统的多功能性。

我们当前的方法在迁移学习方面仍落后于AlexNet。为进一步提升性能，我们提出了若干潜在的设计改进方案与训练策略。从设计角度而言，引入额外的光学核可能是一个解决方案。在满足物理限制的前提下，可通过使用多台相机对应不同光学核，或对元表面进行改造（例如.....）。通过旋转这些卷积核）同时仅使用单个摄像头即可实现。从训练角度来看，采用先进的知识蒸馏方法能更准确地表征AlexNet网络。某些卷积核可与电子CNN的浅层特征相匹配，而其他卷积核则专注于捕捉更深层的特征。

能源消耗

在实际应用中，我们通过在成像过程中用元光学技术替代传统光学元件，实现了混合式光学/数字卷积神经网络（CNN）。这种设计使得能耗仅取决于MAC运算次数，但还需考虑传感器的功耗。由于我们依赖环境光——这与现实世界中的计算机视觉任务类似——因此无需额外配置输入光源。传感器的功耗取决于其传输至数字后端的像素数量：传统CNN仅需32×32像素即可完成图像采集；而混合式CNN在生成单张卷积图像时（需采用平均池化技术，具体细节见补充材料），需要6×6像素，最终所有正负核的像素总数达到32×6×6。因此，与原始CNN相比，我们的混合CNN在成像过程中需要更多像素。

我们使用的彩色相机（Allied Vision Prosilica; GT1930C）总功耗为3.4瓦，帧率为50.70帧/秒，分辨率为1936×1216像素，每帧每像素能耗为28纳焦耳。由于我们同时采集了全部约200万像素并裁剪了感兴趣区域，单张输入图像的能耗因此降低。

原始CNN与混合CNN在能耗方面并无差异。然而，如果我们能够优化传感器配置和像素数量，就可以计算出原始CNN和混合CNN所需的最小像素数量，并据此估算其能耗。对于原始CNN，相机需要32×32个彩色像素；而对于混合CNN，相机则需要32×6×6个彩色像素——其中32代表复用元光学单元的数量，6×6则对应平均池化后的像素数量。当卷积运算通过光学方式实现时，我们仅需6×6个像素而非32×32个像素。因此我们估算，原始CNN和混合CNN的能耗分别约为29.1单位和32单位。单张图像的捕获过程分别消耗8 μJ 的能耗。然而，与混合CNN相比，原始CNN的计算后端能耗要高得多。对于最先进的计算系统，单次MAC操作的能耗可能低至约1 pJ^{30,47}。因此，混合CNN执行单次物体分类任务的能耗约为150 nJ，比原始CNN的3.65 mJ降低了四个数量级以上。不过，我们使用的GPU（GeForce RTX 2080 Ti）单次MAC操作的能耗更高（约30 pJ），导致混合CNN和原始CNN在单次物体分类任务中的数字计算能耗分别为4.62 μJ 和112 mJ。考虑到传感器功耗，单次物体分类任务的系统级总能耗从3.68 mJ降至0.03 mJ；而使用我们的GPU时，能耗从112 mJ降至37.4 μJ（表4）。表4还详细列出了经过网络压缩（通过知识蒸馏技术实现）后的系统级能耗对比结果。与我们原先使用的GPU相比，该方案仍展现出明显优势。需要指出的是，我们可以通过减少核心数量来降低传感器功耗，同时通过增加多址接入（MAC）操作来提升后端计算性能。然而，在光学编码器中增加运算量并搭配简洁的后端计算架构，始终是降低延迟的更优选择。需要特别强调的是，即使某些应用场景的准确率会有所下降，系统级计算机视觉任务能耗降低超过两个数量级，在实际应用中仍能带来显著效益。

改进的机会

尽管当前的混合CNN已达到具有竞争力的性能，但与压缩CNN相比仍存在显著差距（约4.4%）。通过采用更复杂的点扩散函数（PSF）设计，可以缓解这一差异——该设计能提升光学处理能力并减少信息损失。通过利用具有改进相位和振幅控制功能的复杂元原子，该光学系统能够更精确地模拟理想的卷积运算，从而缩小性能差距。此外，原始CNN与其压缩版本之间仍存在性能差异。为解决这一问题，我们可以采用先进的知识蒸馏技术来提升压缩模型的学习效率⁵¹⁻⁵³。通过结合改进的点扩散函数设计与先进的知识蒸馏方法，我们的方案能够有效弥合这些差距。虽然增加核的数量也能实现性能提升，但会相应增加图像采集所需的像素数量。

图3 c清晰地展示了真实卷积核与实验测量得到的点扩散函数（PSF）之间的显著差异。其他

除制造缺陷和光学对准偏差外，我们还确定了导致该差异的另外三个原因。

1. 针对散射体相位的拟合函数并不完美：我们假设散射体具有恒定的透射率且其相对相位不存在任何共振特征，但这一假设并不完全准确（图2b）。
2. 多色点扩散函数（PSF）的超表面自由度有限：我们针对红色、绿色和蓝色三种不同的PSF分别优化了各超表面。同一矩形散射体在三种颜色下的相位分布彼此并不独立。一种解决方案是采用复杂形状的散射体或超单元结构，以获得更多的自由度。
3. 宽带光源：我们模拟了多色超表面在三个离散波长（450、532和635纳米）下的表现。然而，OLED像素的波长范围要宽得多。若针对更具代表性波长对超表面进行优化，便可缩小这一差异。

然而，本文针对 CIFAR -10数据集报告的分类准确率相较于光学神经网络领域的其他研究成果具有显著优势。由于场景的光谱信息会随日光、云层、飞行角度等多种条件不断变化，光学实现方案必然存在缺陷。我们的实验结果表明，数字后端能够有效补偿光学实现的非理想性，从而实现相对较高的分类准确率⁵⁴。

应用程序

与原始CNN相比，混合CNN在延迟和能耗方面具有显著优势。此外，该架构可无缝集成到商用成像系统（如相机）中，仅需对镜头进行PSF工程化元光学元件的改造，无需修改其他物理结构。更重要的是，其彩色图像编码能力为实际场景应用提供了广阔前景。然而，在安全至关重要的场景（如自动驾驶汽车）中，精度的牺牲是绝对不可接受的。换句话说，如果将目标分类应用于统计分析（此时集成平均法能够最小化个体的不准确性），我们就可以接受分类准确率的下降。栖息地监测无人机就是一个典型例子^{55,56}。特别是对于无人机而言，减轻重量至关重要，这要求其仅存储必要的特征信息。这样一来，现场数据处理便更具优势。由于我们的光学编码器能显著降低现场数据处理的延迟和能耗，栖息地无人机单次飞行即可覆盖更广阔的区域。

另一方面，实时运行与低延迟仍是人工智能领域最严峻的挑战之一。我们提出的混合光/数字架构将数字运算量降低了四个数量级以上，从而显著降低了功耗与延迟。因此，该方案有望对视频会议领域产生深远影响，尤其适用于非安全关键场景。

本研究结果提供了有力证据，表明光学前端能够显著降低计算机视觉任务中人工神经网络（ANN）的功耗与延迟。尽管光学实现过程中存在实际制造和测量误差，但通过添加校准层和可训练的全连接层，该方法在多通道 CIFAR -10数据集上实现了当前最先进的分类准确率。利用单一元光学层执行复杂的多通道卷积运算，凸显了元光学技术的独特适用性——这是传统光学技术无法实现的。此外，我们采用迁移学习方法解决了现有光学实现方案可重构性不足的问题，并将针对 CIFAR -10优化的光学前端适配至High-10数据集。基于此，我们建议采用混合式解决方案。

该系统由光学前端和可重构数字后端组成，充分利用了光学技术的关键优势（即无延迟、无信号损失、大空间带宽），同时后端提供了系统的鲁棒性和可重构性。

方法

知识蒸馏

通常，知识蒸馏算法的设计初衷是用于压缩神经网络。本文提出利用知识蒸馏技术，将来自规模更大、经过预训练的教师网络AlexNet的通用知识迁移至更为紧凑的CNN网络——即“学生网络”。具体而言，学生网络仅包含一个卷积层及后端模块：后端由一个全连接层和一个线性校准层组成。我们选择AlexNet作为教师网络主要基于两个原因：首先，AlexNet是成功解决ImageNet数据集挑战的基础模型；其次，与ResNet-18或VGG-16等更复杂的网络相比，五层结构的AlexNet更易于实现且更便于光学实现。

知识蒸馏算法包含两种损失函数：学生损失（student loss）和温度损失（temperature loss）。学生损失旨在最小化学生网络预测结果与真实标签之间的差异。计算时采用softmax函数：

$$p_i^{\text{student}} = \frac{\exp(z_i)}{\sum \exp(z_i)} \quad (5)$$

其中 z_i 表示学生在最后一个全连接层后的逻辑值。另一方面，温度损失函数能够优化学生网络预测结果与教师网络预测结果之间的差异。知识蒸馏方法引入了一个称为“蒸馏温度”的软化参数 T ，用于调整教师网络输出的概率分布。因此，该损失函数可表示为：

$$p_i^{\text{temperature}} = \frac{\exp(y_i/T)}{\sum \exp(y_i/T)} \quad (6)$$

最终，总损失通过两种损失的加权求和计算得出：

$$\mathcal{L}(x, \Phi) = \alpha \mathcal{L}_C(y, p^{\text{student}}) + (1 - \alpha) \mathcal{L}_K(p^{\text{temperature}}; T = \tau, p^{\text{student}}; T = \tau) \quad (7)$$

其中 α 是用于平衡两个损失分量的权重， $\mathcal{L}_C$ 是交叉熵损失函数， $\mathcal{L}_K$ 是库尔巴克-莱布勒（KL）散度损失函数⁵⁷。

我们还发现，其他关键超参数也可能影响我们的混合CNN系统。首先，在大多数CNN模型（如ResNet-18和AlexNet）中，通常包含多个卷积层，每层配备超过200个卷积核，用于提取有效特征并确保在不同数据集上的泛化能力。尽管某些剪枝策略表明，仅使用1%的参数即可达到相近的准确率⁵⁸，但将这些算法应用于光学神经网络并非易事。大多数剪枝方法仍保留人工神经网络的结构，而这种结构存在的对齐偏差几乎无法消除³⁵。因此，采用更薄的层结构并增加核的数量是更优的选择。然而，每个超表面的物理尺寸限制了其可容纳的核数量。为克服这一限制，我们可以使用多台相机和多个超表面来增加核的数量，从而提升混合CNN的分类准确率和泛化能力。

元光学设计

对于每个R、G和B通道的16个数字内核，我们共获得32个元光学内核，因为所有RGB通道均采用相同的元光学技术。

我们无法通过光学手段同时实现正负权重的表征。因此，我们分别创建了16个正核和16个负核，随后在数字后端进行数字减法运算。每个卷积元光学系统包含3200×3200个散射体，其中2×2个散射体组成一组，以增强制造工艺的鲁棒性。基于真实的数字卷积核数据，我们为每个RGB通道定义了光学点扩散函数（PSF），并利用TensorFlow Adam优化器逆向设计出在各RGB波长下均能实现这些PSF特性的元光学系统。

元光学器件制造技术

我们的超光学器件工作在可见光波段（ λ 约400纳米至700纳米）。我们采用石英基底上的氮化硅材料，以确保器件在整个可见光范围内具有高透明度。通过等离子体增强化学气相沉积技术（Oxford; Plasma Lab 100），在双抛石英基底表面沉积了一层800纳米厚的氮化硅层。随后，在氮化硅层上旋涂并烘烤电子束光刻胶（ZEP-520A），再旋涂抗充电剂（DisCharge H2O）。我们采用电子束光刻技术（JEOL; JBX 6300FS）进行图案制备，并使用乙酸戊酯配制光刻胶。随后，通过电子束蒸发法（CHA; SEC-600）沉积金属通孔，并剥离约65纳米厚的氧化铝层作为硬掩模。最后，利用基于氟化物气体的等离子体刻蚀机（Oxford; PlasmaLab 100, ICP-180）在氧化铝硬掩模下对氮化硅进行刻蚀。该亚波长结构的超光学元件周期为293纳米，相当于图像采集相机像素尺寸的二十分之一。

光学测量

我们通过放置激光器和代表点光源的针孔（ $\phi = 25 \mu\text{m}$ ）来测量点扩散函数（PSF）。随后，将卷积式超光学系统安装在带有旋转调节旋钮的三轴平台上，使其中心对准并平行于光束路径，与针孔保持约105毫米的距离。高分辨率彩色相机（GT-1930C，像素尺寸为 $5.86 \mu\text{m}$ ）置于距超光学系统约2.46毫米的位置。通过更换三种不同波长的激光器（Thorlabs品牌：CPS450、CPS532和CPS635），分别测量了每种RGB颜色光的PSF。对于CIFAR-10数据集的图像卷积测量，我们将微型显示器置于针孔位置，然后连接计算机以显示彩色图像。由于单个超光学系统可同时表示三种不同的RGB内核（详见补充信息），具有RGB彩色像素的彩色相机能够提取三个不同通道的卷积图像。这最终可节省超光学系统和相机的空间，这对实际应用至关重要⁵⁹。点光源被任意二维图像 $f(x, y)$ 所替代。我们可以将图像表示为三个颜色通道之和： $f_R(x, y) + f_G(x, y) + f_B(x, y)$ 。卷积超光学系统对每种颜色分别进行卷积运算，最终得到的卷积图像 $\sum_{i=R, G, B} f_i(x, y) * PSF_i(x, y)$ 会通过相机成像。由于输入图像尺寸较小，且超表面与相机之间的距离较近（约2）。与显示器和超表面之间的距离（约105毫米）相比（显示器与超表面间距为46毫米），超表面的空间分布对卷积结果影响甚微。由于我们已确定点扩散函数（PSF）的放大系数为2，因此在CIFAR-10图像中也采用了相同的放大系数。根据相机像素尺寸5.86微米和CIFAR-10图像尺寸32×32，投影到相机上的图像尺寸约为 $374 \times 374 \mu\text{m}^2$ 。在给定的显示器与超光学系统、以及超光学系统与相机之间的距离条件下，显示器上的CIFAR-10图像尺寸最终可达 $16.0 \times 16.0 \text{mm}^2$ 。我们使用10,000张图像进行训练（原始50,000张图像的子集）和10,000张图像进行测试，曝光时间为500毫秒。在训练集和测试集的10,000张图像中，分别有186张和201张因过曝问题未被纳入训练和测试数据。用于迁移学习过程的High-10数据集的所有测量参数和图像数量均保持一致。

另一个关键因素是曝光时间。由于光学特征是通过CCD相机捕捉的，曝光时间会显著影响最终成像效果。如果光学特征曝光过度，猫毛等纹理信息可能会丢失；反之，若曝光不足，大部分细节也会消失，导致图像中高光与阴影之间的区分度降低。为了找到最佳曝光参数，我们可以借鉴现代相机的做法——将“18%灰”视为对数或指数曲线中黑白之间的中点。这一标准有助于实现均衡曝光，确保捕捉到的光学特征既不过曝也不欠曝。

计算后端

如前所述，光学制造和对准噪声在超表面核中不可避免，这些噪声包括缩放、平移、旋转、像差以及光学噪声。为解决这一问题，我们提出添加一个校准函数，将光学卷积输出重新映射，使其与先前训练好的后端模型的输出对齐。具体而言，我们采用全连接层作为校准函数，相应的损失函数定义如下：

$$\mathcal{L} = \min(f_{\text{calibrate}}(\text{混合光学/数字 CNN, 压缩 CNN}))(8)$$

该方法旨在优化实验输出，使其更贴近预先设计的网络模型。为防止过拟合，我们战略性地将训练数据限制在可用数据的20%，从而确保模型保持高效⁶⁰。

迁移学习

泛化能力是我们混合光学/数字卷积神经网络（CNN）的核心测试指标。确保网络能有效泛化到新的、未见过的数据集至关重要，原因有以下几点：首先，我们的混合网络是从AlexNet架构演变而来——而AlexNet最初是基于大规模数据集设计的。经过预训练的AlexNet在多种数据集上均能保持高准确率，并且能够轻松适应或微调以处理分布外的数据集。这种适应性对于实际应用尤为重要，因为在实际应用中，数据分布可能与训练集存在显著差异。其次，探究混合模型的泛化能力至关重要，因为为不同任务设计和制造不同的超表面核效率低下。通过提升泛化能力，我们可以使用单一混合模型完成多种任务，从而减少大量重新设计和制造的需求。我们的迁移学习方案的具体细节及示意图详见补充信息。

为实现迁移学习，我们引入了两种损失函数：特征损失和标签损失。特征损失旨在最小化光学特征与数字特征之间的差异，确保光学组件与数字组件所学习到的表征保持一致；标签损失则用于缩小模型预测结果与实际标签之间的偏差，从而提升整体预测精度。在迁移学习过程中，光学前端和数字后端保持不变。我们在光学前端与后端之间添加了两个全连接层，并利用这两种损失函数对这些层进行微调。具体而言，其函数表达式如下：

$$\mathcal{L} = \alpha \mathcal{L}_{\text{特征}} + \beta \mathcal{L}_{\text{label}} \quad (9)$$

在哪里 $\mathcal{L}_{\text{feature}}$ 表示特征损失， $\mathcal{L}_{\text{label}}$ 表示标签损失，其中 α 和 β 分别是用于平衡这两种损失的权重。

报告摘要

有关研究设计的更多信息，请参阅本文所附的《Nature Portfolio报告摘要》。

数据可用性

支持本研究结论的所有数据均收录于文章及其补充信息中，或可根据要求向通讯作者索取。部分数据因存在利益冲突而受到限制。

代码可用性

用于多色PSF工程化元光学设计的代码可在Zenodo获取：<https://doi.org/10.5281/zenodo.15741412>。

参考文献

1. Thorpe, S., Fize, D. & Marlot, C. 人类视觉系统中的信息处理速度。《自然》381卷, 520–522页 (1996年)。
2. Graimann, B., Allison, B.Z. & Pfurtscheller, G. 大脑-计算机接口：革新人机交互 (2010)。
3. De Cesare, A., Loftus, G. R., Mastria, S. & Codispoti, M. 理解自然场景：图像统计学的贡献。Neurosci. Biobehav. Rev. 74,44–57 (2017)。
4. Iacarus, M. F., Gasler, I. T. & Hofer, S. B. 初级视觉皮层中视觉空间的突触组织。《自然》547卷, 449–452页 (2017年)。
5. Nassi, J. J. & Callaway, E. M. 品目类灵长动物视觉系统的并行处理策略。《自然·神经科学评论》(Nat. Rev. Neurosci.) 第10卷, 第360–372页 (2009年)。
6. 杨志等人。一种具有互补路径的开放世界感知视觉芯片。《自然》629卷, 1027–1033页 (2024年)。
7. Gehrig, D. & Scaramuzza, D. 基于事件相机的低延迟汽车视觉。《自然》629卷, 1034–1040页 (2024年)。
8. Li, W. 等。基于计算机视觉的智能超表面系统,用于移动目标的自动跟踪及无线通信。《自然·通讯》第14卷,第989页(2023年)。
9. Siemenn, A. E. 等。利用可扩展的计算机视觉技术实现半导体高通量表征的自动化。《自然·通讯》第15卷,第4654页(2024年)。
10. Yang, Y. 等。用于智能机器视觉的传感器内动态计算。《自然·电子》第7卷,第225–233页(2024年)。
11. Woodget, A. S., Austrums, R., Maddock, I. P. & Habit, E. 无人机与数字摄影测量：从分类到连续谱——用于河流栖息地与水文地貌监测。Wiley Interdiscip. Rev.: Water 4,1222 (2017)。
12. 张, T. 向自动驾驶车辆远程操控迈进：愿景、机遇与挑战。IEEE物联网杂志。7(12) (2020)。
13. 吴Y.等人。疲劳状态下的驾驶员手足协调性与全脑-区域脑功能连接：基于图论与可解释人工智能的研究。IEEE智能车辆汇刊 (2023年)。
14. McMahon, P. L. 光学计算的物理学原理。《自然·物理评论》第5卷, 第717–734页 (2023年)。
15. Wang, X. 等。用于低功耗高速图像处理的集成光子编码器。《自然·通讯》第15卷,第4510页(2024年)。
16. Chen, Y. 等学者提出的基于光子学的无监督学习变分自编码器,适用于高通量,低延迟的图像传输。《科学进展》第9卷,第8437页(2023年)。
17. Xue, Z. 等。光学神经网络的全前向模式训练。《自然》632卷,280–286页(2024年)。
18. Chen, Y. 等。用于高速视觉任务的全模拟光电芯片。《自然》623卷,48–57页(2023年)。
19. Lin, X. 等。基于衍射深度神经网络的全光学机器学习。《科学》361卷,1004–1008页(2018年)。
20. Chen, Z. 等。基于相干VCSel神经网络的深度学习。《自然·光子学》第17卷,第723–730页(2023年)。
21. 徐X.等人。11种适用于光学神经网络的顶级光子卷积加速器。《自然》589卷, 44–51页 (2021年)。
22. Bernstein, L. 等。单次激发光学神经网络。《科学进展》第9卷,第7904
24. 夏, F. 等。基于循环线性散射实现的非线性光学编码。《自然·光子学》, 第1–9页 (2024年)。
25. Bai, B. 等学者。基于单像素衍射网络的未知随机扩散器全光学图像分类方法。《Light: Sci. Appl.》12卷,第69页(2023年)。
26. Huo, Y. 等。基于松散神经元阵列与功能学习的光学神经网络。《自然·通讯》第14卷,第2535页(2023年)。
27. Rahman, M. S. S. & Ozcan, A. 基于衍射神经网络的延时图像分类。Adv. Intell. Syst. 5,2200387 (2023)。
28. 杨, M.; 罗伯逊, E.; 埃斯格拉, K.; 布施, K.; 沃尔特斯, J. 基于原子非线性的光学卷积神经网络。《Opt. Express》31卷, 16451–16459页 (2023年)。
29. Ryou, A. 等。基于热原子非线性的自由空间光学神经网络。《光子研究》第9卷,第128–134页(2021年)。
30. Wang, T. 等。基于多层非线性光学神经网络的图像传感技术。《自然·光子学》第17卷,第408–415页(2023年)。
31. Jang, H. & Tong, F. 通过在卷积神经网络中引入对模糊的鲁棒性来改进人类视觉建模。Nat. Commun. 15,1989 (2024)。
32. 季一、张浩、张志和刘明。基于CNN的编码器-解码器网络在显著目标检测中的应用：综述与最新进展。《信息科学》546卷, 835–857页 (2021年)。
33. Xiang, J., Colburn, S., Majumdar, A. & Shlizerman, E. 知识蒸馏技术规避光学卷积神经网络的非线性特性。Appl. Opt. 61,2173–2183 (2022)。
34. Goodman, J.W. 《傅里叶光学导论》(2005)。
35. Wirth-Singh, A. 等。用于图像分类的压缩元光学编码器。《先进光子学汇刊》第4卷,026009–026009页(2025年)。
36. Yang, J., Yu, K., Huang, T. 监督式翻译不变稀疏编码。载于：2010年IEEE Computer Society Computer Vision 与 Pattern Recognition 会议, 第3517–3524页 (2010)。
37. Krizhevsky, A. 等。从微小图像中学习多层特征 (2009)。
38. Coates, A., Ng, A. & Lee, H. 无监督特征学习中单层网络的分析。载于：第十四届国际人工智能与统计学会议论文集, 第215–223页 (2011年)。
39. Anderson, M., Ma, S.-Y., Wang, T., Wright, L. & McMahon, P. 光学变压器。《机器学习研究汇刊》(2023)。
40. 周, F. & 柴, Y. 近传感器与传感器内计算。《自然·电子》3, 664–671 (2020)。
41. Tara, V. 等学者。基于宽带隙相变材料硫化锑的非易失性可重构透射型陷波滤波器。《IEEE量子电子学精选专题期刊》(2024年)。
42. Kang, D. 等。用于主动光子平台的液晶集成超表面。《光电进展》, 230216–1(2024)。
43. Hinton, G., Vinyals, O., Dean, J.: 从神经网络中提炼知识。arXiv预印本 arXiv:1503.02531 (2015)。
44. Chang, J., Sitzmann, V., Dun, X., Heidrich, W. & Wetzstein, G. 采用优化衍射光学技术的混合光子卷积神经网络在图像分类中的应用。Sci. Rep. 8,1–10 (2018)。
45. 岛根, T.; 松岛, K.; 角越, T.; 正田, N.; 伊藤, T. 缩放角度谱法。《光学快报》第37卷, 第4128–4130页 (2012年)。
46. 开发者, T.: TensorFlow. Zenodo (2022)。
47. Huang, L. 等。光学编码器的光子学优势。《纳米光子学》13卷, 1191–1196页(2024年)。
48. Wei, K. 等。空间可变纳米光子神经网络。《科学进展》第10卷,第0391页(2024年)。
49. Huang, L. 等人。基于元光学的宽带热成像技术。《自然·通讯》第15卷, 第1662页(2024年)。

- 页(2023年).
23. Xu, Z. 等学者研究指出:大规模光子芯片技术可实现每秒160次运算的人工通用智能.《科学》杂志第384卷,第202–209页(2024年).
50. Kim, Y., Rush, A.M.: 序列水平知识蒸馏。载于《2016年自然语言处理实证方法会议论文集》，第1317–1327页（2016年）。
51. 田Y、Krishnan D、Isola P: 对比表征蒸馏。arXiv预印本 arXiv:1910.10699（2019）。

52. Zagoruyko, S., Komodakis, N.: 更加关注注意力机制：通过注意力迁移提升卷积神经网络性能。arXiv预印本 arXiv:1612.03928 (2016)。
53. Park, W., Kim, D., Lu, Y., Cho, M.: 关系知识蒸馏。载于：IEEE/ CVF 计算机视觉与模式识别会议论文集，第3967–3976页（2019年）。
54. Audhkhasi, R., Froch, J.E., Zhan, A., Colburn, S., Majumdar, A.: 软件定义的元光学系统。《应用物理快报》**123**(15) (2023)。
55. Koger, B. et al. 利用无人机和计算机视觉量化群居动物的运动, 行为及环境背景。《动物生态学杂志》(J. Anim. Ecol.)第92卷,第1357–1371页(2023年)。
56. 查尔默斯 (C. Chalmers)、弗格斯 (P. Fergus)、库贝洛-蒙塔涅斯 (C. A. Curbelo Montanez)、朗莫尔 (S. N. Longmore) 与威奇 (S. A. Wich): 基于卷积神经网络与消费级无人机的视频分析技术用于动物检测。《无人飞行器系统杂志》第9卷, 第112–127页 (2021年)。
57. Seo, G., Yoo, J., Cho, J. & Kwak, N. 提出的基于K1散度的区域提议网络用于目标检测。载于：2020年IEEE International Conference on Image Processing (ICIP), 第2001–2005页 (2020年)。
58. 梁, T.; 格洛斯纳, J.; 王, L.; 史, S.; 张, X. 深度神经网络加速中的剪枝与量化：综述。Neurocomputing 461,370–403 (2021)。
59. Froch, J. E. 等. 超大孔径宽带纳米光学技术突破频谱带宽极限。《自然·通讯》第16卷, 第3025页 (2025年)。
60. 郑Y、向J、苏K与Shlizerman E. Bi-maml: 元学习的平衡增量方法。arXiv预印本 arXiv:2006.07412 (2020)。

致谢

本研究由美国国家科学基金会（项目编号：efribraid-2223495）资助。部分研究工作在华盛顿大学的华盛顿纳米制造设施/分子分析设施完成，该设施隶属于国家纳米技术协调基础设施（NNCI）体系，研究工作部分获得美国国家科学基金会通过资助项目 NNCI -1542101和 NNCI -2025489提供的支持。S.-H.B.感谢韩国国家研究基金会（NRF）提供的资助（项目编号：RS-2023-00211658、RS-2024-00438532），该资助由韩国科学技术信息通信部（MSIT）及教育部共同提供。

作者贡献

M.C.与J.X.对本研究贡献相当。A.M.与E.S.提出了研究构想并提供了资金支持。A.W.S.参与了PSFengineering方法的开发。J.X.与E.S.开发了知识蒸馏方法。J.X.训练了神经网络并分析了实验数据。M.C.开发了多色点扩散函数（PSF）工程工具。

M.C.提出了方法并设计了超光学器件；M.C.负责超光学器件的制备及光学实验的开展；S.H.B.对结果分析提供了指导；M.C.、J.X.和A.M.在全体作者的共同参与下撰写了论文。

竞争性利益

A.M.是Tunoptix公司的联合创始人，该公司致力于将元光学技术商业化。其余作者声明无利益冲突。

更多信息

补充信息：在线版本包含补充材料，可访问<https://doi.org/10.1038/s41467-025-61338-4>获取。

所有函件及材料索取请求均应发送至 Minho Choi、Eli Shlizerman 或 Arka Majumdar。

《自然·通讯》感谢Fion Yeung及其他匿名审稿人对本研究的同行评审工作所作出的贡献。相关同行评审文件已可供查阅。

重印及授权信息可在以下网址获取：
<http://www.nature.com/reprints>

出版商声明：Springer Nature 对已发布的地图及机构隶属关系中的管辖权主张保持中立立场。

开放获取 本文依据知识共享署名-非商业性使用-禁止演绎 4.0 国际许可协议授权。该许可允许在任何媒介或格式下进行非商业用途的使用、分享、分发及复制，但须满足以下条件：正确标注原作者及来源信息、提供知识共享许可协议链接，并注明是否对授权材料进行了修改。根据本许可协议，您无权分享基于本文或其部分内容改编的衍生材料。文中使用的图片及其他第三方素材.....

本文中的派对素材均包含在文章的创意部分中。

除非材料的署名许可条款另有说明，否则均采用知识共享许可协议。如果材料未包含在文章的知识共享许可协议中，且您的使用目的不符合法定规定或超出许可范围，则需直接向版权持有人申请授权。如需查看该许可协议副本，请访问<http://creativecommons.org/licenses-by-nc-nd/4.0/>。

© 作者 2025