

研究文章

开放获取

基于元光学超宽神经网络实现的高度可扩展机器视觉



罗明成¹、蒋美瑞²、巴文·J·沙斯特里³、周南森⁴、郭文飞¹、熊建民¹、王东亮¹、周仁杰⁴、舒切斯特¹、窦琪²与黄朝然^{1*} 

摘要

光学神经网络 (ONNs) 为实现低延迟、节能的人工智能提供了途径, 但将其扩展到现代模型规模时面临两大实际瓶颈: 训练大规模ONNs在计算资源上成本过高; 而实现或调校数百万个光学元件极易受到制造缺陷和对准误差的影响。本文提出一种基于超表面的光学学习机, 通过在超宽参数范围内运行成功规避了这些障碍。我们采用具有4100万个光学参数的超表面构建超宽神经网络, 并证明在此尺度下, 未经训练的固定超表面能够高度近似完全训练好的网络。残余参数失配通过仅含 10^2 至 10^4 个可训练参数的紧凑数字后端进行补偿, 从而无需重新训练或重新制造超表面即可实现任务适应性调整。实验表明, 该混合系统可在六项任务中实现可扩展的机器视觉性能, 其准确率与ResNet和Vision Transformer等最先进模型相当, 同时对制造缺陷和对准误差具有良好的容忍度。我们的方法具有高度可扩展性, 能有效应对制造误差, 并能在相干与非相干光照条件下运行, 为大规模、高性能的光学人工智能计算提供了切实可行的解决方案。

关键词 光学神经网络、神经形态计算、机器视觉

1 引言

神经网络 (NNs) 已成为跨多个科学和技术领域的强大工具, 在药物发现、图像处理、自动驾驶汽车和医学诊断等领域引发了革命性变革[1]。然而, 其复杂性日益增加。

这些问题导致训练和推理神经网络模型的成本每两个月翻一番[2], 其增速远超互补金属氧化物半导体 (CMOS) 电路的技术进步。光神经网络 (ONNs) 因光波固有的高度并行性, 在应对上述挑战方面极具潜力[3–46]。通过利用这种并行特性, ONNs能够实现显著的能效提升与运算速度优势。

尽管光学神经网络 (ONNs) 在理论上具有巨大潜力, 但当前的实际应用扩展参数数量方面仍面临诸多挑战。二维 (2D) 集成式ONNs能够实现高速计算, 但由于光学元件体积庞大、插入损耗较高, 以及控制这些元件的复杂性, 其可集成的组件数量受到限制。通过转向三维自由空间光学技术, 光学中的空间并行性使得

*通信:

黄朝然

crhuang@ee.cuhk.edu.hk

¹ 香港中文大学电子工程系, 香港新界沙田

² 香港中文大学计算机科学与工程系, 香港新界沙田

³ 加拿大安大略省金斯顿市巴德巷64号 (邮编: K7L3N6), 女王大学物理、工程物理与天文学系纳米光子学中心

⁴ 香港中文大学生物医学工程系, 香港新界沙田

© 作者 2026。开放获取本文依据知识共享署名 4.0 国际许可协议授权, 允许在任何媒介或格式中进行使用、分享、改编、分发和复制, 前提是您需适当注明原作者及来源、提供知识共享许可协议链接, 并说明是否进行了修改。本文中的图像或其他第三方材料均包含在文章的知识共享许可范围内, 除非材料的致谢行另有说明。若材料未包含在文章的知识共享许可范围内, 且您的使用意图不符合法定规定或超出许可范围, 则需直接向版权持有人申请许可。如需查看该许可协议副本, 请访问<http://creativecommons.org/licenses/by/4.0/>。

参数数量显著增加[5]。实验演示已成功实现约10万次标量乘法运算[39–46]。然而, 当前模型的参数数量仍远低于现有AI模型——后者可能拥有数百万至数十亿个参数[47, 48]。

要进一步扩大光学神经网络(ONNs)的应用规模, 一个颇具吸引力的解决方案是采用光学超表面——这类结构由高密度的超原子以二维周期性排列方式构成[49–55]。每个超原子均可被精确调控, 从而在亚波长尺度上调节入射光的传输特性。凭借每平方毫米超过400万个超原子的密度, 光学超表面有望实现大规模ONN, 其参数数量接近大型人工智能模型。然而, 当前基于超表面的ONN应用示范所支持的参数数量仍极为有限, 不足100万个[37, 38, 42, 43, 56]。通过梯度下降法训练大规模光学神经网络(ONNs)在计算上具有极高的成本——因为精确计算梯度需要基于复杂物理模型, 这会导致训练耗时漫长、内存消耗巨大以及优化空间庞大。即使完成此类训练, 亚波长尺度上的微小对齐偏差也会导致精度显著下降[57, 58]。此外, 由于超表面通常不具备可编程性, 每完成一项新任务都需要重新训练并制造新的超表面芯片, 这限制了其在实际应用中的普及。

替代性计算范式可以消除对大规模训练的需求。例如储层计算[59–75]、极端学习机[76–80]以及随机投影[68, 81–83]。这些计算系统将固定的光学系统作为光学前端, 与可训练的数字层作为后端相结合。仅需训练数字层即可使整个计算系统适应各种下游任务。然而, 当前的演示大多依赖于光学系统的固有物理特性。光学前端的性能无法得到保证, 因此其整体性能往往无法媲美经过充分训练的神经网络。为弥补光学前端性能的不足, 需要采用规模过大的数字神经网络, 这反而削弱了光学技术本应具备的能量效率与运算速度优势。

为解决这些局限性, 本研究采用了一个由4100万个元原子组成的大型光学超表面来实现光学前端, 其设计灵感源自极端学习机(ELM)[84–86]。在经典的ELM中, 网络仅包含一个隐藏层, 其参数被随机初始化后保持固定, 而仅对输出层进行训练。后续变体通过修改该框架进一步扩展了其功能。

网络深度与架构结构。ELM的性能取决于隐藏层的宽度: 增加隐藏神经元的数量可提升表征能力并提高准确率[35, 87–90]。因此, 我们利用由4100万个元原子构成的光学超表面来实现超宽隐藏层, 其后接一个超紧凑的数字神经网络作为输出层。这些组件共同构成了混合ELM架构: 该架构既利用超表面的海量光学并行性实现高容量特征提取, 又保留了数字灵活性以支持任务特定学习。此外, 基于神经切线核(NTK)框架[91]——该框架为广义神经网络的动力学特性提供了理论支撑——我们采用方差经过适当选择的高斯分布来初始化权重(方差选择方法详见补充说明2)。在此框架下, NTK理论预测训练过程仅会对隐藏层参数产生微小调整; 因此, 固定光学前端结构仅训练紧凑型数字神经网络, 即可实现接近最优的任务特定学习效果, 优于完全训练的系统。与这一预测一致, 我们的混合系统采用仅包含102至104个可训练参数的数字神经网络(NN), 成功解决了六项多样化任务, 并实现了超越以往全连接神经网络(ONNs)的准确率, 其性能与ResNet和Vision Transformer等领先视觉模型相当。这些应用涵盖大规模乳腺癌诊断和病灶定位等实际场景。表S9(见补充说明27)详细列出了本系统与其他现有ONNs的对比结果。

从实际应用角度来看, 我们基于超表面的混合系统无需对单个元原子进行精确训练。此外, 该系统对制造缺陷和对准误差具有极强的容错能力, 因为这些影响可通过重新训练紧凑的数字神经网络(NN)轻松得到补偿。这些特性带来了显著的可扩展性优势: (1)该系统能自然扩展至高分辨率输入——例如对超过 10^6 像素的医学图像进行端到端处理; (2)它可轻松扩展至更复杂的神经网络架构: 例如, 我们实现了采用该混合系统作为内部状态的循环神经网络(RNN), 其性能达到99%。在动作识别任务中, 该系统的准确率达到1%。此外, 我们的系统可在相干与非相干光照条件下运行, 从而将其应用范围扩展至依赖相干光的传统光学神经网络(ONN)之外。由于超过99.99%的计算由光学超表面被动完成(具体推导过程详见补充说明4), 该系统实现了卓越的能效性能。

高效且延迟低。总体而言, 我们的系统为高性能光学人工智能计算提供了极具实用性的解决方案。

2 结果

2.1 工作原理与设备设计

图1 a展示了所提出的基于超表面的光学学习机(MOLM)的实现方案。该MOLM由基于超表面的光学前端和一个紧凑型数字神经网络组成, 该神经网络经过训练后能够为各类任务生成预测结果。光学前端采用了一种光学超表面结构, 由 $6,400 \times 6,400 = 4100$ 万个硅圆柱形超原子构成。这些超原子的直径范围在100至400纳米之间, 晶胞周期为500纳米。每个超原子的直径通过两步确定: 首先, 从均值为零、标准差为 4π 的高斯分布中随机采样生成一个 $6,400 \times 6,400$ 矩阵的光学相位调制系数; 随后根据光学相位调制系数与超原子直径之间的映射关系计算出各超原子的直径, 具体方法详见补充说明1。超表面的设计与制造细节详见“方法”部分及补充说明1和3。在超表面与CMOS传感器之间放置了一个光学透镜, 用于执行傅里叶变换, 这进一步增强了网络提取高频特征的能力。该CMOS传感器分辨率为 600×800 , 被置于光学透镜的焦平面上, 通过光电检测技术连接光学前端与数字后端, 并提供平方非线性特性。后续实验均采用532纳米激光二极管作为光源。如讨论部分所示, 本系统亦可在非相干LED照明条件下运行。传感器输出信号在输入数字神经网络前会进行降采样处理以保持数据紧凑性, 网络则基于这些降采样的输出数据进行训练, 最终生成预测结果。

在光检测之前, 输入的光学图像 $\mathbf{U}$ 会经过由 $\mathbf{F}(\mathbf{H} \mathbf{d} \mathbf{U} \mathbf{W})$ 给出的线性变换, 其中 $\mathbf{H} \mathbf{d}$ 是超表面的复值透射矩阵, $\mathbf{F}(\cdot)$ 表示光学透镜实现的傅里叶变换, 而 $\cdot$ 代表哈达玛积。衍射效应诱导了一个有效的 $N \times N$ 全连接网络, 其中 N 是超原子的数量。光检测后, 第 k 个传感器的输出为 像素 是 指定的 通过

$\tilde{u}_k = \left[\sum_{i=k \cdot (R-1)}^{k \cdot R} \mathcal{F}(\mathbf{H}_a \mathbf{U}_0 \otimes \mathbf{W})[i, :] \right]^2$, 其中 R 表示元原子数量与传感器像素数量之比 ($R = N/M$)。该光电探测器采用平方律响应特性。

该运算单元充当ELM隐藏层中的非线性激活单元(神经元), 而后续的数字神经网络则作为ELM的输出层。因此, 从架构上看, 我们的系统等同于一个ELM。有关系统模型的具体差异, 请参阅补充说明5。

为说明参数 N 的重要性, 我们展示了 N 变化时变换后的图像, 如图1 c所示。信息熵已被用于评估神经网络(包括扩展学习机[ELMs])的性能[35, 92, 93]。增加 N 值可显著提升信息熵: 从无超表面时的8.4比特增至包含4100万个元原子时的13比特, 其数值以 $-\mathbf{s}$ 表示。 $\bar{u}_k = \frac{1}{M} \sum_{k=1}^M \bar{u}_k \log_2(\bar{u}_k)$, 其中 $\bar{u}_k = \tilde{u}_k / \sum_{k=1}^M \tilde{u}_k$ [94], 如图1 d所示。此外, 图1 e表明变换后的图像呈现出日益丰富的高频成分; 根据机器学习理论[95], 这使得神经网络能够在低维域中学习高频函数。关于高频成分增强及信息熵的详细解释详见补充说明26。这种捕提高频特征的能力得到提升后, MNIST分类准确率从无超表面结构时的87.3%提升至使用4100万个元原子时的94.7%——即使未使用光学透镜亦然, 如图1 g所示。当引入光学透镜进行傅里叶变换时, 这些高频特征会得到进一步增强, 使得准确率从94.7%提升至99.2%。这一结果是通过将 600×800 传感器阵列的输出进行下采样至 15×20 实现的, 从而构建了一个仅需 300×10 个权重的紧凑型数字神经网络。我们还在更复杂的CIFAR-10数据集上验证了该方法, 观察到类似趋势: 随着光学参数数量增至107个, 准确率持续提升。如图1 h所示, 最终实验准确率达到91.6%, 仅需7,440个可训练数字参数, 与ResNet-50的性能相当。关于MNSIT和CIFAR-10基准测试的详细实验信息可参阅“方法”部分及补充说明16。

我们进一步证明: 当超表面隐藏层包含数千万个参数时, 未经训练的固定超表面其性能可接近完全训练后的超表面。这一结论通过比较具有相同模型架构的未训练网络与已训练网络参数之间的均方根误差(RMSE)得到验证(见图)。1图f表明, 未经训练与已训练光学参数之间的RMSE随光学参数数量 N 的增加而减小。当 N 为4100万时, RMSE从1.02降至0.018。这种缩放行为与NTK理论的预测一致。未经训练与已训练光学前端之间的残差差异可被有效消除。




图 1 基于超表面的光学学习机（MOLM）。**a** MOLM 示意图。SLM 生成的光学图像被投射到由大量圆柱形硅超原子构成的单层超表面上，随后光学透镜收集超表面反射的光学图像，聚焦平面处的光场由图像传感器阵列捕获，最终将捕获的图像输入数字神经网络以生成预测结果。**b** 基于超表面的超宽神经网络示意图。**c** 基于超表面的光学前端处理后的图像随超原子数量 N 的变化关系。**d** 处理后图像的数值分布及信息熵随超原子数量 N 的变化关系。**e** 不同元原子数 N 下变换图像的归一化功率密度随空间频率的变化关系。**f** 训练前后的参数差异（RMSE）与光学参数数量 N 的关系。**g** 不同配置下基于超表面的光学前端的 MNIST 精度。**h** 实验测得的 CIFAR-10 精度随元原子数量的变化关系。

通过一个小型数字神经网络进行补偿。因此，未经训练的网络所达到的整体 MNIST 分类准确率达到 99.2%，与完全训练后的 99.6% 准确率非常接近，如图所示。

图 1 g。此类缩放行为还受到初始化统计特性的影响。当光学参数取自较窄的高斯分布（标准差 = 2π ）或从非高斯分布中提取时……

根据多模光纤的模式耦合理论[76], 未经训练与已训练光学参数之间的 RMSE 值仍随参数数量增加而减小, 但减小速率放缓。这表明初始化统计量是可调的超参数, 可通过优化实现最佳效果, 但这些参数通常基于经验数据, 且取决于具体系统与任务需求。本文设计中选择 $SD=4\pi$ 的参数值, 在补充说明2中得到了进一步论证。

2.2 实验性验证: 高性能、多功能性及实用性

我们首先通过执行机器视觉任务来展示系统的高性能、多功能性和高可扩展性。在基准测试中, 我们将 MOLM 的性能与三种大规模深度学习模型进行了比较: ResNet-50[96]——一个经典的 50 层卷积神经网络, 拥有约 2350 万个参数; Segment Anything 模型 (SAM) [97]——一款先进的大规模可推广分割模型, 参数量达 9370 万个; 以及 Vision Transformer (ViT) [47]——一种用于图像分类的Transformer编码器模型, 参数量超过8500万个。800万个参数 (详见补充说明18)。图2 a展示了基准测试表征实验的装置示意图 (具体方法见“方法”部分及补充说明4)。针对每个任务, 输入图像均通过 SLM 生成; 这些图像经超表面处理后, 由光学透镜采集, 并最终由CMOS数码相机进行检测。检测到的数字图像会经过下采样处理, 其下采样比例因任务而异。所有任务均使用同一块超表面芯片, 仅后端的数字神经网络会针对不同应用场景进行单独训练。

这些任务的选择不仅是为了展示我们的系统能够利用固定的、未经训练的超表面来适应多种应用场景, 还旨在突出其在实际应用中的优势。具体而言, 我们展示了该系统在以下方面的功能: (1)处理方面.....

(1)一款超紧凑型数字神经网络 (用于COVID-19影像诊断); (2)能够一次性处理高分辨率图像 (用于胸部疾病检测); (3)通过仅重新设计一个小型数字神经网络即可实现多任务分类与检测。


2.2.1 基于超紧凑型数字神经网络的图像分类

COVID-19 放射摄影 我们首先在COVID-19放射影像数据集[98]上展示了 MOLM 的应用效果 (如图2 e所示), 充分展现了该模型利用高度紧凑的数字神经网络实现高性能图像分类的能力。该数据集包含超过 20,000 张胸部 X 光 (CXR) 图像, 涵盖正常病例和 COVID-19 阳性病例, 每张图像分辨率为 299×299 像素。这些 299×299 像素的光学图像由 SLM 生成, 经 MOLM 处理后进行检测; 检测后的图像被大幅下采样至仅 12×16 像素, 随后通过数字后端仅含 192 个权重的紧凑回归网络生成正常与 COVID-19 病例的二分类结果。仅使用 192 个数字训练权重即可获得 98.0% 的准确率、96.8% 的精确率、99.2% 的敏感度和 96.9% 的特异度。如图2 g所示, MOLM 实验获得的 98.0% 准确率优于先前提出的模拟与实验性 ONNs[76, 99], 其性能与 ResNet-50 (97%) 相当。0%) 和 SAM (97.2%), 略低于 ViT (99.0%)。然而, 与 ResNet-50 相比, 我们的 MOLM 可将数字模型压缩 4.9×10^5 倍; 与 ViT 相比则压缩 1.8×10^6 倍, 这意味着在训练阶段计算时间显著缩短 1.2×10^5 倍, 在推理阶段能耗降低 1,900 倍。


计算时间包括 SLM 响应所需时间、光在自由空间中的传播时间、相机响应时间以及数字计算机的运算时间。

(见下页图。)


图 2 MOLM 在三项基准任务中的实验结果。**a** MOLM 在基准任务中的实验装置示意图。**b** 超表面芯片与港元硬币的对比图像。**c** 制备完成的超表面芯片光学显微镜图像 (左图, 面积为 $3.2 \times 3.2 \text{ mm}^2$) 及包含 25×25 个超原子的超表面区域放大扫描电子显微镜 (SEM) 图像 (右图)。**d** 超表面芯片放大区域定量相位成像 (QPI) 的测量结果。关于 QPI 测量的详细信息见补充说明7。在色轮中, 颜色代表相位调制系数, 亮度代表幅度调制系数。**e**、**h** 和 **k** 分别展示了 COVID-19 放射影像 (**e**)、NIH ChestX-ray8 (**h**) 及 RSNA 颅内出血检测任务 (**k**) 的数据集图像。**f** 为 MOLM 在 COVID-19 放射影像任务中准确率随光学神经元数量的变化曲线, 虚线表示 SAM 的准确率作为对比基准; 带彩色散点图的子图展示了 t-SNE 分析结果。**i** 为 NIH ChestX-ray8 预测结果的混淆矩阵。**l** 底部图显示 MOLM 预测的颅内出血区域, 顶部图显示数字 ResNet-50 的预测结果。**g**、**j** 和 **m**: MOLM 在准确性及电子参数方面的表现与其他光学方法[76、99] 以及新冠放射成像 (**g**)、NIH ChestX-ray8 (**j**) 和 RSNA 颅内出血检测任务 (**m**) 的数字模型进行对比。



采用超紧凑神经网络 (192个权重) 进行分类 covid-19



能够对高分辨率 (1,024×1,024像素) 图像进行端到端处理 $\frac{N}{102} \times \frac{H}{4} \times \frac{C}{10} \times \frac{H}{24} \times \frac{a}{p} \times \frac{8}{b} \times \frac{1}{j}$



具备分类与检测的多任务处理能力




图 2 (详见前页图注。)

能耗分别包括激光源、SLM、相机和数字计算机各自消耗的能量。关于时间与能耗基准的更多细节, 请参阅补充说明23和24。

我们的研究进一步表明, 超表面器件所特有的大量光学参数是实现高精度的关键因素。随着光学参数数量从420万增加, 精度从83.0%提升至98.0%。

如图2 f所示(实验详情参见补充说明9), 数据量增至4100万。为深入分析数据, 我们采用t分布随机邻域嵌入(t-SNE) [100]对经MOLM处理后的数据进行可视化: 原始图像通过超表面被转换至低维空间。图2 f的插图显示, 随着光学参数数量显著增至4100万, 不同类别之间的区分度显著增强。

基于我们取得的成果, 我们开始探索更具有挑战性的应用场景——这些应用此前从未由ONNs实现过。这些任务充分展现了我们的MOLM处理高分辨率图像的能力, 以及应对复杂医学诊断任务的实力。

2.2.2 具备对高分辨率图像进行端到端处理的能力

胸部疾病检测: 本任务旨在展示我们的系统对分辨率超过一百万像素的高分辨率图像进行端到端处理的能力。NIH ChestX-Ray8数据集[101]包含高分辨率(1,024×1,024像素)正面视角X射线图像, 涵盖八种不同的胸部疾病(如图2 h所示)。如图2 i所示, 我们的MOLM模型能够以平均85.4%的准确率检测这些常见胸部疾病, 且仅需使用9,600个数字化训练权重进行最小程度的数字处理。该准确率与采用8,580万个数字化训练权重的ViT模型结果相当(准确率为85.8%)。此外, 本任务凸显了我们的MOLM无需任何预处理即可处理高分辨率图像的能力——据我们所知, 该模型采用的1,024×1,024像素分辨率是当前ONNs模型中最高的分辨率。

2.2.3 具备分类与检测的多任务处理能力

颅内出血检测: 颅内出血(ICH)是一种危重疾病, 需要迅速且积极的治疗以防止进一步损伤并改善患者预后[102]。然而, 由于缺乏能够及时解读影像扫描结果的放射科医师, 颅内出血的早期检测常常会延迟。在此, 我们利用MOLM技术加速CT图像中的脑出血(ICH)检测, 如图2 k所示。我们的实验解决了两项任务: 第一项任务是检测CT图像中的出血情况, 准确率达到98.8%, 精确度为98.5%, 灵敏度为99.2%, 特异度为98.3%; 第二项任务是利用MOLM确定出血点位置。具体流程为: 首先将MOLM处理后的光学图像下采样至15×20像素, 这些下采样后的图像作为输入输入到一个6层全连接神经网络中。

数字后端处理单元输出一个包含4个元素的向量, 每个元素分别表示矩形框的水平与垂直位置坐标、宽度及高度。该矩形框对应CT图像中的出血区域(如图2 l所示)。通过比较预测框与真实框计算交并比(IoU), 以评估出血区域定位性能——此处IoU定义为两个框重叠面积与总面积之比。我们的MOLM模型实现了0.85的IoU值。针对3种不同的出血位置, 预测结果均达到61分, 表明指示出血位置的预测边界框与真实边界框高度吻合。相比之下, ResNet-50模型获得的平均IoU值为0.64。

我们在多项视觉任务的MOLM结果揭示了一个重要发现: 该技术仅需采用单层超表面结合小型数字神经网络, 即可与拥有数千万参数的尖端神经网络模型相媲美。通过不同任务的实验验证, 我们证实其卓越性能源于超表面独有的海量参数优势, 如图2 g、j和m所示。尽管数字后端仍需小型神经网络, 但其规模可大幅压缩至原规模的1/10⁵。此外值得注意的是, 后端剩余的小型神经网络可直接在模拟器件中实现, 从而构建出全模拟系统。

2.3 可扩展至复杂的神经网络模型, 用于高精度视频

序列处理

通过利用由随机参数构建的无限层神经网络计算框架, 我们可以放心地增加光学神经网络的深度, 而无需担心物理误差逐层累积。这使得我们的系统能够处理更复杂的AI任务。在此, 我们基于MOLM构建了一个循环神经网络(RNN), 并将其应用于视频处理。作为隐藏层, MOLM通过循环连接形成RNN [40, 103]。这种基于超表面的RNN(meta-RNN)以视频中的图像帧序列作为输入(如图3 a所示)。每个帧均由meta-RNN处理, 其输出经过下采样后从相机读取; 随后, 该输出与前几帧的隐藏状态相结合, 以推导当前帧的隐藏状态; 最终, 输出连接到基于逻辑回归的分类器。meta-RNN已在KTH数据集[104]上用于人体动作识别任务, 该数据集包含四种不同场景下的六种人体动作类型。

对该模型性能的评估涉及两种类型的动作分类。其中一种类型可识别:

动作准确度是指由帧序列共同决定的动作判断结果, 具体通过计算每个测试视频序列中所有动作获得的投票百分比来确定——得票最高的动作即为该视频序列中的预测动作。另一种指标则用于衡量单帧画面所指示的动作, 即帧准确度。如图3 b和c所示, 我们的meta-RNN模型在训练9,180个权重后, 实现了97.5%的帧准确度和99.1%的动作准确度。使用 NVIDIA RTX 3090进行训练仅需4.01秒即可达到如此高的准确率。该结果优于采用长短期记忆机制的数字神经网络(动作准确度90.7%)及最先进的ONNs模型(动作准确度96.3%)。此外, 与其他通常需要通过预训练卷积神经网络(CNN)对动作序列帧进行预处理以实现人体分割的ONNs不同, 我们的meta-RNN模型可直接处理视频数据, 无需此类预处理步骤。因此, 我们的元RNN能够高速处理视频, 帧率可达每秒1,968帧。

我们进一步利用该任务来展示MOLM快速从外部扰动中恢复的能力及其实时自适应学习的潜力。为验证这一特性, 我们在数字神经网络训练完成后, 故意将超表面移动10微米以产生轴向错位——该错位量为光波长的20倍。这种轴向错位会导致超表面调制矩阵发生变化, 可能使精度下降16.7%。然而如图3 e所示, MOLM在重新训练单层数字神经网络后能够快速纠正误差: 仅使用1,920张训练图像, 经过45个训练周期后精度即恢复至96.3%, 整个过程仅需234毫秒。本研究凸显了MOLM在动态或不可预测环境中的自适应能力及其实时自适应学习潜力。实验细节详见补充说明10。采用光学扇形阵列计算超大规模矩阵可实现极低的光学能耗。

当矩阵尺寸足够大时, 每次乘法运算所需的光子数量远小于1。如图3 f所示, 每次运算平均仅需0.078个光子即可将人体动作分类准确率维持在95%以上。这一特性使我们的系统适用于低光照环境。具体实验细节详见补充说明11。

2.4 解决现实世界挑战: 加速多千兆像素全切片图像在癌症诊断中的分析

基于这些优势, 我们最终在实际应用中验证了该MOLM的性能, 充分展现了其在计算密集型场景中的独特优势。对于许多疾病(尤其是癌症), 病理诊断是临床实践中的金标准。全切片成像(WSI)扫描仪的问世——可生成数字化病理显微图像——彻底革新了病理图像分析技术。该技术实现了计算机辅助诊断, 通过运用先进的深度学习技术来减轻病理学家的工作负担并优化医疗资源的区域分布[107]。然而, 由于全切片图像(WSI)的尺寸极其庞大, 其给深度学习带来了挑战。由于单张切片包含数百万像素的图像, 高效处理这些图像对于自动化诊断至关重要。

在本研究中, 我们采用一种MOLM技术来检测并定位已转移至邻近淋巴结的乳腺癌——这一任务具有重要的临床意义, 但需要病理学家投入大量时间进行审阅。病理学家通常需要审阅来自单张超过10吉像素WSI的数千张百万像素级图像。本研究使用CAMELYON16数据集[108]。针对每张尺寸超过20亿像素的超大尺寸图像(WSI)的处理需求, 我们采用了基于图像块的处理框架。首先, 采用Otsu算法[109]进行预处理, 以分离原始图像。

(见下页图。)

图3基于视频的人类动作识别的meta-RNN实验结果。**a**基于视频的人类动作识别中meta-RNN的工作最低阈值。meta-RNN以逐帧方式处理动作视频, 每段动作视频包含20帧。

时间间隔为80毫秒。首先, 将 120×160 像素的输入帧 x_t 未经任何预处理直接编码至光学域。随后通过MOLM处理生成 34×45 像素的压缩数字图像 $f x_t$ 。处理后的帧与前一帧的输出融合, 形成当前帧的输出, 即 $h_t = h_{t-1} + f x_t$ 。最后, 将当前帧的输出输入数字神经网络, 生成逐帧预测结果 y_t 。动作预测结果是动作视频所有逐帧预测结果中出现频率最高的标签。**b**逐帧预测结果的混淆矩阵。**c**动作预测结果的混淆矩阵。**d**MOLM与当前最先进的数字及光学方法的性能对比[40, 68, 105, 106]。meta-RNN的训练时间和处理速度是根据当前实验结果预测得出的(详见补充说明23)。**e**meta-RNN在经历剧烈扰动后快速恢复精度的能力。**f**操作精度与复数乘法运算中平均光子数的关系。




图 3 (详见前页图注。)




图 4基于全切片图像的 MOLM 在癌症诊断中的实验结果。**a**基于全切片图像的癌症诊断工作流程。输入 WSI（超过 2.2×10^{10} 像素）首先采用Ostu方法进行预处理，然后裁剪为一系列1,000×1,000像素的图像块。这些图像块通过 MOLM 一次性处理后，被压缩至30×40像素。最后，这些处理后的图像被输入到一个高度紧凑的数字神经网络中，以生成关于图像中是否检测到肿瘤细胞的最终预测结果。**b**训练阶段各图像块级预测结果的ROC曲线。**c** MOLM 预测概率热图以及最先进的分割模型（SAM）。插图a、b、c分别展示了 WSI 的三个不同放大区域。**d** MOLM 与SAM的训练时间与推理时间对比。MOLM 的耗时基于当前实验结果得出的预测值（详见补充说明23）。

将整个切片图像聚焦于有用的前景区域和非组织背景区域，从而减少了需要处理的切片图像总像素数（如图4 a所示）。随后，我们将大型WSI图像分割为更小的图像块，每个块尺寸为1,000×1,000像素。这些图像块包含1,775个正常区域块和887个肿瘤区域块。在训练阶段，我们使用 SLM 将这些图像块转换为光学图像。经过调制的图像块样本由我们的 MOLM 进行处理，并由传感器阵列进行检测。随后，传感器阵列的输出信号会被降采样。最后一步是利用这些图像块样本训练单层神经网络，以构建能够区分正常组织与肿瘤组织的分类器。如图4 b所示，当训练权重数为140时，平均AUC值为96.0%；当权重数增至1,200时，AUC值提升至97.0%。如图4 d所示，整个训练过程仅需1.46秒，训练准确率达到95.1%。

另一组包含2,030个未标记图像块的 WSI 用于评估肿瘤组织分割性能。首先，这些未标记图像块通过我们的 MOLM 进行预处理；随后，利用训练好的单层神经网络对处理后的图像块进行推理，计算出肿瘤阳性概率；最后，将图像块的预测概率映射到原始 WSI 上，生成概率热图（如图所示）。4 c：生成的热力图表明，我们的 MOLM 能够从十亿像素级 WSI 图像中准确分割出三个不同的肿瘤组织区域，交并比（IOU）达到0.60，与SAM（0.63）相当。更重要的是，我们的 MOLM 推理速度极为迅速——每张完整切片图像（WSI）仅需1.02秒，相比SAM分析单张 WSI 所需的1.48小时显著缩短。这种推理时间的大幅降低使得我们的算法具有显著优势。

MOLM 在单个12小时工作日内可诊断超过42,352名患者, 而使用SAM在同一时间段内仅能诊断8名患者。

3 讨论

与数字ELM的异同: 该系统的整体架构与标准ELM基本一致, 但存在两个关键差异: 隐藏层非线性函数采用二次函数而非S型函数; 全连接权重为复数值, 并通过衍射效应而非任意实值随机变量进行调制。在补充说明5中我们指出, 随着隐藏层宽度的增加, 采用复参数的系统性能略优于数字ELM; 然而当参数数量达到数千万时, 两者在 MNIST 数据集上的准确率均超过99%。

在非相干光照明下的运行: 该meta- ONN 的一个优势在于其兼容宽带照明, 这极大扩展了系统的应用范围。尽管超表面响应具有波长依赖性, 但我们的方法并不依赖于经过精确优化的光学参数, 因此光谱变化对性能的影响有限。为通过实验验证这一点, 我们将宽带连续LED光源与波长带通滤波器结合, 实现了20纳米至100纳米范围内的不同光谱宽度。LED发出的光包含所选光谱带内的所有波长。实验表明, MNIST 推理在所有光谱宽度下的准确率均超过98.3%。与532纳米单色激光工作模式(99.2%)相比, 准确率略有下降, 这是因为基于LED的光学系统仅实现强度域的线性运算, 而相干光能够执行复数值线性变换, 从而提升模型容量。具体实验细节详见补充说明12。

制造公差: 典型的光学超表面因其亚波长特征尺寸而对制造偏差极为敏感; 即使采用相同设计, 不同器件的性能也可能存在显著差异。相比之下, 我们的系统更为稳健, 因为它无需依赖对单个元原子的精确制备。为验证这一点, 我们测试了三个不同批次制造的芯片。所制备超表面的元原子直径范围在92纳米至413纳米之间, 由于制造误差而偏离了设计值100纳米至400纳米。尽管存在物理缺陷, 但我们观察到各器件的实验 MNIST 精度差异均小于1%。实验结果详见“方法”部分及补充说明4。

与随机散射介质的比较: 随机散射介质会强烈调制信号。

光学振幅与相位技术同样可作为我们架构中的光学前端组件。其核心区别在于可控性: 随机介质由微米级散射体构成, 而超表面则由经过工程设计的纳米级元原子组成, 从而提供了密度更高的有效调制元件。这种更精细的空间控制能力实现了更高效的空间信息编码, 进而提升了分类精度。实验表明, 用随机散射介质替代超表面后, 在 MNIST 测试中准确率达到92.0%, 显著低于使用超表面时达到的99.2%。具体实验细节详见补充说明13。

提升系统紧凑性: 亚波长光学超表面比体光学器件更为纤薄小巧, 这使得其能与CMOS传感器实现高度集成, 从而显著缩小 MOLM 系统的整体体积。基于自由空间的 ONN 系统体积定义为自由空间光学器件面积乘以该器件与CMOS相机之间的间距。在当前采用反射式超表面的实验方案中, 分束器的存在阻碍了体积的进一步缩减, 导致系统体积达到2,560立方毫米³。通过改进设计, 可采用蓝宝石或石英等透明基板使超表面以透射方式工作, 此时无需使用分束器, 且超表面与聚光镜之间的距离也可缩短。此外, 笨重的会聚透镜可替换为数值孔径高达0.99的薄型金属透镜[110]。考虑到该金属透镜需完全覆盖面积为 $3.2 \times 3.2 \text{ mm}^2$ 的超表面[2], 其直径为4.5毫米, 焦距为2.27毫米。超表面与透镜之间的最小间距可等于超表面尺寸(3.2毫米), 从而在光衍射过程中实现光学权重的全连接。超表面与相机之间的间距可小至5.47毫米。因此, 系统体积可大幅缩减至56毫米³, 比大多数最先进的基于三维自由空间的 ONN 系统紧凑102–104倍[33, 39, 40, 42]。这种紧凑的体积使得光学系统能够与后续数字后端完全集成。

可能的局限性: 与数字神经网络相比, 当前系统存在两个局限性, 在处理更复杂的任务时这些局限性仍有改进空间。首先, 数字后端的架构相对简单, 仅由全连接层组成; 而最先进的数字ELM通常采用更先进的架构, 例如深度卷积神经网络和Transformer模型。

采用数字后端会导致学习能力不足, 从而在复杂任务中表现欠佳。其次, 我们使用了一种将图像转换至傅里叶域的光学透镜。研究发现, 傅里叶域中的图像呈现出明显的频率相关特征, 这些特征对分类任务非常有用。然而, 在需要逐像素预测的任务(如图像分割)中, 该光学透镜会降低系统性能。在未来的研究中, 可以通过设计针对特定任务的数字后端并移除系统中的光学透镜来克服这些局限性。

总之, 我们通过实验验证了一种高性能 MOLM, 其精度与扩展性均达到前所未有的水平。这一卓越性能源于创新性地将光学超表面(一种能充分发挥光学并行性的器件)与无限宽的神经网络相结合——该计算框架适用于基于超表面的神经网络, 可扩展至任意宽度、深度和复杂度。我们实验演示的重要发现是: 采用 4100 万个无序工程化元原子构建的单层光学超表面芯片, 结合小规模数字神经网络, 其性能已能与 ResNet 和 ViT 等最先进的深度神经网络相媲美。本研究标志着光学神经网络(ONN)的重大突破——不仅超越了基准测试阶段, 更能有效应对实际应用中的挑战。MOLM 与当前最先进的 ONN 系统的性能对比详见补充说明 27 中的表 S8。

我们的系统将超过 99.99% 的计算任务负载于被动光学超表面之上。尽管后端仍需使用小型数字神经网络(NN), 但此类神经网络的训练时间已从数十小时大幅缩短至数秒; 若采用高速空间光调制器(SLM)和摄像头, 训练时间可进一步缩短至仅数十毫秒。这使得我们的系统能够高度适应需要实时学习能力的动态或不可预测环境, 例如机器人辅助手术场景。与此同时, 推理时间可轻松提升至微秒甚至亚微秒级别, 这将适用于涉及高速对象处理及需要实时决策的各类应用场景。通过采用基于现场可编程门阵列(FPGA)和全模拟电子器件实现的精密神经网络加速器, 甚至能进一步缩短训练与推理时间[111, 112]。总体而言, 本系统凭借其可扩展性、对制造与对准误差的高容忍度, 以及在相干与非相干光照条件下均能正常运行的能力, 为高性能光学人工智能计算提供了切实可行的解决方案。

4 方法

超表面设计与模拟: 该超表面由大规模周期性单元结构构成。每个单元均由厚度为 220 纳米的硅圆柱形超原子组成, 其直径在不同单元中有所差异。这些硅超原子沉积在 725 微米厚硅衬底上的 2 微米厚埋氧化层之上。这些单元在二维平面上以方形晶格排列, 其周期为 500 纳米。基于三维 FDTD 模拟, 我们获得了入射光在不同直径下垂直入射时单元胞的光学相位与振幅调制系数。模拟中, 超原子的网格尺寸为 0.25 nm, 埋氧化层和衬底层的网格尺寸分别为 8 nm。x-y 平面的边界采用周期性设计以模拟超表面的周期性超原子结构, 而 z 平面的边界则为完美匹配层。具体模拟细节详见补充说明 1。模拟结果表明, 通过改变超原子直径可有效调控入射光的光学相位与振幅。超原子直径与相位调制关系的数据表见补充材料图 S1c。所制备的超表面包含 $6400 \times 6400 = 4100$ 万个超原子, 每个超原子的直径均独立设计, 遵循高斯采样分布以实现光学相位与振幅调制系数。具体而言, 相位调制的高斯分布标准差设定为 0.4π 。基于此相位分布, 可通过光学相位与超原子直径之间的映射关系计算出每个超原子的直径(详见补充信息图 S1c)。超原子直径范围为 100 nm 至 400 nm。振幅分布亦无需额外设计即可根据该关系确定。光振幅与元原子直径之间的关系。

超表面制造: 该超表面芯片采用一家商用电子束光刻技术硅晶圆厂提供的多项目晶圆(MPW)工艺制备。制造流程始于绝缘体上硅(SOI)晶圆, 其中器件层厚度为 220 纳米, 缓冲氧化层厚度为 2 微米, 硅衬底厚度为 725 微米。首先在晶圆器件层上涂覆一层对电子敏感的光刻胶, 随后通过加热增强光刻胶稳定性; 最后利用 100 keV 电子枪形成超表面的超原子级图案。随后对晶圆进行化学显影处理, 图案化的光刻胶仍保留在基底上。最后,

采用各向异性RIE蚀刻工艺将光刻胶图案转移至硅器件层中。该蚀刻过程将持续进行,直至缓冲氧化层表面完全暴露。

所制备超表面的定量相位成像:采用定量相位成像(QPI)技术测量超表面的反射相位响应。该系统的衍射极限空间分辨率为665纳米,视场为 $36 \times 36 \mu\text{m}^2$ 。在总放大倍数为200倍的情况下,系统可实现60纳米的高像素分辨率,从而清晰呈现相位调制矩阵结构。关于QPI测量的具体细节详见补充说明7。

基于超表面的光学学习机(MOLM)实验装置:我们的MOLM包含用于生成光学图像的SLM、单层超表面芯片、用于相干合成的会聚透镜以及用于光学图像采集的相机。实验装置首先采用一台532纳米激光二极管,其发射的光束直径为3毫米,光谱半高全宽(FWHM)为10纳米。随后通过光学透镜对激光进行准直,并利用光学四倍系统将其光束扩展至10毫米直径。扩大光束直径的目的是确保激光束能有效覆盖空间光调制器(SLM, Meadowlark Optics E19x12-400-800-HDM8)的活性区域($15.4 \text{ mm} \times 9.6 \text{ mm}$)。该SLM的全像素分辨率为 $1,920 \times 1,200$,像素间距为8微米,调制深度为8位。扩展后的激光束以 12° 的轴外角入射至SLM。如补充说明4所述,通过在SLM前后分别放置两个线性偏振器,可将数字图像编码至光学域;两个偏振器的偏振方向均与水平面呈 45° 。SLM生成的光学图像最终被投射到超表面芯片上。在此,为确保光学图像能有效覆盖超表面芯片的区域以实现光学图像的全区域调制,我们特意将光学图像的有效面积设定为 $4.1 \times 4.1 \text{ mm}^2$ 。为在所有任务中实现一致的有效面积,采用了两种方法:(1)对于像素尺寸小于 512×512 的任务图像,采用数字域中的最近邻面积插值法将其上采样至 512×512 像素尺度。因此,光学图像的有效面积为 $512 \times 8 \mu\text{m} \times 512 \times 8 \mu\text{m} = 4.1 \times 4.1 \text{ mm}^2$ 。例如,COVID-19图像的像素尺寸从 299×299 上采样至 512×512 。(2)对于任务图像

对于像素分辨率大于 512×512 的图像,通过光学域中的4-f系统,生成的光学图像会被缩小至实际有效面积为 $4.1 \times 4.1 \text{ mm}^2$ 。例如,像素分辨率为 $1,024 \times 1,024$ 的胸部X光图像会被缩小一半。此外,由于光学图像的实际有效面积小于激光束尺寸($10 \times 10 \text{ mm}^2$),因此需要使用 5.5×5 的孔径。采用 5 mm^2 的光阑用于抑制激光束的杂散光。在SLM与超表面芯片之间放置一个50/50分束器,以实现光学图像垂直入射至超表面。光学图像依次经超表面和分束器反射后,由焦距为150 mm的光学聚光透镜进行聚焦。最终,一台具有8位深度、 600×800 激活像素数的IRVI Contour IR数字CMOS相机被置于聚光透镜焦平面附近以采集光学图像。实验装置示意图详见补充材料图S4。

神经网络训练:在实验中,经MOLM处理的摄像头采集图像被输入单层后端数字神经网络,以生成各类机器视觉任务的预测结果。神经网络训练的工作流程详见补充信息中的图S14a。首先,通过平均相邻传感器阵列接收到的功率对捕获的图像进行下采样(详见补充信息图S14b)。随后,在MOLM处理后将下采样后的图像及其对应标签合并为新的数据集。该数据集按特定比例随机划分为训练集和测试集,其中训练集用于训练数字神经网络。如补充信息图S14c所示,该数字神经网络包含接收输入图像的输入层和生成预测结果的输出层,两层均为全连接结构。在使用sigmoid激活函数前会对输出添加偏置项。单层数字神经网络的数学表达式为: $y = \text{sigmoid}(b + w x)$, 其中b、w、x和y分别代表偏置项、数字权重、以向量形式表示的输入图像及预测结果。采用逻辑回归方法优化偏置项和数字权重,非线性激活函数为sigmoid。最后,测试数据集用于验证整个系统的性能。下采样比例分别为: MNIST 为 1,600, CIFAR -10 为 676, COVID-19 为 2,500。

ICH数据集使用2,500个样本, NIH数据集使用400个样本, WSI 癌症数据集使用400个样本, 人类动作识别数据集使用324个样本。数据集的划分比例及神经网络训练的超参数均取决于具体任务, 相关细节详见补充说明11–17; 关于数字模型训练 (SAM、ResNet-50 和 ViT) 的具体信息见注释22。

补充信息

在线版本包含补充材料, 可访问 <https://doi.org/10.1186/s43593-026-00127-y> 获取。

补充材料1。

致谢

本研究获得以下项目资助: rgcyerg C4004-24Y、C1002-22Y、GRF 14208925、ECS24203724、NSFC 62405258、ITFITS/237/22、顺兴高等工程研究院 RNE -p4-22, 以及 NSFC / RGC 联合研究计划 N_CUHK 444 /22。

作者贡献

C.H.与M.L.提出了该研究构想。M.L.设计了超表面芯片, 完成了实验并分析了实验数据; M.L.、J.X.和W.G.进行了光学模拟; M.J.负责数字神经网络实验; N.Z.完成了 QPI 实验。Z负责监督 QPI 实验。C.H.主导了论文主体的撰写工作。M.L.、B.S.、M.J.C.S.和Q.D.共同参与了论文的撰写。C.H.、Q.D.和C.S.共同监督了整个项目。

数据可用性

支持本文图表及本研究其他发现的数据, 可根据合理要求向通讯作者索取。

声明

竞争性利益

黄超然、舒 Chester 和罗明成共同申报了美国临时专利申请号 63/643,973。

接收日期: 2025年10月23日 修订日期: 2026年2月10日 批准日期: 2026年11月11日

2026年2月

Published online: 18 March 2026

参考文献

1. Y. LeCun, Y. Bengio, G. Hinton, 《深度学习》。《自然》**521** (7553), 436–444 (2015)
2. J. Achiam, S. Adler, S. Agarwal, L. Ahmad, I. Akkaya, F.L. Aleman, D. Almeida, J. Altenschmidt, S. Altman, S. Anadkat 等人。GPT-4 技术报告 (2023), arXiv 预印本 [arXiv: 2303.08774](https://arxiv.org/abs/2303.08774)
3. B.J. Shastri, A.N. Tait, T. Lima, W.H. Pernice, H. Bhaskaran, C.D. Wright, P.R. Prucnal, 《光子学在人工智能与神经形态计算中的应用》, 《自然·光子学》**15**(2), 102–114 (2021)
4. G. Wetzstein, A. Ozcan, S. Gigan, S. Fan, D. Englund, M. Soljacic, C. Denz, D. A. Miller, D. Psaltis, 《基于深度光学与光子学的人工智能推理》。《自然》**588** (7836), 39–47 (2020)
5. P.L. McMahon, 《光学计算的物理学》。《自然·物理评论》**5** (12), 717–734 (2023)
6. N.H. Farhat, D. Psaltis, A. Prata, E. Paek, 《Hopfield模型的光学实现》, 《应用光学》**24**(10), 1469–1475 (1985)
7. W. Bogaerts, D. Perez, J. Capmany, D. A. Miller, J. Poon, D. Englund, F. Morichetti, A. Melloni, 《可编程光子电路》, 《自然》**586**(7828), 207–216 (2020)
8. J. Sun, E. Timurdogan, A. Yaacobi, E.S. Hosseini, M.R. Watts, 《大规模纳米光子相控阵》, 《自然》**493**(7431), 195–199 (2013)
9. X. Zhang, K. Kwon, J. Henriksson, J. Luo, M.C. Wu: 一种基于大规模微机电系统的硅光子激光雷达。《自然》**603**(7900), 253–258 (2022)
10. Y. Shen, N.C. Harris, S. Skirlo, M. Prabhu, T. Baehr-Jones, M. Hochberg, X. Sun, S. Zhao, H. Larochelle, D. Englund, 《基于相干纳米光子电路的深度学习》, 《自然·光子学》**11** (7), 441–446 (2017)
11. P. Stark, F. Horst, R. Dangel, J. Weiss, B.J. Ofrein: 集成光子神经网络的应用前景。Nanophotonics **9**(13), 4221–4232 (2020)
12. C. Pappas, T. Moschos, M. Moralis-Pegios, G. Giamougiannis, A. Tsakyridis, M. Kirtas, N. Passalis, A. Tefas, N. Pleros: 一种基于时-空-波长复用AWGR架构的Teralop光子矩阵乘法器。收录于: 2024年光纤通信会议暨展览会 (OFC), (IEEE, 2024), 第1–3页。
13. L. De Marinis, M. Cococcioni, O. Liboiron-Ladouceur, G. Contestabile, P. Castoldi, N. Andriolli: 光子集成可重构线性处理器作为神经网络加速器。《应用科学》**11**(13), 6232 (2021)
14. G. Donati, C.R. Mirasso, M. Mancinelli, L. Pavesi, A. Argryris: 采用外部光学反馈的微环谐振器用于时延层计算。《Opt. Express》**30**(1), 522–537 (2021)
15. A. Skalli, J. Robertson, D. Owen-Newns, M. Hejda, X. Porte, S. Reitzenstein, A. Hurtado, D. Brunner, 《基于垂直腔半导体激光器的光子神经形态计算》, 《光学材料快报》**12**(6), 2395–2414 (2022)
16. K. Sozos, A. Bogris, P. Bienstman, G. Sarantoglou, S. Deligianidis, C. Mesaritakis, 基于循环光学频谱切片神经网络的高速光子神经形态计算。《工程通讯》**1**(1), 24 (2022)
17. R. Amin, J.K. George, H. Wang, R. Maiti, Z. Ma, H. Dalir, J.B. Khurgin, V.J. Sorger: 一种基于硅光学的ITO-石墨烯异质结集成吸收调制器, 用于神经形态非线性激活。《应用光子学》**6**(12), 120801 (2021)
18. 徐X、谭M、科科伦B、吴J、博斯A、阮T.G.、朱S.T.、B.E. Little, D.G. Hicks, R. Morandotti, 《用于光学神经网络的11项光子卷积加速器》, 《自然》**589**(7840), 44–51 (2021)
19. B. Shi, N. Calabretta, R. Stabile, 《INP光子集成多层神经网络: 架构与性能分析》, 《APL Photon》**7**(1), 010801 (2022)
20. C. Wu, H. Yu, S. Lee, R. Peng, I. Takeuchi, M. Li: 用于多模光子卷积神经网络的可编程相变超表面在波导上的应用。《自然·通讯》**12**(1), 96 (2021)
21. B. Dong, S. Aggarwal, W. Zhou, U.E. Ali, N. Farmakidis, J.S. Lee, Y. He, X. Li, D.-L. Kwong, C. Wright: 基于连续时间数据的光子张量核心实现高维数据处理。《自然·光子学》**17**(12), 1080–1088 (2023)
22. J.M. Shainline, S.M. Buckley, R.P. Mirin, S.W. Nam, 《用于神经形态计算的超导光电子电路》, 《物理评论应用》**7**(3), 034013 (2017)
23. X.肖, M.B.; 昂, T.; 范·瓦伦伯格, T.; 梁, D.; 博索莱尔, R. G.; 余, S.——基于III-V族硅基moscap平台的大规模、高效能量化光学神经网络。APL Photon. **6**(12), 126107 (2021)
24. 傅涛、臧勇、黄勇、杜志、黄浩、胡超、陈明、杨帅、陈浩: 基于片上衍射光学的光子机器学习。《自然·通讯》**14**(1), 70 (2023)
25. J. Cheng, Y. Zhao, W. Zhang, H. Zhou, D. Huang, Q. Zhu, Y. Guo, B. Xu, J. Dong, X. Zhang: 一种可实现大规模复数值矩阵-向量乘法的小型微环阵列。Front. Optoelectron.**15**(1), 15 (2022)
26. B. Bai, Q. Yang, H. Shu, L. Chang, F. Yang, B. Shen, Z. Tao, J. Wang, S. Xu, W. Xie, 基于微梳的集成光子处理单元。《自然·通讯》**14**(1), 66 (2023)
27. 徐S、王J、易S、邹W: 基于集成光子电路的高阶张量低复杂度处理。《自然·通讯》**13**(1), 7970 (2022)

28. X. 孟、G. 张、N. 史、G. 李、J. 阿扎纳、J. 卡普曼尼、J. 姚、Y. 沈
W. 李, N. 朱, 基于多模干涉的紧凑型光学卷积处理单元。
《自然·通讯》14(1), 3000 (2023)
29. F. Ashtiani, A.J. Geers, F. Alatouni: 一种用于图像分类的片上光子深度神经网络。《自然》606(7914), 501–506 (2022)
30. J. Feldmann, N. Youngblood, M. Karpov, H. Gehring, X. Li, M. Stappers, M. Le Gallo, X. Fu, A. Lukashchuk, A.S. Raja: 基于集成光子张量核心的并行卷积处理。《自然》589(7840), 52–58 (2021)
31. N.U. Dinc, A. Saba, J. Madrid-Wolf, C. Gigli, A. Boniface, C. Moser, D. Psaltis, 从三维到二维再回归三维。《纳米光子学》12(5), 777–793 (2023)
32. M. Yildirim, N.U. Dinc, I. Oguz, D. Psaltis, C. Moser, 《基于线性光学的非线性处理》, 《自然·光子学》18(10), 1076–1082 (2024)
33. 王T、索霍尼M.M、赖特L.G、斯坦M.M、马S.-Y、小野寺T、安德森M.G、麦克马洪P.L, 《基于多层非线性光学神经网络的图像传感》, 《自然·光子学》17(5), 408–415 (2023)
34. J. Chang, V. Sitzmann, X. Dun, W. Heidrich, G. Wetzstein, 采用优化衍射光学技术的混合光电子卷积神经网络用于图像分类。《科学报告》8(1), 1–10 (2018)
35. F. Xia, K. Kim, Y. Eliezer, S. Han, L. Shaughnessy, S. Gigan, H. Cao: 基于循环线性散射实现的非线性光学编码。《自然·光子学》18(10), 1067–1075 (2024)
36. K. Wei, X. Li, J. Froech, P. Chakravarthula, J. Whitehead, E. Tseng, A. Majumdar, F. Heide, 《空间变化的纳米光子神经网络》, 《科学进展》10(45), 0391 (2024)
37. C. 刘、Q. 马、Z.J. 罗、Q.R. 邓、Q. 肖、H.C. 张、L. 缪、W.M. 余, Q. 程, 李, L. 基于数字编码超表面阵列的可编程衍射深度神经网络。《自然·电子》5(2), 113–122 (2022)
38. 罗明、徐涛、肖帅、曾宏基、舒超、黄超: 基于元光学的神经网络加速器并行卷积处理。《激光光子学评论》18(11), 2300984 (2024)
39. X. Lin, Y. Rivenson, N.T. Yardimci, M. Veli, Y. Luo, M. Jarrahi, A. Ozcan: 基于衍射深度神经网络的全机器学习。《科学》361(6406), 1004–1008 (2018)
40. 周涛、林晓、吴杰、陈勇、谢浩、李阳、范杰、吴浩、方磊、Q. 戴, 采用可重构衍射处理单元的大规模神经形态光电子计算。《自然·光子学》15(5), 367–373 (2021)
41. E. Goi, X. Chen, Q. Zhang, B.P. Cumming, S. Schoenhardt, H. Luan, M. Gu: 基于CMOS芯片实现近红外推理的纳米印刷高神经密度光学线性感知器。《光科学与应用》10(1), 40 (2021)
42. X. Luo, Y. Hu, X. Ou, X. Li, J. Lai, N. Liu, X. Cheng, A. Pan, H. Duan: 基于超表面技术的可见光域片上多路复用衍射神经网络。《光科学与应用》11(1), 158 (2022)
43. 郑H、刘Q、周Y、Kravchenko I.I、霍Y、Valentine J.: 面向目标分类器的元光学加速器。《科学进展》8(30), 6410 (2022)
44. H. Zheng, Q. Liu, I. I. Kravchenko, X. Zhang, Y. Huo, J.G. Valentine, 《用于加速机器视觉的多通道元成像技术》, 《自然·纳米技术》(2024年)。 <https://doi.org/10.1038/s41565-023-01557-2>
45. S.-Y. Ma, T. Wang, J. Laydevant, L.G. Wright, P.L. McMahon, 《量子噪声限制的光学神经网络, 每次激活仅需几个量子单元运行》。Res. Sq. (2023). <https://doi.org/10.1038/s41467-024-55220-y>
46. T.王S.-Y、马L.G、赖特T、小野寺T、理查德B.C、麦克马洪P.L: 一种每次乘法运算中使用少于1个光子的光学神经网络。《自然·通讯》13(1), 123 (2022)
47. A. 瓦斯瓦尼、N. 沙泽尔、N. 帕马尔、J. 乌什科雷特、L. 琼斯、A.N. 戈麦斯、L. 凯撒、I. 波洛苏欣: 《注意力就是你所需要的全部——神经信息处理系统进展》, 第30卷 (2017年)。
48. A. 多索维茨基、L. 贝耶尔、A. 科列斯尼科夫、D. 魏森伯恩、X. 赵、T. 乌特特海纳、M. 德加尼、M. 米恩德勒、G. 海戈尔德、S. 格利等人。一张图像价值16×16个字: 大规模图像识别的Transf-
52. 赵Y、刘X.-X、Alu A. 光学超表面的最新进展。《光学杂志》16(12), 123001 (2014)
53. S. Chen, W. Liu, Z. Li, H. Cheng, J. Tian, 《基于超表面的光学复用与多功能技术》, 《先进材料》32(3), 1805912 (2020)
54. X. Qiu, J. Zhang, Y. Fan, J. Zhou, L. Chen, D.P. Tsai: 基于超表面技术实现高阶微分器。《自然·通讯》16(1), 2437 (2025)
55. 周Y、郑H、I.I. 克拉夫琴科、J. 瓦伦丁, 《用于图像区分的平面光学技术》, 《自然·光子学》14(5), 316–323 (2020)
56. 郭奎、蔡刚、沙旭、陈强、程杰、张宇、韩杰、宋琪、肖松, 全介质超表面赋能的光-电子混合神经网络。《激光与光子学评论》16(10), 2100732 (2022)
57. D. Mengü, Y. Zhao, N.T. Yardimci, Y. Rivenson, M. Jarrahi, A. Ozcan: 抗错位衍射神经网络。《纳米光子学》9(13), 4207–4219 (2020)
58. Y. Luo, D. Mengü, N.T. Yardimci, Y. Rivenson, M. Veli, M. Jarrahi, A. Ozcan: 基于宽带衍射神经网络的任务专用光学系统设计。《光科学与应用》8(1), 112 (2019)
59. J. Dong, M. Rafayelyan, F. Krzakala, S. Gigan, 《基于多重光散射的光学储层计算在混沌系统预测中的应用》, 《IEEE选: 量子电子学杂志》26(1), 1–12 (2019)
60. U. Paudel, M. Luengo-Kovac, J. Pilawa, T.J. Shaw, G.C. Valley: 基于散斑的光学储层计算机用于时域波形分类。《光学》。Express 28(2), 1225–1237 (2020)
61. P. Antonik, N. Marsal, D. Rontani, 用于图像分类的大规模时空光子存储器计算机。IEEE期刊《选择性与顶级量子电子学》26(1), 1–12 (2019)
62. Y. Paquot, F. Duport, A. Smerieri, J. Dambre, B. Schrauwen, M. Haelterman, S. Massar, 《光电储层计算》, 《科学报告》2(1), 287 (2012)
63. L. Larger, M.C. Soriano, D. Brunner, L. Appeltant, J.M. Gutierrez, L. Pesquera, C.R. Mirasso, I. Fischer, 《超越图灵机的光子信息处理: 储层计算的光电实现》, 《Opt. Express》20(3), 3241–3249 (2012)
64. D. Brunner, M.C. Soriano, C.R. Mirasso, I. Fischer: 利用瞬态状态实现每秒千兆字节数据速率的并行光子信息处理。《自然·通讯》4(1), 1364 (2013)
65. K. Vandoorne, P. Mechet, T. Van Vaerenbergh, M. Fiers, G. Morthier, D. Verstraeten, B. Schrauwen, J. Dambre, P. Bienstman, 《硅光子芯片上储层计算的实验验证》。《自然·通讯》5(1), 3541 (2014)
66. Q. Vincier, F. Duport, A. Smerieri, K. Vandoorne, P. Bienstman, M. Haelterman, S. Massar, 基于相干驱动被动腔的高性能光子存储器计算机。《Optica》2(5), 438–446 (2015)
67. L. Larger, A. Baylon-Fuentes, R. Martinenghi, V.S. Udaltsov, Y. K. Chembo, M. Jacquot, 基于时延架构的高速光子存储器计算: 每秒百万词级分类能力。《物理评论X》7(1), 011015 (2017)
68. P. Antonik, N. Marsal, D. Brunner, D. Rontani, 基于大规模脑启发式光子计算机的人类行为识别。《自然·机械智能》1(11), 530–537 (2019)
69. M. Rafayelyan, J. Dong, Y. Tan, F. Krzakala, S. Gigan, 《用于时空混沌系统预测的大规模光学储层计算》, 《物理评论X》10(4), 041037 (2020)
70. S. Sunada, A. Uchida, 《硅芯片上的光子神经网络: 大规模、高速神经启发式计算与传感》。《Optica》8(11), 1388–1396 (2021)
71. 中岛M、田中K、桥本T: 基于相干线性光子处理器的可扩展储层计算。《物理通讯》4(1), 20(2021)
72. A. Lupo, E. Picco, M. Zajnulina, S. Massar, 基于频率复用技术的深度光子存储器计算机, 其层间采用全模拟连接。Optica 10(11), 1478–1485 (2023)
73. 沈Y.-W、李R.-Q、刘G.-T、余J、何X、易L、王C, 《深度光子存储器计算循环网络》, 《Optica》10(12), 1745–1751 (2023)
74. D. Wang, Y. Nie, G. Hu, H.K. Tsang, C. Huang: 超高速硅

- ormer (2020), arXiv预印本[arXiv:2010.11929](https://arxiv.org/abs/2010.11929)
49. V.-C. Su, C.H. Chu, G. Sun, D.P. Tsai, 《光学超表面进展: 制备与应用》, 《Opt. Express》 **26**(10), 13148–13182 (2018)
 50. W.T. Chen, A.Y. Zhu, F. Capasso: 基于色散工程超表面的平面光学系统。《自然·材料评论》 **5**(8), 604–620 (2020)
 51. D. Neshev, I. Aharonovich, 《光学超表面: 多功能光学的新一代基础元件》。《光科学与应用》 **7**(1), 58 (2018)
 - 光子存储器计算引擎性能超过200 TOPS。《自然·通讯》 **15** (1), 10841 (2024)
 75. 聂Y、杨B、王D、王T、王J、王Z、黄C: 集成激光梯度神经元实现无需反馈回路的高速储层计算。《Optica》 **11**(12), 1690–1699 (2024)

76. U. Tegin, M. Yildirim, I. Oguz, C. Moser, D. Psaltis: 可扩展光学学习算子。《自然·计算科学》1(8), 542–549 (2021)
77. D. Pierangeli, G. Marcucci, C. Conti, 基于自由空间光传播的光子极端学习机。《Photonics Res.》9(8), 1446–1454 (2021)
78. A. Lupo, L. Butschek, S. Massar, 基于频率复用的光子极端学习机。《Opt. Express》29(18), 28257–28276 (2021)
79. S. Saeed, M. Muftuoglu, G.R. Cheeran, T. Bocklitz, B. Fischer, M. Chemnitz, 光纤极端学习机的非线性推理能力。《纳米光子学》(2025)。 <https://doi.org/10.1515/nanoph-2025-0045>
80. S. Biasi, R. Franchi, L. Cerini, L. Pavesi: 一种基于微谐振器阵列的光子极端学习机。APL Photonics 8(9), 096105 (2023)
81. H. Wang, J. Hu, A. Morandi, A. Nardi, F. Xia, X. Li, R. Savo, Q. Liu, R. Grange S. Gigan: 基于非线性无序介质的规模光子计算。《自然·计算科学》4(6), 429–439 (2024)
82. A. Saaed, F. Caltagirone, I. Carron, L. Daudet, A. Dreameau, S. Gigan, F. Krzakala: 基于多重光学散射的随机投影——以光速逼近核函数。载于: 2016年IEEE声学、语音与 Signal Processing 会议 (ICASSP), (IEEE, 2016), 第6215–6219页。
83. I. Kang, S. Pang, Q. Zhang, N. Fang, G. Barbastathis: 循环神经网络通过散射介质揭示透明物体。《Opt. Express》29(4), 5316–5326 (2021)
84. 黄GB、朱QY、徐CK. 极端学习机: 理论与应用。《神经计算》70(1–3), 489–501 (2006)
85. J. Wang, S. Lu, S.-H. Wang, Y.-D. Zhang, 《极端学习机综述》。Multimed. Tools Appl. 81(29), 41611–41660 (2022)
86. 丁S、赵H、张Y、徐X、聂R, 《极端学习机: 算法、理论与应用》。《人工智能评论》44(1), 103–115 (2015)
87. Y. Qing, Y. Zeng, Y. Li, G.-B. Huang: 基于深度与广度特征的图像分类极端学习机。《神经计算》412, 426–436 (2020)
88. E. Soria-Olivas, J. Gomez-Sanchis, J.D. Martin, J. Vila-Frances, M. Martinez, J.R. Magdalena, A.J. Serrano: 贝叶斯极端学习机。IEEE神经网络汇刊22(3): 505–509 (2011)
89. H. Zhou, G.-B. Huang, Z. Lin, H. Wang, Y.C. Soh, 《堆叠式极端学习机》, IEEE控制论汇刊45(9), 2013–2025 (2014)
90. J.R. Rausell-Campo, A. Hurtado, D. Perez-Lopez, J. Capmany Franco, 《可编程光子极端学习机》。《激光与光子学评论》19(9), 2400870 (2025)
91. A. Jacot, F. Gabriel, C. Hongler, 《神经切线核: 神经网络中的收敛性与泛化》。《神经信息处理系统进展》, 第31卷 (2018年)。
92. M. Gabriele, A. Manoel, C. Luneau, N. Macris, F. Krzakala, L. Zdeborova 等。深度神经网络模型中的熵与互信息。《神经信息处理系统进展》, 第31卷 (2018年)。
93. S. Yu, K. Wickström, R. Jenssen, J.C. Principe: 运用信息论理解卷积神经网络——初步探索。《IEEE神经网络与学习系统汇刊》32(1), 435–442 (2020)
94. D.-Y. Tsai, Y. Lee, E. Matsuyama, 《用于评估图像质量的信息熵度量》, 《数字成像杂志》21(3), 338–347 (2008)
95. M. Tancik, P. Srinivasan, B. Mildenhall, S. Fridovich-Keil, N. Raghavan, U. Singhal, R. Ramamoorthi, J. Barron, R. Ng: 傅里叶特征使网络能够在低维域中学习高频函数。《先进神经信息与过程系统》33, 7537–7547 (2020)
96. K. He, X. Zhang, S. Ren, J. Sun: 用于图像识别的深度残差学习。载于: 《IEEE Computer Vision 与 Pattern Recognition 会议论文集》(2016年), 第770–778页
97. A. Kirillov, E. Mintun, N. Ravi, H. Mao, C. Rolland, L. Gustafson, T. Xiao, S. Whitehead, A.C. Berg, W.-Y. Lo, 《任意分割》, 载于《IEEE/ CVF 国际计算机视觉会议论文集》(2023年), 第4015–4026页。
98. T. Rahman, A. Khandakar, Y. Qiblawey, A. Tahir, S. Kiranyaz, S.B.A. Kashem, M.T. Islam, S. Al Maadeed, S.M. Zughaier, M.S. Khan: 《利用胸部X光图像探究图像增强技术对COVID-19检测的影响》。Comput. Biol. Med. 132, 104319 (2021)
99. I. Oguz, J.-L. Hsieh, N.U. Dinc, U. Tegin, M. Yildirim, C. Gigli, C. Moser, D. Psaltis, 《为高效光学学习机设计非线性传播方案》, 《先进光子学》6(1), 016002–016002 (2024)
100. L. Maaten, G. Hinton: 使用 t-sne 对数据进行可视化。《机器学习研究杂志》。9(11), 2579 (2008)
101. X. Wang, Y. Peng, L. Lu, Z. Lu, M. Bagheri, R.M. Summers, 《Chestx-ray8: 医院规模胸部X光数据库及常见胸腔疾病弱监督分类与定位基准研究》。载于: 《IEEE Computer Vision 与 Pattern Recognition 会议论文集》(2017年), 第2097–2106页
102. A.E. Flanders, L.M. Prevedello, G. Shih, S.S. Halabi, J. Kalpathy-Cramer, R. Ball, J.T. Mongan, A. Stein, F.C. Kitamura, M.P. Lungren: 通过协作构建机器学习数据集——rsna 2019 脑CT出血挑战赛。《放射学: 人工智能》2(3), 190211 (2020)
103. J. Bueno, S. Maktoobi, L. Froehly, I. Fischer, M. Jacquot, L. Larger, D. Brunner, 《大规模光子循环神经网络中的强化学习》, 《Optica》5(6), 756–760 (2018)
104. C. Schultdt, I. Laptev, B. Caputo, 《识别人类行为: 一种局部支持向量机方法》, 载于《第17届国际模式识别会议论文集》(2004年), ICPR 2004年第3卷 (IEEE 出版社, 2004年), 第32–36页。
105. A. 吉尔伯特, J. 伊林沃思, R. 鲍登, 《基于挖掘的层次化复合特征的動作识别》, 《IEEE模式分析与机器智能汇刊》33(5), 883–897 (2010)
106. A. Grushin, D.D. Monner, J.A. Reggia, A. Mishra: 基于长短期记忆的鲁棒性人类行为识别。载于: 2013年国际神经网络联合会议 (IJCNN), (IEEE, 2013), 第1–8页。
107. G. Campanella, M.G. Hanna, L. Geneslaw, A. Miralor, V. Werneck Krauss Silva, K.J. Busam, E. Brogi, V.E. Reuter, D.S. Klimstra, T.J. Fuchs: 基于弱监督深度学习对全切片图像进行临床级计算病理学分析。《自然·医学》25(8), 1301–1309 (2019)
108. B.E. Bejnordi, M. Veta, P.J. Van Diest, B. Van Ginneken, N. Karssemeijer G. Litjens, J. A. Van Der Laak, M. Hermesen, Q.F. Manson, M. Balkenhol, 《深度学习算法在乳腺癌女性患者淋巴结转移检测中的诊断评估》, 《JAMA》318(22), 2199–2210 (2017)
109. N. Otsu: 一种基于灰度直方图的阈值选择方法。Automatica 11(285–296), 23–27 (1975)
110. R. Paniagua-Dominguez, Y.F. Yu, E. Khaidarov, S. Choi, V. Leong, R.M. Bakker, X. Liang, Y.H. Fu, V. Valuckas, L. A. Krivitsky: 一种数值孔径接近1的金属透镜。《Nano Lett.》18(3), 2124–2132 (2018)
111. F. Zhou, Y. Chai, 《近传感器与传感器内计算》。《自然·电子》3(11), 664–671 (2020)
112. 陈Y、纳扎迈提M、徐H、孟Y、周T、李G、范J、魏Q、J. 吴, F. 乔: 用于高速视觉任务的全模拟光电芯片。《自然》623(7985), 48–57 (2023)