

用于图像分类的压缩元光学编码器

预印本

安娜·沃思-辛格^{1,*}西昂·金林^{2,*}

崔敏浩^{2,*}约翰内斯·E·弗罗赫^{1,2}黄洛成²埃利·施利泽曼^{3,2}

肖恩·科尔本²

阿尔卡·马朱姆达尔^{1,2}

¹华盛顿大学物理系, 美国华盛顿州西雅图市, 邮编 98195

²华盛顿大学电气与计算机工程系, 美国华盛顿州西雅图市, 邮编: 98195

³华盛顿大学应用数学系, 美国华盛顿州西雅图市, 邮编 98195

*这些作者对本研究的贡献相同。

2024年4月

摘要

光学与混合卷积神经网络（CNN）近年来在实现低延迟、低功耗的图像分类及计算机视觉任务方面备受关注。然而，实现光学非线性运算颇具挑战性；而在标准CNN中省略非线性层会导致准确率显著下降。本研究采用知识蒸馏技术，将改进版AlexNet压缩为仅包含一个线性卷积层和一个电子后端（两个全连接层）。实验结果表明，其性能与采用五个卷积层和三个全连接层的纯电子CNN相当。我们通过设计反向优化的元光学元件来实现光学卷积运算——具体而言，是通过精确调控其点扩散函数来完成这一过程。通过这种混合方案，我们估算出：在传统电子版改进型AlexNet中，多重累加运算次数为1700万次；而在采用光学前端的混合压缩网络中，该次数降至仅8.6万次。这使得延迟和功耗均降低了两个数量级以上。此外，实验表明，该系统在MNIST数据集上的分类准确率超过93%。

关键词：神经网络、元光学、图像分类、知识蒸馏、光学计算

1 引言

卷积神经网络（CNN）在图像分类、识别和跟踪领域标志着一项重要里程碑[1]。以AlexNet为例，CNN由多个卷积层组成，能够自适应地从输入图像中学习空间表征。尽管卷积运算功能强大，但其计算成本极高，导致系统延迟大且功耗高。事实上，据估算CNN总运行时间中约80%用于执行卷积运算[2]。降低这种延迟并相应减少功耗已成为当前活跃的研究领域，多项研究提出自由空间光系统作为解决方案[3, 4, 5, 6]。除了降低延迟和功耗外，光学信息处理还具备高带宽、空间并行性和低损耗传输等特性，这些特性使得该领域引起了广泛关注[3]。

数十年来，人们已经认识到：通过在透镜的傅里叶平面上放置适当的滤波器，可以利用4f透镜系统实现光学卷积运算[7, 8, 9, 4]。这一原理在2018年的研究[4]中得到了验证——该研究采用衍射光学元件作为滤波元件，并结合传统折射透镜构建了4f系统。空间光调制器

[6] 此外，数字微镜器件[10]也可用作滤波元件。然而，基于傅里叶的4f方法存在一个缺点：它需要三个元件（两个透镜和一个空间滤波器），从而形成体积较大的光学系统，且比单元件光学系统更容易出现对准偏差。即使权重是通过含噪声的输入进行训练的，每个光学卷积层引起的对准偏差也无法忽略（更多细节见补充材料）。此外，在4f系统中，滤波光学元件必须集成在焦平面的紧凑区域内，这会限制并行处理能力——除非采取创新性措施，例如利用天然存在的衍射级次[10]或微透镜阵列[5]。

有利的是，卷积运算也可使用自由空间光学系统实现，且仅需单个光学元件。任何光学系统生成的最终图像，都是输入信号与该光学系统的点扩散函数（PSF）进行卷积的结果[11, 12, 13]。因此，通过设计光学系统以产生特定的点扩散函数（PSF），卷积运算只需让光线穿过该光学系统即可实现光学处理。此外，若将输入信号并行通过多个此类光学系统，便能以光速同时执行多次卷积运算[5, 14]。这种方法利用了光固有的并行特性，能够在不增加计算时间的前提下对海量数据进行被动处理[3, 10, 5]。这种独特的光学特性有效规避了传统基于电子元件的卷积神经网络系统在处理高分辨率图像时面临的扩展性问题。

然而，所有基于光学实现的卷积神经网络（CNN）方法都面临一个共同挑战：非线性层与线性层相互交错分布。例如，AlexNet由五个卷积层和三个全连接层组成[15]。具体而言，该架构中的每个卷积层均采用修正线性单元（ReLU）作为非线性激活函数，随后依次经过局部响应归一化层和最大池化层，从而形成了一套有效的空间层次结构提取机制。因此，非线性处理在整个网络各层中均得到一致应用，成为提升网络学习能力的核心设计要素。若缺少卷积神经网络中高效的非线性层（例如ReLU），其分类准确率将下降约20%。[16]非线性层无法通过简单的透镜式光学结构实现；要实现其光学功能，必须引入某种物理非线性效应，例如使用原子蒸气单元[6, 17]或图像增强器[18]。采用信号反复转换的混合方法——即在光学系统中执行线性运算、在电子系统中执行非线性运算——由于信号转换过程存在较大的延迟和功耗问题，实际效果有限[5, 18, 9]。在速度和延迟方面，仅实现多种所需卷积运算中的某一种并不会带来显著优势。另一方面，近期在物理网络和混合网络设计中采用端到端架构取得了突破性进展——这类架构无需显式使用卷积运算即可完成图像分类或其他任务[19, 3, 20, 21]。这种设计能够在单一光学前端有效实现多个线性层。尽管这类端到端神经网络颇具创新性，但其训练过程计算成本高昂，且仅适用于专门为此设计的物理系统。




图1：用于图像分类任务的卷积神经网络示意图。(a)全电子多层CNN；(b)全电子压缩CNN；(c)混合CNN，其结合了光学元光学前端与电子后端；(d)各网络配置的乘积累加（MAC）运算次数，其中卷积MAC以绿色表示，全连接（FC）MAC以棕色表示。

在本研究中，我们通过实验验证了一种混合光电子卷积神经网络（CNN）：该网络由单一光学卷积层和一个电子全连接层组成，在手写数字分类任务中达到了与AlexNet相当的准确率。为克服光学非线性缺失带来的局限，我们采用知识蒸馏技术移除非线性层，并将多个层压缩为单一线性层[16]。知识蒸馏（详见方法部分）通过将知识从规模更大的预训练网络（“教师”网络）转移到更紧凑的网络（“学生”网络），在不显著降低性能的前提下规避了对非线性组件的需求。本研究采用改进版AlexNet（记为AlexNet-Mod）作为教师网络，而将单一卷积层与单一全连接层相结合作为学生网络。我们采用这一架构来展示一种混合型超光学平台：其光学前端基于单一超光学元件执行线性卷积运算，随后是包含线性校准层和全连接层的电子后端。通过这种方式，计算成本最高的运算环节被置于光学层面完成，从而充分发挥光学计算的优势——即高空间带宽和低功耗特性。采用单一超光学层的设计极大简化了实验装置，并实现了紧凑的几何结构。

该网络的光学前端采用逆向设计的超光学结构实现。这些超光学结构由亚波长散射体阵列构成，可充当相位掩模，对入射光施加空间编码的相位偏移。本研究通过优化点扩散函数（PSF），设计出能够实现卷积神经网络（CNN）所需卷积步骤的相位掩模。我们利用中心波长为525纳米的发光二极管发出的非相干绿光，对所设计的光学系统进行了制备并进行了实验验证。此外，我们通过实验验证了整个混合CNN在MNIST数据集上的分类准确率。该混合CNN结构如图1所示，其中对比了多层电子CNN、压缩电子CNN（一种线性单层CNN）以及我们的混合系统三种架构。通过将多个卷积层压缩为单层并采用光学实现方式，整个网络中的乘积累加（MAC）运算次数减少了两个数量级以上。压缩后的混合CNN分类准确率仅比AlexNet-Mod（98%准确率）下降5%，在MNIST数据集上达到93%的分类准确率。

2 结果

在卷积神经网络（CNN）的每个卷积层中，经过优化的卷积核会与输入图像进行卷积运算，生成特征图并传递至下一层。采用知识蒸馏方法，我们针对MNIST手写数字数据集优化了八个卷积核（每个尺寸为 6×6 像素）。所选卷积核的数量与尺寸基于先前的实验结果（详见补充信息）[22]。如下一节所述，我们设计了相应的光学系统以实现这些优化后的卷积核，并将其与用于图像分类的电子后端模块相结合。

2.1 利用知识蒸馏技术压缩多层卷积层

为了为线性光-电子混合系统选择理想的网络架构，必须避免欠拟合和过拟合问题。较小规模的网络容易出现欠拟合问题，尤其是在光学设置中——这类设置将系统限制在仅8个卷积核且移除了非线性函数[23]。这与AlexNet形成鲜明对比，后者使用了超过300个卷积核[1]。然而，复杂模型容易发生过拟合，而制造噪声和对准偏差等实际问题，也为在光学平台上实现大量卷积核带来了额外挑战。

因此，为获得一个可实现光学部署的平衡网络，我们采用知识蒸馏技术对AlexNet-Mod基础模型进行压缩。AlexNet-Mod包含5个卷积层和3个全连接层（共8个层），我们将其压缩为所需的结构——仅包含一个卷积层和一个全连接层（共2个层）。知识蒸馏方法假设教师网络已预先训练完成并能以高精度完成目标任务；本研究采用AlexNet-Mod作为教师网络，其在重复试验中于MNIST数据集上的训练分类准确率达到 $98.9\% \pm 0.33\%$ ，测试分类准确率达到 $98.4\% \pm 0.32\%$ 。此外，AlexNet-Mod采用非线性激活函数（ReLU）来优化性能；而知识蒸馏技术规避了这一限制，从而获得与我们的光学系统兼容的结果。在压缩后的网络中，我们将压缩卷积层的核数量限制为8个，每个核的尺寸为 6×6 像素。经过训练后，该压缩网络在训练集和测试集上的分类准确率均达到约96%。

2.2 基于元光学技术的光学卷积算法

该网络的光学组件采用逆向设计的超光学技术实现。我们采用Gerchberg-Saxton（GS）相位恢复方法[24]设计了与优化后的卷积核相对应的相位掩模。




图2: 光学系统的示意图。(a)使用单色点光源的PSF测量装置(左),以及采用微型LED显示屏进行的光学卷积测量结果(右)。(b)所制备元光学系统的照片。该元光学系统包含16个不同的子光学元件,这些元件在单层结构中空间分布,并并行用于分类任务。(c)对应特定卷积核正负部分的示例子光学元件的相位图及扫描电子显微镜(SEM)图像。(d)示例卷积核的正负部分(左)、相应的PSF模拟结果(中)及实验结果(右)。(e)针对输入为MNIST生成的“7”字符,该卷积核的模拟电子输出(左)与光学实验输出(右)。

具体而言,每个子光学元件均被设计为具有与卷积核相似的点扩散函数(PSF)。由于电子卷积核同时包含正值和负值,我们将每个卷积核分离为正负两部分,并分别为这两部分设计了相应的元光学元件。随后通过计算对正负图像进行相减运算,得到最终卷积结果。图2(b)展示了某组亚光学元件的二维相位图。这些相位图由氮化硅柱实现,柱高为750纳米,但宽度根据其相对相位延迟进行调整。图中同时展示了所制备光学元件的扫描电子显微镜(SEM)图像以供对比,突显了其制造质量。所有16个光学元件(对应8个卷积核)均制备于同一基板上(详见材料与方法),使得单次成像即可实现16个不同卷积核的运算。图2(b)展示了所制备超光学元件的照片。每个卷积核超光学元件尺寸为 $470\text{ }\mu\text{m} \times 470\text{ }\mu\text{m}$,中心间距为 $705\text{ }\mu\text{m}$ 。这些光学元件排列为两排,每排八个,总占地面积为 $5.6\text{毫米} \times 1.4\text{毫米}$ 。

为验证光学系统的性能,我们采用单模光纤作为点光源,测量了每个子光学系统的点扩散函数(PSF),如图所示。2(a)。所有16个子光学系统的点扩散函数(PSF)均通过二维CMOS相机同时采集(更多细节详见材料与方法部分)。因此,当我们单模光纤替换为显示模块后(如图2(a)所示),所有16个子光学系统的卷积图像也实现了同步采集。图2(d)展示了代表光学实现卷积核真实点扩散函数的示例电子卷积核。我们还展示了基于角谱传播方法[25, 26]生成的超光学系统模拟点扩散函数。图2(d)中实验测得的点扩散函数与模拟结果高度吻合。

这证实了制造精度。然而，由于物理上可实现的点扩散函数（PSF）存在限制，真实值PSF与实验测量得到的PSF之间存在显著差异。为校正这些差异以及光学系统中的微小噪声和对准偏差，我们在计算后端引入了一个校准层，具体讨论详见第4.2节。

2.3 混合网络分类结果

为解决影响图像分类性能的光学噪声和对准偏差问题，系统引入了额外的校准层，用于调整光学表征以确保与计算后端兼容。具体而言，该校准层仅使用训练数据集的10%进行微调，从而避免了对计算后端进行重新训练的必要性。因此，混合网络的电子后端由校准层及原始压缩后的电子后端组成。

我们在表1中比较了三种CNN架构（AlexNet-Mod、压缩电子网络及混合光电子网络）。AlexNet-Mod在训练集和测试集上的分类准确率均超过98%。该网络的MAC运算次数为1700万次，精度为8位（详细信息见补充材料第S1节）。压缩后的电子CNN实现了超过96%的准确率；这一2%的下降反映了将多层结构压缩为单层所固有的挑战。主要得益于卷积层的压缩，MAC运算次数减少至228,672次。混合网络将光学卷积层与校准层及单层全连接电子后端相结合，实验结果显示其在训练集和测试集上的分类准确率分别为93.9%（ $\pm 0.25\%$ ）和93.4%（ $\pm 0.22\%$ ），所需的MAC运算次数仅为85,824次，分别仅为AlexNet-Mod和压缩电子网络所需运算次数的0.5%和37%。

表1：分类结果

网络架构	火车 (%)	测试 (%)	MAC操作
AlexNet-Mod	98.9 $\pm$ 0.33	98.4 $\pm$ 0.32	17,268,224
压缩电子CNN（不含KD）	84.2 $\pm$ 0.47	82.1 $\pm$ 0.69	228,672
压缩电子CNN（KD）	97.2 $\pm$ 0.35	96.2 $\pm$ 0.29	228,672
混合CNN（KD）	93.9 $\pm$ 0.25	93.4 $\pm$ 0.22	85,824

图3展示了三种神经网络配置的混淆矩阵。每个矩阵直观呈现了模型在不同类别（本例中为标有0至9的数字）上的测试性能，其中行代表真实标签，列代表预测标签。多层电子CNN AlexNet-Mod在对角线上的数值较高，各类别准确率均超过98.1%。压缩型电子CNN虽然对角线数值略有下降，但仍保持稳定的分类准确率，最低达94.3%。混合网络对角线上的数值分布更为多样化，某些类别的预测准确率低于压缩型电子网络。我们认为这种轻微下降源于光学实验中的噪声，可能与光学器件制造工艺、相机传感器噪声以及校准层无法完全补偿的振动引起的光学噪声有关。尽管存在这些因素，混合网络仍表现良好，其对所有类别的预测准确率最低达到87.6%。这表明该混合网络在应对这些噪声和差异时仍能保持合理的准确度水平。

3 讨论

3.1 消融研究与主成分分析

为理解混合光电CNN各组件的贡献，我们进行了消融实验和主成分分析。在消融实验中，我们评估了仅使用电子后端结构进行分类时的准确率。消融实验结果汇总于表2。为确保公平比较，此处后端层采用与混合网络相同的结构，但经过重新优化以在无任何卷积前端的情况下实现最佳性能。具体而言，我们比较了仅使用后端层（单个全连接层）、校准层与后端层组合（两个全连接层）以及整个混合网络的性能。结果显示，仅使用单个全连接层时准确率达到89%，低于混合网络的表现；这凸显了光学前端的重要性。此外，对于两个全连接层（分别代表校准层和后端层）且前端未采用任何卷积结构的情况，准确率会降低至




图3：不同网络架构的混淆矩阵。(a) AlexNet-Mod（多层电子CNN）的分类结果。(b) 未使用知识蒸馏技术压缩的全电子CNN的分类结果。(c) 采用知识蒸馏技术压缩的全电子CNN的分类结果。(d) 混合光电子CNN的分类结果。

84%。这归因于两个层是全连接的，且在没有非线性激活函数的情况下，它们倾向于在优化过程中收敛到一个“鞍点” [27]。

表2：网络消融研究

配置	训练准确率	测试准确性
仅适用于后端	89%	87%
校准 + 后端	84%	80%
光学系统 + 校准 + 后端处理	94% (+5% / +10%)	93% (+6% / +13%)

我们假设，校准层仅对光学表征进行重新映射，并不会单独提升电子后端的性能。为了研究这一点，我们进一步采用主成分分析（PCA）方法，对比校准层的影响及混合网络的整体性能与全电子网络的表现。PCA是一种广泛应用于各领域的统计方法，尤其在分析神经网络质量时[28]，可将原始的高维数据投影到新的、更简洁的坐标系中，以便进行直观解读。具体而言，

PCA通过对协方差矩阵进行特征值分解或对输入数据进行奇异值分解，以确定主方向（即“主成分”）。主成分1对应方差最大的轴，概括了变量间最重要的关联关系；而与主成分1正交的主成分2则捕捉了第二重要的方差方向。值得注意的是，前两个主成分通常包含最关键的信息。本研究将电子层和光学层卷积层的输出维度分别压缩为两个主成分，以比较两种方法的分类效能——这一结论通过对比PCA可视化结果中的聚类分布得以验证[29]。图4通过PCA分析表明：原始实验数据确实识别出了分类所需的基本成分，但校准函数对于将光学表征转换为与预设计电子后端兼容的形式至关重要。如图4 a和4 c所示，我们观察到全电子CNN的输出结果与未经校准的混合网络实验结果都能有效区分不同类别——这得益于特定类别（例如浅蓝色和深蓝色）的聚类特性。这种聚类行为表明，尽管PCA图中存在可观测的变化，但混合网络对数据分类的基本能力仍与全电子网络相当。然而，由于光学实验输出与电子后端预期输入之间存在差异，直接使用原始后端网络会导致准确率显著下降至16.3%。校准层的设计旨在将光学卷积层的输出重新校准回原始输出，从而无需重新训练即可直接使用原始后端网络。如图4 b和4 c所示，经过校准的实验结果展现出与全电子网络极为相似的聚类行为，进一步证明混合网络的分类性能与全电子网络相当。




图4：混合CNN的PCA分析。(a) 未经校准的实验性混合CNN分类数据的PCA分析。(b) 已校准的实验数据的PCA分析；该数据经过重新映射后，其聚类行为与压缩后的电子CNN数据相似。(c) 压缩后的电子CNN数据的PCA分析。

3.2 基于 PSF 技术设计的元光学系统

我们重点强调了我们的PSF工程方法在执行光学卷积运算时的两大优势。首先，该方法显著提升了光学系统的简洁性——仅需显示器、单层光学元件和相机即可实现，因此结构紧凑且易于实施。由于采用非相干照明技术，该方法可直接应用于实际图像分类场景。其次，我们特别强调了其与优化后的电子系统集成便捷性。光学计算面临的主要挑战在于：电子计算本身已具备强大的性能，这得益于数十年来在算法与硬件领域的持续研发[3]。在我们的方案中，光学元件的设计旨在实现经过电子优化的核心算法。这些核函数可经过修改以体现电子卷积神经网络（CNN）模型与架构的改进，相应的光学系统也能相应调整，以实现与任意核矩阵的卷积运算。此外，用于设计光学系统的Gerchberg-Saxon（GS）算法[24]是一项成熟的技术。GS算法是一种迭代相位恢复算法，用于确定能在目标平面（焦平面）产生特定强度分布的相位（位于光学平面）。换言之，这类超光学系统本质上是仅生成相位信息的全息图，其成像结果即为所需的点扩散函数（PSF）。由于强度分布仅由振幅而非相位决定，通过迭代设计的相位掩模并非唯一解。关于GS算法的具体实现细节可参阅补充材料；在补充材料中，我们还探讨了一种基于自动微分的替代设计方法——该方法同样能实现有效的光学系统，但我们发现基于GS算法设计的光学系统所生成的图像亮度更高、清晰度更优。

然而，PSF工程方法存在两个主要局限性。一个局限性在于，无法保证所需的点扩散函数（PSF）在物理上能够实现；也就是说，可能不存在能够满足所有振幅约束条件的单一相位掩模。然而，通过引入电子校准层，所得的PSF无需完美即可有效实现数据分类。另一种方法是采用端到端的校准方案，以确保所获得的PSF在物理上具有可实现性。

该优化方案通过后端模块同步优化相位掩模。然而，训练这种规模庞大的相位掩模（每个光学核约包含 10^5 至 10^6 个单元格）成本极高，且设计空间可能过于庞大而难以收敛。相比之下，分别训练电子卷积核与光学组件均为合理步骤——实践证明，二者结合使用能取得显著效果。

所述方法的第二个局限性在于，我们假设点扩散函数（PSF）在空间上具有不变性。实际上，成像物体不同空间位置发出的光线以不同的入射角照射到超光学系统上，导致离轴光线产生的PSF各不相同。相比之下，我们在设计光学系统时假设照明为垂直入射。为消除这一差异，我们通过将显示屏相对于焦距（2.4毫米）设置得较远（90毫米），确保入射光线的角度相对较小。因此，对于显示图像尺寸为 $8\text{ mm} \times 8\text{ mm}$ 的情况，我们确保其与法线入射的最大偏差不超过 3.6° ；因此，空间不变性假设适用于我们的系统。然而，对于大视场成像系统，可能需要明确建模空间变化的点扩散函数（PSF）。值得注意的是，Wei等人的研究.....[14]采用参数化重构技术设计空间变化型核光学系统，在CIFAR-10数据集上的分类准确率更高（73.8%），优于基于空间不变性假设设计的光学系统（71.6%）。在PSF（点扩散函数）工程技术的另一变体中，Zheng等人进行了相关研究。[30]对偏振敏感型元光学系统的点扩散函数（PSF）进行工程化设计，以生成一系列焦点，这些焦点产生的图像强度与核权重相对应。

3.3 Outlook——混合卷积神经网络的计算效能

网络所需MAC操作的数量可作为计算复杂度的衡量指标，该指标与所采用的硬件技术无关。在现代数字系统中，一次MAC操作大约消耗 1pJ 能量[21, 18]。因此，基于MAC操作次数的减少，混合网络有望将输入分类所需的功耗从 $17\text{ }\mu\text{J}$ 降低至 85 nJ 。此类分类任务的延迟也预计将成比例下降。对于已处于光域的输入，无论采用何种网络，捕获图像并将其转换为数字输入所需的功耗和延迟均相同。具体而言，MNIST手写数字是使用标准摄像头捕获的；我们网络的光学前端采用标准摄像头传感器，并用超光学系统替换了折射式镜头。

随着输入像素数量的增加，通过光学方式实现卷积步骤的优势变得更加显著。每个卷积层的电子计算复杂度取决于输入图像的高度和宽度（ H, W ）以及卷积核的尺寸（ k ），其复杂度为 $O(HWk^2)$ [16]。然而，在光学卷积层中，计算复杂度可降至 $O(1)$ 量级。例如，当MNIST数据集的典型图像尺寸从 28×28 像素扩大至 100×100 像素时（假设核尺寸保持不变），每个卷积层的电子计算复杂度预计将增加12.76倍，但采用光学实现的卷积运算不会导致计算时间增加。因此，随着现实世界图像分辨率的持续提升，如本文所述的混合网络为解决全电子网络面临的扩展难题提供了极具前景的解决方案。

总之，我们通过采用电子后端实现单层光学卷积，在MNIST手写数字分类任务上达到了与AlexNet-Mod相当的准确率，同时将计算复杂度降低了99.5%。为规避AlexNet-Mod的非线性特性，我们运用知识蒸馏技术将CNN压缩为线性层，并以混合架构形式实现。作为一项进一步的创新，我们通过优化元光学系统的点扩散函数（PSF）实现了光学卷积运算。与常用的四倍焦距（4f）镜头系统相比，这种方案不仅实现了更紧凑、更可靠的光学前端设计，还无需相干照明或偏振控制。该混合方法能与现有卷积神经网络（CNN）架构无缝集成，采用简洁的光学设计，且无需对电子后端进行重新训练即可完成实验数据分类。此外，该方法适用于更高分辨率数据集的扩展：与全电子网络中卷积时间随输入像素数量增加而延长不同，光学卷积的处理时间与数据集分辨率无关。本研究为其他光学及混合神经网络提供了基准方案，有助于在日益普及的CNN应用中实现更高的带宽、更低功耗及更短延迟。

4 材料与方法

4.1 将知识传递给线性网络

知识蒸馏（KD）算法旨在压缩神经网络。KD通过将知识从一个规模更大、经过预训练的网络（称为“教师模型”）转移到一个更为紧凑的网络（称为“学生模型”）来实现这一目标。在我们的实现中，我们使用AlexNet-Mod作为教师网络，而使用线性网络作为学生网络。该学生网络仅由一个卷积神经网络（CNN）构成。

仅包含一个全连接层。直接训练该线性网络容易收敛到次优鞍点；然而，采用知识蒸馏方法后，学生网络收敛速度更快，性能也优于未使用知识蒸馏训练时的表现。

KD算法通过结合两种损失函数——温度损失和学生损失——来优化线性学生网络。与图像分类中的其他传统损失函数类似，KD将训练标签作为“硬标签”，并计算概率分布向量 p^{hl} ，其中向量中的每个元素 p_i^{hl} 对应当前输入属于类别 i 的概率。采用softmax函数来计算这些概率。

$$p_i^{hl} = \exp(z_i) / \sum \exp(z_i) \quad (1)$$

其中 z_i 表示学生在最后一个全连接层后的逻辑值。

随后，KD将教师模型的预测结果视为“软标签”，这些标签用于指导学生模型的学习；因为仅使用硬标签进行训练是一个敏感过程，尤其对于紧凑型线性网络而言。KD包含一个软化参数 T ，该参数被称为教师概率的蒸馏温度。因此，对于每个输入，在使用学生模型计算 p^{hl} 的同时，KD会根据教师模型计算出软概率向量 p^{sl} 。

$$p_i^{sl} = \exp(y_i/T) / \sum \exp(y_i/T) \quad (2)$$

因此，总损失可通过将两种损失进行加权求和来计算。

$$\mathcal{L}(x, \Phi) = \alpha \mathcal{L}_C(y, p^{hl}) + (1 - \alpha) \mathcal{L}_k((p^{sl,t}; T = \tau), (p^{sl,s}; T = \tau)) \quad (3)$$

其中 x 对应输入， y 为训练数据， Φ 是学生模型权重， $\mathcal{L}_C$ 为交叉熵损失函数， $\mathcal{L}_k$ 为库尔巴克-莱布勒（KL）散度损失函数[31]， p^{hl} 对应学生模型的硬预测结果， $p^{sl,t}$ 对应给定教师模型概率 $p^{sl,t}$ 下的学生预测结果，而 α 为权重参数。

4.2 利用有限数据校准光学实验结果

该校准功能旨在将光学卷积输出重新映射，使其与先前训练的后端模型输出对齐。这一改进解决了光学组件与电子组件之间可能出现的各种差异，包括尺寸缩放、平移、旋转以及光学噪声等问题。通过增加校准层，全连接层的权重得以保留，光学前端可直接集成到现有网络框架中，而无需重新训练后端模型或对光学对准进行微调。

具体而言，校准层为全连接层。该过程中使用的损失函数定义如下：

$$L = \min(f_{calibrate}(ON), EN) \quad (4)$$

其中 ON 表示包含光学实验结果的网络， EN 则是全电子网络。该方法旨在优化实验输出，使其更贴近预先设计的电子网络。为防止过拟合，我们战略性地仅使用可用数据的10%进行训练，从而确保模型保持高效[32, 33]。校准层可处理光学系统中遇到的各种噪声类型，从而确保混合网络更具鲁棒性。

4.3 元光学设计

这些元光学结构的设计充分考虑了我们的实验装置。鉴于相机（GT-1930C）的灵敏度及可用光源特性，我们专门针对525纳米波长的照明设计了光学系统。在所有电磁模拟中，我们采用586纳米的模拟网格尺寸，该尺寸既与光波长相匹配，又能被相机像素尺寸（每个像素 $5.86 \mu\text{m}$ ）整除。每个子光学结构均为方形，尺寸为 800×800 个模拟像素，既实现了紧凑的体积布局，又保证了合理的计算时间。虽然无需在亚波长网格上传播电场，但必须使元光学散射体具备亚波长周期性。因此，我们将每个元光学像素划分为由 2×2 个方形散射体组成的模块，每个模块周期为293纳米。针对750纳米SiN（折射率 $n=2.06$ ）柱状结构，我们选取了能在目标波长下产生 0 至 2π 相位偏移的配置方案。散射体单元胞的模拟采用S4 RCWA软件[34]完成，更多元光学设计细节详见补充材料。

4.4 元光学器件制造技术

卷积式超光学器件是在石英基板上的氮化硅层上制备的。我们首先采用等离子体增强化学气相沉积法（Oxford; Plasma Lab）在双面抛光的石英晶圆上沉积了氮化硅。

100)随后,我们使用电子束光刻技术(JEOL;JBX6300FS)在正性光刻胶(ZEP-520A)上进行图案制备。为蚀刻氮化硅层,我们采用氧化铝作为硬掩模:先通过电子束蒸发器(CHA;SEC-600)沉积氧化铝,再使用1-甲基-2-吡咯烷酮进行剥离处理。氮化硅层的蚀刻采用等离子体刻蚀机(Oxford;PlasmaLab 100, ICP-180),并使用含氟气体。为最大限度减少元光学系统的杂散光,我们通过光刻工艺(Heidelberg;DWL 66+)在每个子光学元件周围设置光阑,并结合金属沉积及剥离工艺,仅保留16个核心子光学元件的照明。

4.5 光学测量

采用简单的测量装置同步测量了16种不同光学核的二维点扩散函数。单模光纤耦合光源作为点光源,超光学元件与光源间距为92毫米。我们将超光学元件安装在三轴线性载台上,并配合带有两个旋转调节旋钮的动力支架,从而能够精确确定超光学元件相对于设计装置的位置和角度。随后,在距离超光学元件2.4毫米处放置一台高分辨率彩色相机(型号GT-1930C,像素分辨率 μ 为5.86微米),用于采集各核函数的点扩散函数。为获取卷积图像,我们仅将光源从单模光纤更换为可显示MNIST手写数字数据集的微型显示屏。该相机可同时捕捉来自不同核函数的全部16幅卷积图像,我们利用Python代码自动采集了MNIST数据集中的10,000幅卷积图像。

补充信息

在线版本包含补充材料。

代码可用性

所生成和/或分析的代码及数据可根据合理请求向通讯作者索取。

致谢

本研究由美国国家科学基金会(NSF-ECCS-2127235和EFRI-braid-2223495)资助。本研究的部分工作是在华盛顿纳米制造与分子分析中心完成的,该中心是华盛顿大学下属的国家纳米技术协调基础设施(NNCI)站点,并获得了美国国家科学基金会通过资助项目NNCI-1542101和NNCI-2025489提供的部分资助。

作者贡献

A.W.S.、J.X.和M.C.对本研究贡献相当。E.S.和A.M.提出了研究构想并提供了资金支持。S.C.参与了初步卷积元光学及知识蒸馏方法的设计工作。J.X.与E.S.共同开发了知识蒸馏方法;J.X.负责训练神经网络并分析实验数据;A.W.S.开发了PSF工程方法并设计了元光学系统;M.C.负责元光学器件的制造及光学实验的实施;L.H.编写了实现实验自动化的脚本;J.F.为器件制造和实验提供了指导;J.F.、E.S.和A.M.共同负责项目管理工作并对论文进行了修订。

竞争性利益

A.M.是Tunoptix公司的联合创始人,该公司致力于将元光学技术商业化。

参考文献

- [1] 亚历克斯·克里热夫斯基、伊利亚·苏茨克韦尔和杰弗里·E·欣顿。“基于深度卷积神经网络的图像分类”。载于:《神经信息处理系统进展》第25卷(2012年)。
- [2] X. Li等人,《基于GPU的卷积神经网络性能分析》,载于:第45届ICPP(2016年),第67–76页。
- [3] P. L. McMahon. “光学计算的物理学。”见: *Nat. Rev. Physics* 5 (2023), 第717–734页。
- [4] J. Chang 等人: “采用优化衍射光学技术的混合光电子卷积神经网络用于图像分类。”载于: *Scientific Reports* 8 (2018), 第 12324 页。

- [5] S. Colburn 等人: “卷积神经网络的光学前端。” 载于: 《应用光学》第58卷第12期(2019年), 第3179–3186页。
- [6] 杨先生等人: “具有原子非线性的光学卷积神经网络。” 载于: *Optics Express* 31.10 (2023), 第16451–16459页。
- [7] L. Cutrona 等人: “光学数据处理与滤波系统。” 载于: *IRE 信息理论汇刊* 6.3 (1960), 第386–400页。
- [8] J. N. Mait, G. W. Euliss 和 R. A. Athale. 《计算成像》。载于: *Adv. Opt. Photon.* 10 (2018), 第409–483页。
- [9] Carlos Mauricio Villegas Burgos 等人. “基于超表面光学的卷积神经网络设计框架”。载于: *Appl. Opt.* 60.15 (2021年5月), 第4356–4365页。
- [10] Z. Hu 等人: “高通量多通道并行衍射卷积神经网络加速器。” 载于: *Laser Photonics Rev.* 16 (2022), 第2200213页。
- [11] W. Lohmann 和 W. T. Rhodes. “双瞳孔光学传递函数合成”。载于: *Appl. Opt.* 17.7 (1978), 第1141–1151页。
- [12] J. N. Mait 和 W. T. Rhodes. “光学传递函数的双孔径合成: 2: 孔径函数关系”。载于: *应用光学* 25.12 (1986), 第2003–2007页。
- [13] J. N. Mait. “复杂非相干空间滤波的瞳孔功能设计”。载于: *JOSA* 4.7 (1987), 第1185–1193页。
- [14] K. Wei 等人: “空间变化的纳米光子神经网络”。载于: *Arxiv* (2023), 第2308.03407页。
- [15] 亚历克斯·克里热夫斯基、伊利亚·苏茨克韦尔和杰弗里·E·欣顿。《基于深度卷积神经网络的ImageNet分类(AlexNet)》。载于: ()。
- [16] Jinlin Xiang 等人: “知识蒸馏规避光学卷积神经网络的非线性问题”。载于: *Applied Optics* 61.9 (2022), 第2173–2183页。
- [17] A. Ryou等人: “基于热原子非线性的自由空间光学神经网络。” 载于: *Photon Res.* 9 (2021), B128–B134。
- [18] T. Wang 等人: “基于多层非线性光学神经网络的图像传感。” 载于: *Nature Photonics*, 第17卷(2023年), 第408–415页。
- [19] H. Zheng等人: “用于对象分类器的元光学加速器。” 见: 《科学进展》第8卷第30期(2022年)。
- [20] T. Zhou 等人: “采用可重构衍射处理单元的大规模神经形态光电子计算。” 载于: *Nature Photonics* 15 (2021), 第367–373页。
- [21] L. Huang 等人: “光学编码器的光子学优势。” 载于: 《纳米光子学》(2023年)。
- [22] ,Saban Ozturk 等人: “卷积核尺寸对组织病理学图像处理应用中卷积神经网络的影响”。载于: 2018年国际电气工程基础研讨会 (ISFEE)。IEEE, 2018年, 第1–5页。
- [23] 韩彩等人: “面向微型深度学习的网络增强”。载于: *arXiv预印本 arXiv:2110.08890* (2021)。
- [24] R. W. Gerchberg. “一种基于图像与衍射平面图像确定相位的实用算法。” 见: *Optik* 35 (1972), 第237–246页。
- [25] J. W. Goodman. 《傅里叶光学导论》。科罗拉多州恩格尔伍德: Robers & Company出版社, 2005年。
- [26] K. Matsushima 和 T. Shimobaba. 《用于远场与近场自由空间传播数值模拟的带限角谱方法》。载于: 17.22 (2009), 第19662–19673页。
- [27] Arthur Jacot等人 “深度线性网络中的鞍点间动态: 小规模初始化训练、对称性与稀疏性”。载于: *arXiv 预印本 arXiv:2106.15933* (2021)。
- [28] 马吉与袁玉玉。《基于PCA的图像深度特征降维方法》。载于: 《视觉通信与图像表示杂志》第63卷(2019年), 第102578页。
- [29] 戈尔达娜·伊沃谢夫、莱尔·伯顿和罗恩·邦纳。《主成分分析中的降维与可视化》。载于: 《分析化学》第80卷第13期(2008年), 第4933–4944页。
- [30] H. Zheng 等人: “用于加速机器视觉的多通道元成像器。” 载于: *Nature Nanotechnology*, 第59卷(2024年)。
- [31] Seo Geonseok 等人: “基于KL-分歧度的区域提议网络用于目标检测”。收录于: 2020年IEEE国际图像处理会议 (ICIP)。IEEE, 2020年, 第2001–2005页。
- [32] Jinlin Xiang 与 Eli Shlizerman. 《TKIL: 用于类别平衡增量学习的切线核优化》。载于: *IEEE/CVF 国际计算机视觉会议论文集*, 2023年, 第3529–3539页。
- [33] 杨 Zheng 等人: “Bi-maml: 一种用于元学习的平衡增量方法”。见: *arXiv 预印本 arXiv:2006.07412* (2020)。

- [34] V. Liu 和 S. Fan。《S4：一种用于层状周期结构的免费电磁求解器》。载于：《计算机物理通讯》，第183卷（2012年），第2233–2244页。