

Demo级验证方案调研报告

超表面光学视觉前端 + AI 神经网络用于工业缺陷检测

核心思路：先用成熟 GitHub 项目和开源工业缺陷数据集跑通电子端完整闭环；再把电子 CNN 的前端特征提取模块抽象为 OpticalConvBank；最后用蒸馏、物理约束训练和光电混合架构，把该前端映射到超表面光学卷积/编码器。

调研日期：2026-05-09

报告定位：用于开题前的 demo 方案选择、代码复现路径和后续超表面设计规划。

0. 执行摘要

现阶段最稳的策略不是直接设计“超表面 YOLO”，而是先跑通一个简单、成熟、可复现的工业缺陷检测电子闭环。这个闭环应该足够小，方便以后把电子 CNN 前端替换为光学前端；同时任务又要足够工业化，避免停留在 MNIST/Fashion-MNIST 这类弱应用场景。

本报告按四个问题展开：一是选什么数据集和工业任务；二是选什么 AI 模型；三是超表面如何实现线性/CNN 运算或编码；四是如何让超表面承载 AI 模型，包括蒸馏、编码和光电混合。

推荐第一版 demo：DeepPCB 数据集 + ResNet18 或小 CNN 多标签分类 teacher + OpticalConvBank student + 轻量电子头。DeepPCB 与 PCB/芯片/电子制造更接近，含 1500 对模板/测试图和 6 类缺陷标注；现成 GitHub 项目已经有 ResNet18 多标签分类闭环，报告 F1=91.2%、Recall=98.3%、20 ms/image。

- 最小任务：有缺陷/无缺陷二分类，或 6 类 PCB 缺陷多标签分类。
- 中期任务：把 bounding box 标签转成 heatmap，做缺陷位置提示。
- 后期任务：超表面生成 ROI/defect saliency map，再接 tiny YOLO 或轻量检测头。
- 超表面角色：不是完整神经网络，而是 sensor-side optical encoder，即 CNN 第一层或第一组卷积的物理实现。

本阶段不建议把 YOLO 作为最终模型核心。YOLO 可以作为后续 teacher 或 baseline；第一版更适合用 ResNet18、小 CNN、U-Net heatmap head 或 anomaly detection 模型，原因是这些模型更容易拆出可光学替换的前端。

1. 四个关键问题与总体技术路线

问题	demo阶段建议	后续超表面映射
1. 数据集 / 工业任务	先选 DeepPCB：电子制造相关、公开、有 GitHub、标注含缺陷位置和 6 类类型。备选 AITEX 织物二分类、MVTec AD 异常检测。	选固定视场、固定照明、少类别、小缺陷场景，便于把任务知识压缩到少量光学特征通道。
2. AI模型架构	第一版用 ResNet18 / 小 CNN / U-Net heatmap，不急于 YOLO。YOLO 可以作为 teacher 或目标检测扩展。	拆分为 OpticalConvBank + tiny electronic head：超表面做线性编码，电子端做非线性判别。
3. 超表面设计	先在 PyTorch 中模拟 N 个 learned kernels：4/8/16 通道，15×15 或 31×31。	用 PSF/OTF 工程、多通道复用、正负权重差分 and 物理约束训练，把 learned kernels 映射为超表面。
4. 承载 AI 的方式	先直接训练 optical student，再做 teacher-student 蒸馏。	复杂电子 teacher 的判别知识压缩到受物理约束的线性光学编码器；电子后端仅保留 pooling/MLP/1×1 conv/sigmoid。

总流程如下：

Step 1 ■■■■■■DeepPCB ■■ → ResNet18/small CNN → ■■■■■■■■
Step 2 ■■ student ■■■■DeepPCB ■■ → OpticalConvBank → tiny head → ■■■■
Step 3 ■■■■teacher logits/features/heatmaps → student■
Step 4 ■■■■■■SLM/4f ■■ → metasurface PSF/OTF ■■ → CMOS ■■ feature maps■

需要注意：如果整个系统完全线性，则两个线性层叠加仍等价于一个线性层，表达能力有限。因此合理架构不是全光替代，而是“超表面负责高分辨率线性编码，电子端负责极小非线性决策”。

2. GitHub 电子端成熟项目调研

筛选标准是：数据是否公开、训练/推理是否相对完整、模型是否不太复杂、是否适合后续把前端替换成 OpticalConvBank。以下是推荐排序。

优先级	项目/链接	数据集与任务	模型/闭环	适合程度
1	pcb-defect-detection	DeepPCB；PCB 6 类缺陷多标签分类。	ResNet18 backbone + dropout + 6 类 sigmoid；项目报告 F1=91.2%、Recall=98.3%、20 ms/image。	最推荐。贴近电子制造，模型不复杂，适合先做电子闭环，再蒸馏到 OpticalConvBank。
2	DeepPCB 官方数据集	1500 对 PCB 模板/测试图；标注 x1,y1,x2,y2,type；6 类缺陷。	数据集和 evaluation 工具；原论文 deep detector 报告 98.6% mAP @ 62 FPS。	主数据源。可以从分类扩展到 heatmap/检测。
3	fabric_defect_detection	AITEX 织物缺陷；patch 二分类 + UNet 分割。	4 个卷积块小 CNN；Streamlit UI；分类 F1=0.975。	最快 demo。场景非芯片，但最容易验证 optical encoder 替代 CNN 前端。
4	anomalib	MVTec AD / VisA 等工业异常检测。	PatchCore、PaDiM、FastFlow、EfficientAD 等；CLI/API/部署完整。	成熟 benchmark。模型较复杂，不适合第一版映射，但适合做强 baseline。
5	pcbDefectDetectionYOLO	DeepPCB；YOLOv3 目标检测。	YOLOv3/tiny-YOLO 配置、训练 notebook、Web demo。	目标检测扩展参考。不建议第一版主线。
6	Steel_defect	NEU-DET 钢表面缺陷检测。	YOLOv5、RetinaNet、anchor 优化、数据转换。	可做补充 benchmark；与芯片/PCB 主线弱相关。
7	mixed-segdec-net	KolektorSDD、KolektorSDD2、DAGM、Severstal。	混合监督 segmentation + classification。	真实工业表面缺陷强，但代码和任务相对复杂。
8	Magnetic Tile defects	磁瓦表面缺陷；像素级标注。	binary semantic segmentation。	可作为简单分割 demo 备选。

结论：第一版主线选 DeepPCB + ResNet18 多标签分类项目；若希望一两天内快速看到闭环，可先用 AITEX fabric_defect_detection 复现二分类，再迁移同样思路到 DeepPCB。

3. 数据集与工业任务选择

3.1 推荐主线：DeepPCB

DeepPCB 的优势在于：它来自 PCB 工业检测，图像由线扫 CCD 获取；每个样本有缺陷测试图、无缺陷模板图和 bounding box 标注；缺陷类型包括 open、short、mousebite、spur、spurious copper、pin-hole。官方仓库说明共有 1500 对图像，原始图约 $16k \times 16k$ ，裁剪成 640×640 子图，并分为 1000 张训练图和 500 张测试图。

- demo 1：二分类 - 将所有有缺陷样本视为 NG，正常样本为 OK。如果需要正常样本，可从模板图或无缺陷区域构造。
- demo 2：多标签分类 - 输入一张 640×640 PCB 图，输出 6 类缺陷概率。该任务不需要精确定位，最适合第一版超表面 student。
- demo 3：heatmap 定位 - 将 bounding box 转成 Gaussian heatmap 或 binary mask，训练 student 输出 defect probability map。
- demo 4：目标检测 - YOLO/FCOS/RetinaNet 可做 teacher 或对照，但不建议第一版直接做。

DeepPCB 也存在局限：其测试图经过二值化/配准处理，和真实灰度/彩色芯片表面成像存在 domain gap。因此它适合作为第一阶段算法闭环，后续仍需要自采 PCB/芯片/晶圆样品图验证光路。

3.2 快速验证备选：AITEC fabric

AITEC 织物缺陷项目有完整二分类和分割 pipeline。尽管场景不是芯片，但它的任务简单、patch 二分类自然、模型小，适合快速验证“线性光学编码器 + 小电子头”是否可行。该 GitHub 项目使用 140 张无缺陷图和 105 张缺陷图，切成 256×256 patch，先做 defect/no-defect 二分类，再对阳性 patch 做 UNet 分割。

3.3 成熟 benchmark 备选：MVTec AD + Anomalib

MVTec AD 是工业异常检测标准数据集，包含 5000 多张高分辨率图，15 个 object/texture 类别，训练集为无缺陷样本，测试集含缺陷图和像素级标注。Anomalib 已提供 MVTecAD datamodule 和 PatchCore/PaDiM/FastFlow/EfficientAD 等模型的训练、推理和部署接口。

不建议将 Anomalib 作为第一版光学映射对象，因为 PatchCore/PaDiM/EfficientAD 依赖深层预训练特征、memory bank 或 teacher-student 模型，和“超表面做一组线性卷积核”之间的映射不够直接。它更适合后期做强数字 baseline。

4. AI模型选择：从小模型开始，而不是直接 YOLO

第一版 demo 的目标是证明“工业缺陷任务可以被压缩到少量光学特征通道 + 极小电子头”。因此模型越复杂，越不利于解释超表面的作用。推荐采用三层模型策略。

层级	模型	适用任务	为什么适合/不适合超表面
第一层：最小闭环	Small CNN / ResNet18 classifier	OK/NG 二分类、6 类多标签分类	最容易复现；可拆分成前端卷积 + 后端分类头；适合蒸馏到 OpticalConvBank。
第二层：定位能力	U-Net / shallow heatmap head	缺陷概率图、粗定位、连通域后处理	比 YOLO 更适合光学卷积输出；热力图可以直接从 defect saliency feature maps 得到。
第三层：复杂检测	YOLOv5/v8/v11、FCOS、RT-DETR	多类 bounding box 检测、小目标定位	适合作为 teacher/baseline；不建议说超表面实现完整 YOLO。可做超表面 ROI generator + tiny detector。
异常检测	PatchCore / PaDiM / EfficientAD	只用正常样本训练、异常定位	工业界成熟，但依赖深层预训练特征和 memory bank，光学映射难度较高。

建议第一版实现两条电子闭环：

- DeepPCB-Classification：ResNet18 teacher → 6 类 sigmoid。这个用于验证电子端基线和蒸馏。
- DeepPCB-Heatmap：把 bbox 转 heatmap，用浅层 U-Net 或 teacher detector 生成 soft target，再训练 OpticalConvBank student 输出 defect heatmap。

YOLO 的合理位置：YOLO 可以作为更强 teacher，输出 logits、objectness map、box 或中间 feature；但 student 不必长得像 YOLO。论文/项目中应避免“超表面实现 YOLO”的表达，改为“YOLO-guided task distillation for a metasurface optical encoder”。

5. 第一版电子端闭环建议

建议先在普通 GPU/CPU 上跑通以下闭环，不涉及超表面。

```

■■■DeepPCB 640×640 ■■■
■■■ResNet18 teacher / small CNN baseline■
■■■6 ■■■■■■■■■■ OK/NG ■■■■
■■■Accuracy|Precision|Recall|F1|per-class F1|inference time|■■■MACs■

```

第一版不需要完整检测框。如果数据样本内每张图通常有 3-12 个缺陷, 6 类多标签分类已经能说明是否识别出缺陷类型; 等分类闭环稳定后, 再利用 box 标签生成 heatmap 做缺陷位置提示。

5.1 电子端 baseline 结构

推荐 baseline :

- Input 640×640 PCB image
- ResNet18 backbone
- Global average pooling
- Dropout
- Linear layer, 6 outputs
- Sigmoid probabilities for 6 defect classes

然后构造一个小模型 baseline：

- Input image
- ConvBlock $\times$ 2 or 3
- Global average pooling
- Linear / MLP
- 6-class sigmoid

小模型 baseline 很重要，因为你的 optical student 不能只和大 ResNet18 比；它还要和“普通小 CNN”比较，证明超表面前端不是靠降低任务难度取胜。

5.2 从电子 CNN 到可替代前端

把网络拆成两部分：

```
x → F_electronic(x) → head → prediction
■■ F_electronic ■ CNN ■■■■■■■■■■
x → F_optical(x; h1...hN) → head → prediction
```

这个 F_{optical} 就是后续超表面要实现的 OpticalConvBank。

6. OpticalConvBank：超表面前端的数字等效模型

在 PyTorch 中先定义一个可训练的、受物理约束的 OpticalConvBank：

```
y_i = x * h_i + noise, i = 1...N
```

■ x ■■■■■■ h_i ■ i ■■■■■■ y_i ■■■■■■ i ■ feature map

建议起步参数：

- 输入：灰度图或模板差分图，先不做 RGB。
- 通道数 N：先 4 或 8，再扩展到 16。
- kernel size：15×15 或 31×31。若要体现光学大核优势，可尝试 63×63。
- 后端：global pooling + linear，或 1×1 conv + sigmoid heatmap。
- 约束：权重幅值限制、正负权重分解、量化、噪声、通道串扰、有限 NA/带宽。

6.1 为什么是线性编码器，而不是完整 CNN

被动超表面最自然实现的是一个或一组线性光学算子。它可以把卷积、频域滤波、方向/尺度选择、背景抑制等运算前移到成像链路；但 ReLU、BatchNorm、多尺度 feature fusion、box regression、NMS 等仍应交给电子端。

因此合理架构是：

```
■■■■■■■■■■■■■■■  
CMOS■■■■■■ feature maps  
■■■■■■■■■■■■■■ linear/MLP/1x1 conv/sigmoid
```

6.2 正负权重与多通道实现

真实光学强度一般非负，CNN 卷积核却有正负权重。可采用差分读出：

$$h = h_{\text{max}} - h_{\text{min}}$$
$$y = x * h = x * h_{\text{max}} - x * h_{\text{min}}$$

物理上可用空间复用、偏振复用、角度复用或波长复用分别输出正/负通道；后端 CMOS 或电子电路做差。Nature Nanotechnology 2024 的 multichannel meta-imager 已经展示了角度/偏振复用的正负卷积通道；ACS Photonics 2024 的大核 metasurface convolution 工作也展示了多核、正负权重和非相干照明下的空间复用。

7. 如何让超表面承载 AI：直接训练、蒸馏与光电混合

7.1 直接训练 optical student

最简单路线是不使用 teacher，直接训练：

```
image → OpticalConvBank → tiny head → label / heatmap
```

损失函数按任务选择：

- 二分类：BCE loss。
- 多标签分类：BCEWithLogits loss。
- heatmap 定位：BCE + Dice / Focal。
- 若有 box：可先转 Gaussian heatmap，再做阈值和连通域，暂时避免完整 YOLO loss。

7.2 Teacher-student 蒸馏

更强路线是先训练一个电子 teacher，再把它的任务知识蒸馏到 optical student。已有光学 CNN 知识蒸馏工作证明，KD 能部分绕开光学网络缺少中间非线性的瓶颈；compressed meta-optical encoder 也展示了用 KD 将改造 AlexNet 压缩到一个光学卷积层 + 电子后端。

推荐损失：

```

$$L = L_{\text{task}} + \alpha L_{\text{logit}} + \beta L_{\text{feature}} + \gamma L_{\text{heatmap}} + \delta L_{\text{physics}}$$

```

- L_{task} ：与真实标签比较，例如 BCE、Focal、Dice。
- L_{logit} ：student 输出概率接近 teacher 输出概率。
- L_{feature} ：student 中间特征接近 teacher 浅层特征。
- L_{heatmap} ：student saliency map 接近 teacher objectness/mask。
- L_{physics} ：相位/振幅约束、正负通道、串扰、噪声、量化、有限带宽。

7.3 光电混合闭环

最终系统不应追求“全光”。最合理目标是：

高分辨率、重复性的线性前端由超表面承担；低维、少量的非线性决策由电子端承担。

这既符合超表面的物理能力，也符合工业部署逻辑：在线检测中大量计算浪费在高分辨率前端特征提取上，而最终判别通常只需要少量缺陷敏感特征。

8. 超表面设计路线：从数字核到物理器件

8.1 三阶段实现路线

阶段一：纯数字仿真。先把 OpticalConvBank 当成 PyTorch 模块训练，加入噪声和约束。

阶段二：4f/SLM 原型。用 SLM 或可编程滤波器在 Fourier 面实现 learned filter，验证真实光学 feature maps 能否支持分类/heatmap。

阶段三：超表面制备。将 learned PSF/OTF 映射到 metasurface，采用空间复用、偏振复用或角度复用输出 4/8/16 个通道。

8.2 设计形式

形式	优点	限制	demo建议
PSF-engineered meta-imager	直观：成像过程本身就是卷积；适合接 CMOS。	任意 signed multi-kernel 和效率较难；需处理视场和像差。	适合最终小型化样机。
Fourier-plane OTF processor	适合频域滤波、大核卷积、背景/周期纹理抑制。	4f 光路较大；需要精确对准。	适合 SLM/4f 先验验证。
空间复用多通道	实现简单；相机不同区域记录不同 feature map。	牺牲视场或分辨率。	第一片器件推荐。
偏振/角度/波长复用	更紧凑；能单次输出多通道。	设计和标定复杂；串扰需建模。	第二阶段增强。
可重构超表面	可切换任务/核；适合未来自适应检测。	材料、损耗、速度、寿命带来难度。	未来展望，不作为第一版。

8.3 物理约束必须进入训练

如果只在数字端训练任意卷积核，然后事后声称“可以用超表面实现”，说服力不够。建议从第一版仿真就加入：

- kernel 幅值/能量归一化；
- 正负权重差分通道；
- 通道串扰矩阵；
- 相位/振幅量化；
- shot noise / read noise；
- 有限 NA 和有限 OTF support；
- 加工误差和对准误差。

9. demo 实验设计与对照

要证明超表面前端有价值，不能只比较“大模型 teacher vs 小 optical student”。需要设置公平对照。

编号	实验组	目的
A	ResNet18 teacher / 强电子模型	给出任务上限和蒸馏来源。
B	普通 small CNN	证明不是所有小模型都能完成任务。
C	手工 Sobel/Gabor/LoG + linear/MLP	排除“只是边缘检测”的质疑。
D	learned OpticalConvBank + tiny head	证明任务学习的光学线性编码器有效。
E	distilled OpticalConvBank + tiny head	证明 KD 能把 teacher 知识压缩到光学 student。
F	physics-constrained OpticalConvBank	证明模型在加入真实光学约束后仍可用。
G	SLM/4f 或 metasurface 实验 feature maps + same head	验证从数字到光学的实现差距。

9.1 建议指标

- 分类任务：Accuracy、Precision、Recall、F1、per-class F1、false alarm、miss rate。工业检测应更重视 Recall 和 miss rate。
- 定位任务：pixel-level AUROC、PRO、IoU、Dice、center localization error、defect-level recall。
- 系统指标：电子 MACs、参数量、推理时间、读出数据量、需要处理的 ROI 数量。
- 光学指标：通道数、光效率、串扰、PSF/OTF 误差、视场、分辨率、对准容差。

9.2 第一版里程碑

M1■■■ DeepPCB ResNet18 ■■■■■■

M2■■■ small CNN baseline■

M3■■■ OpticalConvBank + linear■■■■■■■■■ baseline■

M4■■■ teacher-student distillation■

M5■■■■■■■■■■■

M6■■■■■ heatmap ■■■■

M7■■■ SLM/4f ■■ learned kernels■

10. 具体执行计划

阶段	时间	目标	产出
P0	第 1 周	环境和项目复现	DeepPCB 下载、ResNet18 项目跑通、得到 baseline 指标。
P1	第 2-3 周	小模型和任务重构	small CNN、OK/NG、6 类多标签分类；统一评估脚本。
P2	第 4-5 周	OpticalConvBank 仿真	4/8/16 通道 learned kernels；手工滤波对照。
P3	第 6-7 周	蒸馏训练	teacher logits/feature/heatmap 蒸馏；student 性能提升曲线。
P4	第 8-9 周	物理约束	正负权重、噪声、串扰、量化、有限 NA；鲁棒性测试。
P5	第 10-12 周	缺陷定位	bbox→heatmap；student 输出 defect probability map；connected component 生成位置。
P6	第 13 周以后	光学实验准备	SLM/4f 验证方案、metasurface 通道数和核尺寸确定。

第一版代码结构建议：

```
datasets/deeppcb.py
models/teacher_resnet.py
models/optical_conv_bank.py
models/tiny_head.py
train_teacher.py
train_student.py
train_distill.py
eval_metrics.py
configs/deeppcb_cls.yaml
configs/deeppcb_heatmap.yaml
```

建议把电子端和光学 student 的输入输出张量定义统一。这样后续从数字 OpticalConvBank 替换成 SLM/4f 或 metasurface 采集 feature maps 时，不需要重写后端。

11. 关键风险与规避策略

风险	表现	规避策略
数据集 domain gap	DeepPCB 是处理过的二值/配准数据，和真实芯片表面灰度成像不同。	先用 DeepPCB 验证算法闭环；随后自采 PCB/芯片/金属片样品，做灰度/反射真实数据。
线性 student 能力不足	OpticalConvBank + linear 性能远低于 teacher。	增加通道数、核尺寸、弱非线性电子头；使用 KD 和 heatmap target；将任务简化为 OK/NG 或 ROI proposal。
光学实现误差	数字仿真好，SLM/超表面输出差。	从训练开始加入噪声、串扰、量化和 PSF 误差；后端 fine-tune 适配实测 feature maps。
正负权重实现困难	光强非负，无法直接实现负权重。	采用 h+ / h- 双通道差分；或把 signed kernel 转为正通道组合，由电子端做差。
论文定位被质疑	审稿人认为这只是“数字滤波 + 小模型”。	强调传感器前端、系统读出/计算降低、光学实验 feature maps，以及与手工滤波/数字卷积的公平对照。

最重要的规避点：不要一开始承诺“全光 AI”或“超表面实现 YOLO”。项目核心应是 task-distilled metasurface optical encoder，也就是把固定工业场景中的缺陷判别知识压缩到可物理实现的光学线性编码器中。

12. 未来展望：从 demo 到高水平工作

第一版 demo 如果跑通，可以沿三个方向升级：更复杂模型、更复杂任务场景、更高级的超表面设计。

12.1 更复杂的模型

- YOLO/FCOS/RT-DETR teacher：用目标检测器提供 objectness heatmap、box 和中间特征，但 student 仍保持 OpticalConvBank + tiny head。
- U-Net/SegFormer teacher：用于像素级缺陷 mask，适合划痕、裂纹、污染等不规则缺陷。
- PatchCore/EfficientAD teacher：用于只有正常样本的异常检测，把 anomaly map 蒸馏给 optical student。
- 轻量边缘模型：TinyML-style head、depthwise separable conv、 1×1 channel mixing，把电子端进一步压缩。

12.2 更复杂的任务场景

- 芯片/晶圆/封装表面：划痕、污染、颗粒、裂纹、焊盘异常；这是最贴近“超表面视觉前端 + 工业检测”的场景。
- 线扫高速检测：钢板、织物、PCB 连续运动；超表面产生 defect saliency，电子端只处理可疑 ROI。
- 弱信号/低对比检测：暗场、散射、反射增强；超表面负责背景抑制和微缺陷显著性。
- 多模态工业检测：偏振、相位、散射角、波长通道联合编码，而不是只处理普通强度图。

12.3 更高级的超表面设计

- 多通道 signed convolution：正负权重差分、多核并行、单次曝光输出。
- 大核 optical-native front-end：利用光学天然大感受野，做 31×31 、 63×63 或连续频域核，不必模仿数字 CNN 的 3×3 。
- 硬件感知训练：把 fabrication error、相位量化、串扰、光效率、对准误差直接放进训练。
- 可重构/可切换超表面：针对不同材料/照明/缺陷类型切换 kernel bank。
- 传感器集成：metasurface-on-sensor 或 compact 4f-on-chip，让相机直接输出 feature maps，而不是普通图像。

长期目标可以定义为：一个面向工业在线检测的 metasurface convolutional sensing camera。它不输出人眼友好的图像，而是直接输出缺陷敏感的光学特征图，并由极小电子后端完成 OK/NG、缺陷类型和缺陷位置判断。

13. 参考链接清单

以下链接已按“GitHub 项目/数据集/超表面与光学神经网络/工业检测模型”分类。PDF 中链接可点击。

类别	名称	链接
GitHub	DeepPCB 官方数据集	https://github.com/tangsanli5201/DeepPCB
GitHub	DeepPCB ResNet18 多标签分类项目	https://github.com/fardinhossain007/pcb-defect-detection
GitHub	AITEX fabric defect detection	https://github.com/jraad/fabric_defect_detection
GitHub	Anomalib 工业异常检测库	https://github.com/open-edge-platform/anomalib
GitHub	DeepPCB YOLOv3 项目	https://github.com/VanillaHours/pcbDefectDetectionYOLO
GitHub	NEU-DET steel defect YOLOv5 项目	https://github.com/annsonic/Steel_defect
GitHub	Mixed supervision surface defect detection	https://github.com/vicoslab/mixed-segdec-net-comind2021
GitHub	Magnetic tile defect segmentation	https://github.com/MitraDP/Detection-of-Surface-Defects-in-Magnetic-Tile-Images
数据集	MVTec AD	https://www.mvtec.com/research-teaching/datasets/mvtec-ad
论文/数据集	DeepPCB arXiv paper	https://arxiv.org/abs/1902.06197
超表面	Ultracompact meta-imagers for arbitrary all-optical convolution	https://www.nature.com/articles/s41377-022-00752-5
超表面	Multichannel meta-imagers for accelerating machine vision	https://www.nature.com/articles/s41565-023-01557-2
超表面	Metasurface-generated large and arbitrary analog convolution kernels	https://arxiv.org/abs/2409.18614
光学KD	Knowledge distillation circumvents nonlinearity for optical CNNs	https://pubmed.ncbi.nlm.nih.gov/35333231/
光学KD	Compressed Meta-Optical Encoder for Image Classification	https://arxiv.org/abs/2406.06534
光电检测	PHOENIX photonic distillation for object detection	https://openreview.net/forum?id=J36Tagukno

推荐立即执行的第一步：clone DeepPCB 官方仓库和 ResNet18 多标签分类项目，复现电子端指标；随后把 ResNet18 前端替换为 OpticalConvBank student，并与手工滤波、小 CNN、teacher 蒸馏版本做对照。